

密级：公开

北京邮电大学

硕士学位论文(学术学位)



题目： 基于深度强化学习的汽车雷达
多域联合抗干扰技术

学 号： _____

姓 名： _____

学科专业： 信息与通信工程

培养方式： 全日制

导 师： _____

学 院： 信息与通信工程学院

2024 年 3 月 10 日



BEIJING UNIVERSITY OF POSTS AND TELECOMMUNICATIONS

Master Thesis

Automotive Radar Anti-Interference Technology
based on Deep Reinforcement Learning

Student ID: _____

Author: _____

Subject: **Information and Communication Engineering**

Supervisor: _____

Institute: **School of Information and Communication**

Mar. 10, 2024

答辩委员会名单

职务	姓 名	职 称	工 作 单 位
主席			
委员			
委员			
委员			
委员			
秘书			
答辩日期			

独创性（或创新性）声明

本人声明所呈交的论文是本人在导师指导下进行的研究工作及取得的研究成果。尽我所知，除了文中特别加以标注和致谢中所罗列的内容以外，论文中不包含其他人已经发表或撰写过的研究成果，也不包含为获得北京邮电大学或其他教育机构的学位或证书而使用过的材料。与我一同工作的同志对本研究所做的任何贡献均已在论文中作了明确的说明并表示了谢意。

申请学位论文与资料若有不实之处，本人承担一切相关责任。

本人签名：_____ 日期：_____

关于论文使用授权的说明

本人完全了解并同意北京邮电大学有关保留、使用学位论文的规定，即：北京邮电大学拥有以下关于学位论文的无偿使用权，具体包括：学校有权保留并向国家有关部门或机构送交学位论文，有权允许学位论文被查阅和借阅；学校可以公布学位论文的全部或部分内容，有权允许采用影印、缩印或其它复制手段保存、汇编学位论文，将学位论文的全部或部分内容编入有关数据库进行检索。（保密的学位论文在解密后遵守此规定）

本人签名：_____ 日期：_____

导师签名：_____ 日期：_____

摘 要

随着汽车毫米波雷达的日益普及,雷达之间的互相干扰正在成为一个严重的问题。原本用于辅助、智能驾驶的工具却可能危害行驶安全。为了解决这个问题,本文深度研究了基于深度强化学习的汽车雷达多域联合抗干扰技术。本文主要的研究内容和创新点包括:

1. 面对相干干扰的时、频域联合的抗干扰策略

针对目前缺少公开的汽车雷达场景仿真方法,提出了一种多目标多干扰源的动态场景仿真方法;针对目前合作式的雷达资源分配抗干扰策略需要额外的通信和计算开销,非合作式的抗干扰策略仅限于频谱分配或随机切换参数,其抗干扰效果受限的问题,基于认知雷达框架,提出了一种非合作式的时、频域联合参数调整的抗干扰策略,引入动作代价约束机制,并使用深度强化学习来优化;仿真实验表明所提方法能显著提升避开相干干扰的几率且更加鲁棒。

2. 面对相干干扰的连续值脉间相位编码抗干扰策略

针对现有的脉间相位编码方法仅使用迭代式方法求解离散的编码值,其求解空间有限、迭代效率低、实时性无法保证的问题,提出了一种非合作式的连续值脉间相位编码优化策略,并使用深度强化学习算法进行优化求解;仿真实验表明所提方法可以完全消除相干干扰引起的虚警并大幅减少漏检,且具有优秀的实时性。

3. 针对非相干干扰的多域联合的抗干扰策略

针对时域策略避开非相干干扰性能贫瘠的问题,在时、频域联合策略的基础上加入调频斜率的调整,提出了一种非合作式的多域联合参数调整的抗干扰策略,并使用深度强化学习来优化;仿真实验表明所提方法可以进一步减少非相干干扰进入雷达通带的比例,提升抗干扰性能,同时通过多组实验对比,验证了多个域的参数调整策略及其组合的抗干扰原理和有效性。

综上,本文针对汽车毫米波雷达相互干扰的问题,提出了三种基于深度强化学习的非合作式雷达参数调整策略,分别用于对抗相干干扰和非相干干扰,取得了良好的抗干扰性能、实时性和鲁棒性,形成了较为完备的多域联合抗干扰方法。

关键词: 汽车毫米波雷达; 抗干扰; 雷达参数调整; 联合域策略;

深度强化学习

ABSTRACT

With the increasing popularity of automotive millimeter-wave radars, mutual interference among them is becoming a significant issue, potentially undermining driving safety despite their original purpose of assisting and enabling intelligent driving. To tackle this problem, this thesis conducts an in-depth study on joint multi-domain anti-interference technology for automotive radar based on deep reinforcement learning. The main research contents and innovations presented include:

1. Joint time and frequency domain strategy against coherent interference

In response to the lack of open-source simulation methods for automotive radar scenarios, we propose a dynamic scenario simulation method for multiple targets and interference sources. Cooperative strategies for radar resource allocation require additional communication and computational overheads, and current non-cooperative strategies only implement spectrum allocation or random parameter switching, suffering a limited anti-interference capacity. To overcome these shortcomings, this thesis proposes a non-cooperative joint time and frequency domain parameter adjustment strategy under the cognitive radar framework. Furthermore, we introduce an action cost constraint mechanism and utilizing deep reinforcement learning to optimize the strategy. In numerical simulations, the proposed method significantly improves the probability of avoiding coherent interference and exhibits greater robustness.

2. Continuous value inter-pulse phase coding strategy against coherent interference

The existing inter-pulse phase coding methods use iterative methods to solve discrete value codes, which endure the limited solution space and poor real-time performance. To address this issue, we propose a non-cooperative continuous value inter-pulse phase coding optimization strategy based on deep reinforcement learning. Numerical simulations demonstrate that the proposed method can completely eliminate false

alarms caused by coherent interference and significantly reduce missed detections, while maintaining excellent real-time performance.

3. Joint multi-domain strategy against incoherent interference

To address the inability of the time domain strategy in avoiding non-coherent interference, we introduce the adjustment of chirp rate onto the joint time and frequency domain strategy, proposing a non-cooperative joint multi-domain parameter adjustment strategy for anti-interference, optimized via deep reinforcement learning. Numerical simulations show that the proposed method further reduces the proportion of non-coherent interference entering the radar's passband, thereby enhancing the anti-interference capability. Through comparative experiments with multiple sets, the principle and effectiveness of the parameter adjustment strategies across multiple domains and their combinations are validated.

In summary, this thesis proposes three non-cooperative radar parameter adjustment strategies based on deep reinforcement learning to address the problem of mutual interference among automotive millimeter-wave radars, which are designed to counteract coherent and incoherent interference, respectively. These strategies have demonstrated effective anti-interference performance, real-time capability, and robustness, forming a relatively comprehensive joint multi-domain anti-interference method.

KEY WORDS: automotive radar; anti-interference; radar parameter adjustment; joint domain strategy; deep reinforcement learning

目 录

摘 要.....	I
ABSTRACT.....	III
第一章 绪论.....	1
1.1 研究背景.....	1
1.2 国内外研究现状.....	1
1.3 本论文的主要内容及结构安排.....	5
第二章 面对相干干扰的时、频域联合抗干扰策略.....	7
2.1 FMCW 雷达基础	7
2.1.1 FMCW 雷达信号模型	7
2.1.2 运动场景下的目标回波和干扰信号推导.....	10
2.2 时域和频域联合干扰避免策略.....	14
2.3 基于深度强化学习的联合抗干扰策略的实现.....	16
2.3.1 马尔可夫决策过程.....	16
2.3.2 干扰避免的马尔可夫决策过程建模.....	19
2.3.3 所提方法基于深度强化学习的实现.....	20
2.4 仿真实验.....	26
2.4.1 实验设置.....	26
2.4.2 实验结果.....	29
2.5 本章小结.....	32
第三章 面对相干干扰的脉间相位编码抗干扰策略.....	33
3.1 应对相干干扰的相位编码.....	33
3.2 连续值相位编码策略.....	34
3.3 基于深度强化学习的脉间相位编码抗干扰策略的实现.....	37
3.3.1 脉间相位编码的 MDP 建模.....	37
3.3.2 强化学习算法设计.....	39
3.4 仿真实验.....	44
3.4.1 实验设置.....	44
3.4.2 实验结果.....	47
3.5 本章小结.....	50
第四章 面对非相干干扰的多域联合抗干扰策略.....	51
4.1 非相干干扰场景.....	51
4.2 面对非相干干扰的多域联合抗干扰策略.....	52

4.3	基于深度强化学习的多域联合抗干扰策略的实现.....	53
4.4	仿真实验.....	54
4.4.1	实验设置.....	54
4.4.2	实验结果.....	57
4.5	本章小结.....	59
第五章	总结与展望.....	61
5.1	总结.....	61
5.2	未来工作展望.....	62
参考文献		63
攻读学位期间取得的“创新成果”目录		68

符号说明

第一章 绪论

1.1 研究背景

进入 21 世纪,随着传感器技术、人工智能算法(特别是深度学习)、高精度地图以及高性能计算平台的突破性进展,自动驾驶技术开始实现跨越式的升级。自动驾驶技术在安全性提升、交通效率优化和出行方式变革等方面展现出巨大的潜力。许多全球知名的汽车制造商和科技公司纷纷投入大量资源研发自动驾驶系统,并将其应用于辅助驾驶和部分自动驾驶场景中。近十年来,L2 级自动驾驶功能已在许多量产车上普及,例如自适应巡航控制、车道保持等功能。同时,业界也在积极推进更高级别的自动驾驶,如 L3、L4 级别的有条件 and 高度自动驾驶车辆的研发和测试,甚至在部分地区开始试点无人驾驶出租车服务^{[1][2]}。

作为整个自动驾驶系统的核心组成部分之一,感知系统通过各种传感器(包括毫米波雷达、激光雷达、摄像头、超声波传感器、惯性导航系统、全球导航卫星系统等)收集环境信息,使自动驾驶车辆能够实时了解周围的静态与动态环境因素,为后续的路径规划、行为决策和车辆控制提供准确的基础信息支持。相较于其他传感器,毫米波雷达能够在恶劣环境条件下稳定工作,不受光照、雾、雨、雪等天气条件的影响,且距离与速度测量精度高、探测范围大,是自动驾驶感知系统中的关键组件。其中,调频连续波(Frequency-Modulated Continuous Wave, FMCW)雷达因其分辨率高、体积小、成本低、发射功率低、易实现等优势,已成为汽车毫米波雷达的主流选择^[3]。

然而,当前汽车上安装的各种毫米波雷达共享同一个频段(76~79 GHz)^[4],非合作地发射探测信号,且为实现高距离分辨力,雷达有着很大的射频传输带宽。如今,越来越多的车辆配备更多的雷达以在不同距离提供 360°全方位态势感知,这使得雷达之间产生相互干扰的几率大大增加。雷达之间的相互干扰会掩盖弱目标或产生虚假目标,严重影响汽车雷达检测结果的正确性,造成巨大安全隐患^[5]。因此,汽车雷达间的互相干扰已成为一个急需解决的问题。本文将聚焦于 FMCW 雷达间的抗干扰问题。

1.2 国内外研究现状

当干扰雷达的发射信号进入受干扰雷达的接收机,即形成干扰。根据干扰雷达与受干扰雷达的发射信号波形参数的相似程度,FMCW 雷达间的相互干扰可分为相干干扰和非相干干扰^[6]。当干扰雷达和受干扰雷达的波形参数相同或非常相近时,雷达间的干扰为相干干扰,相干干扰在频域、时频域、距离多普勒域上的样式与目标回波非常相近,在目标检测时会形成虚假目标;当干扰雷达和受干

扰雷达的波形参数差异较大时,雷达间的干扰为非相干干扰,非相干干扰在频域和距离多普勒域上会抬高噪声等级,在目标检测时将掩盖真实目标,导致漏检。

目前,研究人员已提出了多种方法来消除汽车雷达之间的相互干扰,从原理上主要可以归纳为信号处理和雷达参数调整这两类方法。其中,信号处理方法是针对雷达接收信号进行后处理来消除干扰。Muhammad Rameez 等人在时域上对接收信号构建自回归模型来估计和重建目标回波^[7]。Feng Jin 等人从接收信号的快速傅里叶(Fast Fourier Transform, FFT)变换结果中提取主样本和参考样本来进行自适应噪声消除,从而实现在频域上的干扰抑制^[8]。Seongwook Lee 等人使用小波变换对受干扰雷达的接收信号进行分解并重构出干扰信号,利用重构的干扰信号去消除原信号中干扰^[9]。Jianping Wang 在接收信号经短时傅里叶变换(Short Time Fourier Transform, STFT)得到的时频图上,使用恒虚警(Constant False Alarm Rate, CFAR)检测器估计干扰的掩膜,在时频域上消除干扰并分别使用置零、幅度修正和基于 Burg 的外推法来重建信号^[10]。如今,深度学习方法在信号处理领域也取得了成功。Jiwoo Mun 等人使用带有自注意力的循环神经网络(Recurrent Neural Network, RNN)处理接收信号的时间序列来消除干扰^[11]。Johanna Rock 等人使用卷积神经网络(Convolutional Neural Networks, CNN)对接收信号的一维距离像(Range Profile)和距离多普勒图(Range-Doppler Map, RDM)进行处理来抑制干扰^[12]。Yuan He 等人使用复数卷积神经网络、对比学习以及空洞卷积,加入基于先验信息的正则项,处理接收信号的时频图来抑制干扰^{[13][14][15][16]}。上述这些信号处理方法主要利用干扰与目标回波在时域、频域、时频域、距离多普勒域等处理域上的区别来消除干扰。其优点是不需要改变雷达前端的结构,只需要增加信号后处理模块即可,比较容易实现。然而这类方法由于需要对接收信号进行额外的处理,降低了目标探测的时效性,更重要的是,作为产生虚假目标的主要来源,相干干扰在这些处理域上有着与探测目标的回波信号相同的样式,故信号处理方法无法区分和消除相干干扰,无法解决虚假目标的问题。

调整雷达参数的方法不仅可以避开非相干干扰,还能对抗相干干扰,该类方法对雷达发射信号的参数进行调整,从而使得接收到的干扰在后续的常规雷达信号处理中被滤除或能量被分散,从而消除或降低干扰对目标检测的影响。Tang-Nian Luo 等人率先提出具备抗干扰特性的集成 77 GHz 汽车雷达信号收发器的设计及其硬件实现,通过随机调整雷达发射信号中心频率和调频斜率来避开相干干扰或使相干干扰变成噪声,从而避免虚假目标的产生^[17]。Yusuke Kitsukawa 等人提出使用脉冲重复间隔(Pulse Repetition Interval, PRI)随机变化的 FMCW 发射波形,将相干干扰的能量在频域分散来消除虚假目标^[18]。Faruk Uysal 等人提出了一种新的 FMCW 雷达系统来实现脉内相位编码,将相干干扰的能量分散到

整个距离多普勒域,从而降低产生虚假目标或弱目标被掩盖的概率^{[19][20]}。Bo Tang 等人提出慢时间维(即脉间)二进制编码,改变相干干扰在多普勒维的能量分布来避免虚警(False Alarm)和漏检(Missed Detection)^[21]。Sian Jin 等人提出了在一个 FMCW 雷达网络中非合作式地使用随机跳频、时分复用、二进制脉间相位编码及其组合,并分析了各组合的多址接入容量和目标误检测概率^[22]。上述这些方法都是非合作式的抗干扰,对频域、时域以及相位域的参数调整是随机或盲优化的,并没有利用具体情况下目标和干扰的信息,干扰抑制的效率仍有待提高。当前还有一些合作式的方法来避开雷达间的相互干扰。Joud Khoury 等人提出了一种雷达媒介访问控制(Medium Access Control, MAC)系统架构及其配套算法,在一个区域内所有汽车都上传其行驶信息和雷达参数信息至一个中心控制器,由中心控制器分配下一时刻各雷达的工作参数(包括中心频率和发射时间),以实现该区域内各汽车雷达避免相互干扰^[23]。Canan Aydogdu 等人提出了基于分布式网路协议的雷达与通信协作系统 RadChat,每辆汽车仅与周围车辆通信并分配雷达和通信的工作参数,同时降低雷达间以及雷达与通信间的干扰,并提高了时效性^[24]。Arindam Bose 等人提出在互联汽车信息共享的情况下进行相位编码并使用循环迭代方法进行优化,最小化交叉模糊函数,从而降低距离多普勒域上真实目标附近的干扰能量^[25]。上述这些合作式的方法利用了周围的环境信息来优化雷达参数选择,可以获得更好的抗干扰效果,但需要额外的通信开销,并增加了通信系统和雷达系统间相互干扰的可能。

Simon Haykin 教授在 2006 年首次提出了认知雷达(Cognitive Radar)这一概念^[26]。如图 1-1 所示,认知雷达系统具有先进自适应能力和智能决策功能,能够通过学习、理解和动态适应环境变化来优化其性能,其核心包括:(1)智能信息处理:能够实时地分析接收到的回波信号,并基于先验知识库和对当前环境的学习来更新和改进其自身算法,以提升目标检测、分类与跟踪能力;(2)闭环自适应:形成一个从发射机到接收机再到信息处理器的闭环反馈系统,使得雷达能够根据接收到的信息调整发射信号特性(如波形、频率、带宽、极化等),以及工作模式,以最大程度上降低干扰并提高信噪比(Signal to Noise Ratio, SNR);(3)环境感知与理解:雷达系统能主动感知周围环境的变化,包括气象条件、杂波分布、敌我识别等因素,并通过存储和分析历史数据来更好地预测未来场景,从而做出最佳决策;(4)资源最优分配:在能量、时间、频谱等资源有限的情况下,认知雷达可以智能地选择最优的工作参数和策略,确保雷达效能最大化;(5)自主学习与进化:随着运行时间的增长,认知雷达通过机器学习或深度学习方法不断积累经验,逐步优化自身的操作策略,实现长期的自我改进和适应不同作战环境的需求^[27]。




图 1-1 作为动态闭环反馈系统的认知雷达系统框图

随着认知雷达的提出，一些研究^{[28][29][30]}表明认知雷达技术可以用来减少雷达和其他射频系统间的干扰，包括在频谱感知^[31]、亚奈奎斯特采样^[32]、频谱共享^[33]、波形自适应^[34]、天线配置^{[35][36]}等方面的应用。在很多场景下，通过调整雷达参数抗干扰可以视为序贯决策问题，而基于认知雷达的抗干扰过程通常可以建模为马尔可夫决策过程（Markov Decision Process，MDP）。强化学习（Reinforcement Learning，RL）作为解决序贯决策问题的有力方法，近些年来已被引入到认知雷达抗干扰方法中。Ersin Selvi 等人使用策略迭代和 Q-Learning 来优化自适应带宽雷达在通信干扰下的目标追踪性能^{[37][38]}。Qinhao Wu 等人使用双学习技巧来优化无人机网络的雷达系统抗干扰策略，从天线配置、频率选择和位置布局这三个维度去对抗干扰^[39]。Ailiya 等人提出改变中心频率和脉冲宽度的雷达抗干扰策略并在奖励中加入了惩罚项来约束雷达切换参数的频率，使用 Q-Learning 得到抗干扰性能和探测效率都较优的策略^[40]。这些基于强化学习的认知雷达抗干扰方法都使用了传统强化学习的表格型求解法（如 Q-Learning、策略迭代），然而这类表格型求解法难以处理大的搜索空间和连续值，只能解决简单场景下干扰样式相对固定的抗干扰问题，无法应对复杂场景和多样多变的干扰。

最近十年发展迅速的深度学习技术被引入强化学习，并发展出深度强化学习技术，用来处理大规模、高维度、连续的搜索空间，从而解决复杂的决策问题，例如分别在围棋和星际争霸中战胜顶尖职业选手的 AlphaGo^{[41][42]}和 AlphaStar^[43]。近几年，研究人员也将深度强化学习技术应用于汽车雷达间的抗干扰。Pengfei Liu 等人提出了一种在双车道多辆车的动态场景下的汽车雷达抗干扰建模，车辆从自身雷达的接收信号中提取频谱环境信息，并使用加入了长短期记忆（Long Short-Term Memory，LSTM）网络的深度 Q 网络（Deep Q Network，DQN）来处理历史观测信息，解决部分可观测问题，实现了多智能体场景下分布式训练-分布式执行（Decentralized Training Decentralized Execution，DTDE）的频谱分配^[44]。

然而,该方法仅在频域上做参数调整,并未利用其他如时域、时频域、相位域等空间上的资源,故当面对的干扰数量较多时,避开干扰的效果明显恶化。刘飞鹏提出了调整中心频率和调频斜率的策略来避开 FMCW 雷达间的相互干扰,并使用 Double DQN (DDQN) 来优化策略,实现比单独调整中心频率取得了更好的性能^[45]。然而其干扰设置较为简单,避开干扰难度不大,且受限于 DQN 无法输出连续动作,在抗干扰性能上仍有提升空间。Mario Coutino 等人提出从脉冲时长、脉冲间隔和调制模式这三个维度进行波形设计的策略,并使用近端策略优化 (Proximal Policy Optimization, PPO) 算法来优化策略^[46],但是 PRI 的频繁变化严重降低了相干累积的效率。Graeme E. Smith 等人提出使用 DDPG 来优化脉间相位编码以实现频谱上的陷波 (Spectrum Notching)^{[47][48][49]},尽管可以实现较好的频谱定位准确度、陷波宽度和深度,但并未进行雷达抗干扰实验,没有实现端到端的抗干扰以及体现该方法的抗干扰性能。

基于当前的研究现状,本文拟研究基于深度强化学习的汽车雷达多域联合抗干扰技术,在不需要额外通信开销的情况下,利用多个操作域的资源进行非合作式的雷达参数优化,降低雷达间相互干扰的影响。该研究拟从三个方面展开:(1)面对相干干扰的时、频域联合抗干扰;(2)面对相干干扰的脉间相位编码抗干扰;(3)面对非相干干扰的多域联合抗干扰。

1.3 本论文的主要内容及结构安排

本论文针对基于深度强化学习的汽车 (FMCW) 雷达多域联合抗干扰技术展开研究和分析,共分为五章,每一章的研究内容概括如下:

第一章是本论文的绪论。首先阐述了汽车雷达抗干扰的研究背景和意义,体现了毫米波雷达所提供的环境感知能力在智能驾驶系统中的重要性、汽车雷达相互干扰的危害以及抗干扰的必要性。然后根据抗干扰原理,将当前的雷达抗干扰方法分为信号后处理和雷达参数调整这两类,分别阐述了这两类方法的研究现状、优点和不足之处,最后聚焦于基于深度强化学习的认知雷达抗干扰方法,针对现有研究的不足之处提出本文的研究目标。

第二章是面对相干干扰的时、频域联合抗干扰的内容。首先介绍 FMCW 雷达的信号模型、信号处理基础,给出了运动目标和干扰源对应信号的数学表达,为后续场景建模和信号仿真提供理论基础。紧接着介绍相干干扰并提出时域和频域联合调整参数的避开相干干扰的策略。随后介绍马尔可夫决策过程和时、频域联合抗干扰策略执行过程的建模,以及优化抗干扰策略的强化学习算法及其建模。最后给出仿真实验的设置、统计结果和实例展示以及分析总结。

第三章是面对相干干扰的脉间相位编码抗干扰的内容。首先介绍脉间相位编码如何降低相干干扰对目标检测的影响。随后提出连续随机值相位编码及其优化

的抗干扰策略。接着介绍该策略的 MDP 建模、优化策略所用的强化学习算法及其建模。最后给出仿真实验的设置、统计结果和实例展示以及分析总结。

第四章是面对非相干干扰的多域联合抗干扰策略的内容。首先介绍非相干干扰产生的场景并简单说明前两章的抗干扰方法并不适用于非相干干扰的原因。随后在时、频域联合策略的基础上进行改进，加入调频斜率这一维度的调整，形成多域联合抗干扰策略。然后介绍该策略的 MDP 建模、优化策略所用的强化学习算法及其建模。最后给出仿真实验的设置、统计结果以及分析总结。

第五章是本论文的总结。对本论文的研究内容进行概括，并讨论未来可能的研究方向。

第二章 面对相干干扰的时、频域联合抗干扰策略

本章将先介绍 FMCW 雷达基础，并给出运动场景下的目标和干扰信号解析形式的推导和仿真方法。然后，提出用于避开相干干扰的时、频域联合抗策略，接着介绍马尔科夫过程和本章抗干扰策略的建模，以及优化策略的强化学习算法设计。最后，将展示验证本章所提出的抗干扰策略的仿真实验的设置和结果。

2.1 FMCW 雷达基础

2.1.1 FMCW 雷达信号模型

FMCW 雷达是指发射频率受特定信号调制的连续波雷达。其连续发射调频信号并接收目标反射的回波，对目标回波进行解调，从中解算出目标的距离、速度等信息。FMCW 雷达系统如图 2-1 所示，雷达由波形生成器生成特定波形，通过数模转换器（Digital-to-Analog Converter, DAC）与压控振荡器（Voltage-Controlled Oscillator, VCO）生成 FMCW 信号波形（参考信号），该信号经过功率放大器（Power Amplifier, PA）放大后，由发射天线发送出去。当遇到目标时，发射的电磁波由物体反射，形成目标回波，由接收天线接受。接收信号通过低噪声放大器（Low-Noise Amplifier, LNA）后，与参考信号混频进行解调（Dechirp），然后通过低通滤波器（Low-Pass Filter, LPF）保留有效探测范围内的基带信号，得到拍频信号（Beat Signal）。最后 beat signal 经过模数转换器（Analog-to-Digital Converter, ADC）采样处理后，进行数字信号处理（例如 FFT、CFAR 检测等），解算出目标的距离、速度等信息。




图 2-1 FMCW 雷达系统框图

FMCW 信号的频率随着时间线性或非线性地变化，通常按照预先设定的规律，如三角波、锯齿波或者正弦波形式进行调频。本文使用的调制波形为锯齿波，如图 2-2 所示，其在一次扫频周期内频率从起始频率线性变化至终止频率，这样

的一次扫频也称为一个 chirp。通常相邻两个 chirp 间会有一段空闲时间，而一个 chirp 加上这样一段空闲的时间总和称为一个 chirp 周期 T_c （也称 PRI）。




图 2-2 锯齿波频率示意图

一般地，FMCW 雷达在一个 chirp 内的参考信号（此处以及后面的推导均默认信号的幅度为单位幅度）可以表示为

$$x_T(t) = e^{j2\pi \left[f_c t + \frac{1}{2} K \left(t - \frac{T_{sw}}{2} \right)^2 \right]}, \quad 0 \leq t \leq T_{sw} \quad (2-1)$$

其中 f_c 、 K 和 T_{sw} 顺次表示中心频率、调频斜率和单个 chirp 的扫频时长， j 为虚数单位。则信号的带宽为

$$B = K T_{sw} \quad (2-2)$$

当最大探测距离 d_{max} 确定后，最大延迟时间 τ_{max} 以下式计算

$$\tau_{max} = \frac{2d_{max}}{c} \quad (2-3)$$

其中 c 表示光速。在 dechirp 处理之后的最大拍频（Beat Frequency） $f_{b_{max}}$ 可确定为

$$f_{b_{max}} = K \tau_{max} \quad (2-4)$$

本文的信号仿真中在 dechirp 后均使用理想低通滤波器，其截止频率就等于 $f_{b_{max}}$ 。因此，接收信号中与参考信号的频率差大于 $f_{b_{max}}$ 的成分将被低通滤波器滤除，不会出现在 beat signal 中。不妨设该 chirp 在某目标回波（由点目标直接反射）中对应的信号为

$$x_R(t) = e^{j2\pi \left[f_c(t-\tau) + \frac{1}{2} K \left(t - \tau - \frac{T_{sw}}{2} \right)^2 \right]}, \quad \tau \leq t \leq \tau + T_{sw} \quad (2-5)$$

其中 τ 为目标回波相对参考信号的延迟时间。若该目标相对雷达的距离为 d ，则根

据运动学原理不难得出

$$\tau = \frac{2d}{c} \quad (2-6)$$

目标回波和参考信号做 dechirp 后的信号为

$$x_s(t) = x_T(t) \cdot \bar{x}_R(t) = e^{j2\pi[f_c\tau + K\tau(t - \frac{\tau}{2} - T_{sw})]}, \quad \tau \leq t \leq T_{sw} \quad (2-7)$$

其中 $\bar{x}_R(t)$ 为 $x_R(t)$ 的复共轭。该信号频率，同时也是参考信号和目标回波的频率差为

$$\Delta f = \frac{dx_s(t)}{dt} = K\tau \quad (2-8)$$

则可建立目标距离和该频率的关系

$$d = \frac{c\Delta f}{2K} \quad (2-9)$$

当 $\tau < \tau_{\max}$ ，即 $K\tau < f_{b\max}$ 时，该频率成分经过低通滤波器后将保留至 beat signal，则原理上可依据式 (9) 从 beat signal 中解算目标的距离。对于运动目标，其相对于雷达的运动会引起多普勒频移，理论上可以根据多普勒频率 f_D 推算出目标的相对运动速率

$$v = \frac{f_D c}{2f_c} \quad (2-10)$$

然而实际中由于一个 chirp 的持续时间很短，多普勒频率在单个 chirp 的 beat signal 中难以体现，需要多个 chirp 累积。如图 2-3 所示，通常 FMCW 雷达会连续发射多个 chirp，构成一帧 (Frame)，相邻两帧之间存在一个间隔时间，称为帧间间隔 (Inter Frame Time)，从当前一帧的起始时刻到下一帧的起始时刻的这段时间称为帧周期 (Frame Period)。雷达测量目标距离和速度通常以一个 frame




图 2-3 典型的帧结构

作为操作单位。不妨设一个帧周期内包含 L 个 chirp，参考信号 $x_T(t; L)$ 和接收信号 $x_R(t; L)$ 为

$$\mathbf{x}_T(t; L) = \sum_{l=1}^L \mathbf{x}_T(t; l) \quad (2-11)$$

$$\mathbf{x}_R(t; L) = \sum_{l=1}^L \mathbf{x}_R(t; l) \quad (2-12)$$

经过 dechirp 和低通滤波后的 beat signal 为

$$\mathbf{x}_b(t; L) = \sum_{l=1}^L \mathbf{x}_T(t; l) \cdot \bar{\mathbf{x}}_R(t; l) * h_{lp}(t) \quad (2-13)$$

其中 $*$ 表示卷积操作, $h_{lp}(t)$ 表示低通滤波器。在此我们称 t 这一维为快时间维, L 这一维为慢时间维。从快时间维的 FFT 结果可以解算出目标的距离信息, 而目标在快时间维对应位置的峰值处的相位在慢时间维的角频率 ω 则对应了目标的相对运动速率 v :

$$\omega = \frac{4\pi v T_c f_c}{c} \Rightarrow v = \frac{\omega c}{4\pi v T_c f_c} \quad (2-14)$$

在对 beat signal 做距离多普勒处理时, 同时在快时间维和慢时间维各做一次 FFT, 得到距离多普勒图, 距离多普勒图上的峰值位置即对应可能的目标位置, 再对距离多普勒图进行 CFAR 检测^[50]即可得到目标的距离和速率。

2.1.2 运动场景下的目标回波和干扰信号推导

实际上在雷达的接收信号中, 除了有目标直接反射回来的目标回波, 还有多径反射的回波、杂波以及其他汽车雷达的发射信号 (即干扰)。汽车雷达间的相互干扰成因主要有两种: 一种是直接入射干扰, 即干扰雷达的发射信号直接射入受干扰雷达的接收机, 形成干扰; 另一种是反射干扰, 即干扰雷达的发射信号经过其他物体反射射入受干扰接收机, 形成干扰^[51]。本文在场景设定中, 专注于点目标的回波和直接射入干扰, 不考虑反射干扰、多径效应以及杂波。接下来我们推导之后将用于运动场景下信号仿真的目标回波和干扰信号的解析形式。

2.1.2.1 运动目标的回波信号推导

以一个 frame 为单位, 设单个 frame 有 L 个 chirp, 包括单次扫频时长 T_{sw} 和 chirp 间间隔 T_{icd} , 则 $T_c = T_{sw} + T_{icd}$, 一个 frame 的时间 $t \in [0, LT_c]$ 。设目标与雷达的初始距离为 R_0 , 目标与雷达的相对速率为 $v_{re} = v_{target} - v_{radar}$ 。这里暂且假定在这段时间内, 目标匀速运动且目标相对雷达的距离和速率均在雷达的有效测量范围内。则雷达与目标的距离为

$$R(t) = R_0 + v_{re} t \quad (2-15)$$

接下来计算目标回波到达雷达接收机相对对应发射信号的延迟时间 τ 。以雷达为

参考系，则目标的速率即为 v_{re} 。设雷达发射电磁波时与目标的距离为 R_1 ，电磁波从雷达发射到抵达目标用时 Δt_1 ，电磁波到达目标时，目标与雷达距离为 R_2 ，电磁波由目标反射后返回雷达用时 Δt_2 ，遵守光速不变原理^[52]，则有

$$\begin{cases} \tau = \Delta t_1 + \Delta t_2 \\ c\Delta t_1 = R_2 \\ c\Delta t_2 = R_2 \\ R_2 = R_1 + v_{\text{re}}\Delta t_1 \end{cases} \Rightarrow \begin{cases} \tau = \frac{2}{c}(R_1 + v_{\text{re}}\Delta t_1) \\ \Delta t_1 = \Delta t_2 = \frac{R_1}{c - v_{\text{re}}} \end{cases} \quad (2-16)$$

设目标回波在 t 时刻到达雷达，则有

$$\begin{cases} \tau(t) = \tau = \frac{2}{c}(R_1 + v_{\text{re}}\Delta t_1) \\ R_1 = R(t - \tau(t)) = R_0 + v_{\text{re}}[t - \tau(t)] \end{cases} \quad (2-17)$$

$$\Rightarrow \begin{cases} R_1 = \frac{(R_0 + v_{\text{re}}t)(c - v_{\text{re}})}{c + v_{\text{re}}} \\ \tau(t) = \frac{2(R_0 + v_{\text{re}}t)}{c + v_{\text{re}}} \end{cases} \quad (2-18)$$

即回波相对参考信号的延迟为

$$\tau(t) = \frac{2(R_0 + v_{\text{re}}t)}{c + v_{\text{re}}} \quad (2-19)$$

对于第 k 个 chirp, $1 \leq k \leq N$, 时间 $t \in [(k-1)T_c, kT_c]$, 参考信号频率为

$$f_{\text{ref}}(t) = \begin{cases} 0, \text{ 其他} \\ f_c + K \left[t - t_0 - \frac{1}{2}T_{\text{sw}} \right], t_0 \leq t \leq t_0 + T_{\text{sw}} \end{cases} \quad (2-20)$$

其中 chirp 起始时间 $t_0 = (k-1)T_c$, K 为调频斜率。实际中, 在 chirp 间隔内, 雷达参考信号的频率将下降至 $(f_c - \frac{1}{2}KT_{\text{sw}})$, 由于雷达系统对该段时间的接收信号不会进行 ADC 采样, 故在此简化。现代 FMCW 雷达可以精准控制每一个 chirp 的起始相位, 在不考虑相位编码的情况下, 在此认为每个 chirp 的起始相位保持一致^{[53][54]}, 故每一段扫频的起始相位用一个固定值 φ_0 表示, 即对于 $t_0 \leq t \leq t_0 + T_{\text{sw}}$, 参考信号相位为

$$\varphi_{\text{ref}}(t) = 2\pi \left[\left(f_c - \frac{1}{2}KT_{\text{sw}} \right) (t - t_0) + \frac{1}{2}K(t - t_0)^2 \right] + \varphi_0 \quad (2-21)$$

回波信号相位为

$$\begin{aligned} \varphi_{\text{echo}}(t) &= \varphi_{\text{ref}}(t - \tau(t)) \\ &= 2\pi \left[\left(f_c - \frac{1}{2}KT_{\text{sw}} \right) (t - \tau(t) - t_0) + \frac{1}{2}K(t - \tau(t) - t_0)^2 \right] \\ &\quad + \varphi_0 + \varphi_r \end{aligned} \quad (2-22)$$

其中 φ_r 是由反射引起的相位改变。对相位求导得到回波信号频率

$$\begin{cases} f_{\text{echo}}(t) = [1 - \tau'(t)] \left\{ \left(f_c - \frac{1}{2} K T_{\text{sw}} \right) + K[t - \tau(t) - t_0] \right\} \\ 1 - \tau'(t) = 1 - \frac{d\tau(t)}{dt} = \frac{c - v_{\text{re}}}{c + v_{\text{re}}} \end{cases} \quad (2-23)$$

至此已经得到运动场景下，一个 frame 内每个 chirp 的参考信号的频率、目标回波相位和频率的解析形式，信号仿真时可以直接根据解析式生成信号，在 dechirp 后的低通滤波时，直接根据 $f_{\text{ref}}(t)$ 和 $f_{\text{echo}}(t)$ 做截断，以此实现理想低通滤波。如果考虑直接生成 beat signal，则相位为

$$\begin{aligned} \varphi_{\text{beat}}(t) &= \varphi_{\text{ref}}(t) - \varphi_{\text{echo}}(t) \\ &= 2\pi \left[\left(f_c - \frac{1}{2} K T_{\text{sw}} \right) \tau(t) + \frac{1}{2} K \tau(t) (2t - \tau(t) - 2t_0) \right] \end{aligned} \quad (2-24)$$

频率分别为

$$\begin{aligned} f_{\text{beat}}(t) &= \frac{1}{2\pi} \frac{d\varphi_{\text{beat}}(t)}{dt} \\ &= \left(f_c - \frac{1}{2} K T_{\text{sw}} \right) \tau'(t) + K \tau'(t) [t - \tau(t) - t_0] + K \tau(t) \\ &= \frac{2v_{\text{re}}}{c + v_{\text{re}}} \left\{ \left(f_c - \frac{1}{2} K T_{\text{sw}} \right) + K[t - \tau(t) - t_0] \right\} + K \tau(t) \end{aligned} \quad (2-25)$$

其中

$$\begin{cases} \tau(t) = \frac{2(R_0 + v_{\text{re}}t)}{c + v_{\text{re}}} \\ \tau'(t) = \frac{d\tau(t)}{dt} = \frac{2v_{\text{re}}}{c + v_{\text{re}}} \end{cases} \quad (2-26)$$

仿真时 beat frequency 超过低通滤波器截止频率的部分直接置零即可。

2.1.2.2 运动干扰源的干扰信号推导

由于干扰在时域的扫频参数，如 PRI、chirp 间间隔等与受干扰雷达的参考信号并不一定一致（相干干扰一致，非相干干扰则差异较大），在此我们并不以干扰信号的 frame 长度作为样本长度。若受干扰雷达的一个 frame 的长度可以容纳的干扰 chirp 数为 $(M - 1)$ ，则干扰信号仿真样本补长为 M 个 chirp 的长度，在仿真中，生成完整的 M 个 chirp 的信号后之后再根据延迟时间进行截断。

设干扰的中心频率为 f_{cintf} ，调频斜率为 K_{intf} ，扫频时长为 T_{swintf} ，chirp 重复周期为 T_{cintf} 。设干扰信号被受干扰雷达接收到的起始时刻相对与受干扰雷达参考信号最近的一个 chirp 的起始时刻的延迟时间为 $t_{\text{dintf}}(0)$ ，这个初始延迟时间实际将由干扰源相对距离和两部雷达的发射时间差共同决定。设干扰源相对速度为

$v_{\text{reintf}} = v_{\text{intf}} - v_{\text{radar}}$ ，以受干扰雷达作为参考系，不妨设干扰发射的起始时刻，发射时间差为 τ_{transmit} ，干扰源相对距离为 $R(0)$ ，则有

$$t_{\text{dintf}}(0) \approx \tau_{\text{transmit}} + \frac{R(0)}{c} \quad (2-27)$$

当然我们对 $t = 0$ 时刻之前（即 $t < 0$ ）发生的运动过程并不感兴趣，所以在此忽略雷达和干扰的速度，得到 $t_{\text{dintf}}(0)$ ，在仿真中这一项的初始化将从一定范围内的均匀分布中采样得到。对于 $t > 0$ ，有

$$\begin{cases} t_{\text{dintf}}(t) = \tau_{\text{transmit}} + \frac{R(t)}{c} \\ R(t) = R(0) + v_{\text{reintf}}t \end{cases} \quad (2-28)$$

可得

$$t_{\text{dintf}}(t) = t_{\text{dintf}}(0) + \frac{v_{\text{reintf}}t}{c} = t_{\text{dintf}}(0) + t_{\text{dopplerintf}}(t) \quad (2-29)$$

$t_{\text{dopplerintf}}(t)$ 表示由干扰对受干扰雷达的相对运动导致时移。在仿真时，先补长干扰仿真的时间序列（至 M 个 chirp 的长度），然后计算 $t_{\text{dopplerintf}}(t)$ ，再逐 chirp 地生成干扰在时频域和时域的序列，最后按照 $t_{\text{dintf}}(0)$ 平移。

在此给出时移前的干扰样本的解析式，之后整体时移 $t_{\text{dintf}}(0)$ 即可。对于干扰样本的第 k 个 chirp， $1 \leq k \leq M$ ，时间 $t \in [(k-1)T_{\text{cintf}}, kT_{\text{cintf}}]$ ，发射的干扰信号频率为

$$f_{\text{intftransmit}}(t) = \begin{cases} 0, \text{其他} \\ f_{\text{cintf}} + K_{\text{intf}} \left[t - (k-1)T_{\text{cintf}} - \frac{1}{2}T_{\text{swintf}} \right], \\ (k-1)T_{\text{cintf}} \leq t \leq (k-1)T_{\text{cintf}} + T_{\text{swintf}} \end{cases} \quad (2-30)$$

每一段扫频的起始相位用一个固定值 φ_1 表示，则发射的干扰信号相位为

$$\varphi_{\text{intftransmit}}(t) = 2\pi \left[\left(f_{\text{cintf}} - \frac{1}{2}K_{\text{intf}}T_{\text{swintf}} \right) (t - (k-1)T_{\text{cintf}}) + \frac{1}{2}K_{\text{intf}}(t - (k-1)T_{\text{cintf}})^2 \right] + \varphi_1 \quad (2-31)$$

回波信号相位为

$$\begin{aligned} \varphi_{\text{intfrecieve}}(t) &= \varphi_{\text{intftransmit}}(t - t_{\text{dopplerintf}}(t)) \\ &= 2\pi \left[\left(f_{\text{cintf}} - \frac{1}{2}K_{\text{intf}}T_{\text{swintf}} \right) (t - t_{\text{dopplerintf}}(t) - (k-1)T_{\text{cintf}}) + \frac{1}{2}K_{\text{intf}}(t - t_{\text{dopplerintf}}(t) - (k-1)T_{\text{cintf}})^2 \right] \\ &\quad + \varphi_1 \end{aligned} \quad (2-32)$$

对相位求导得到回波信号频率

$$f_{\text{intf_recieve}}(t) = [1 - t'_{\text{doppler_intf}}(t)] \left\{ \begin{array}{l} \left(f_{\text{c_intf}} - \frac{1}{2} K_{\text{intf}} T_{\text{sw_intf}} \right) \\ - K_{\text{intf}} [t_{\text{doppler_intf}}(t) + (k-1)T_{c_intf}] \end{array} \right\} \quad (2-33)$$

其中

$$1 - t'_{\text{doppler_intf}}(t) = 1 - \frac{v_{\text{re_intf}}}{c} \quad (2-34)$$

至此干扰信号仿真所需的频率、相位解析式也已得到。

2.2 时域和频域联合干扰避免策略

在本章中，我们专注于相干干扰，即干扰源和受干扰雷达有着相同的扫频斜率和 PRI。如图 2-4(a)所示，在时频域上，相干干扰的频率-时间曲线与受干扰雷达的参考信号及目标回波完全平行，当干扰的中心频率与受干扰雷达参考信号相近，且相对延迟时间很小，则干扰将全部进入受干扰雷达的通带，形成窄带干扰。由于干扰信号从发射到被受干扰雷达接收仅经过单程传播，且全部进入通带，其能量相较于经过往返传播的目标回波通常大很多，从而极易在距离多普勒图及 CFAR 检测中形成强度很大的虚假目标，如图 2-5 所示。

目前最常用的避开干扰的方法就是调整受干扰雷达的中心频率（也称**频谱分配或频分复用**）^{[17][22][23][24][33][37][38][40][44][45][51]}。如图 2-4(c)所示，该方法的原理是增大干扰信号和受干扰雷达参考信号间的频率差，当该频率差大于低通滤波器截止频率时，干扰在时频域上将落在受干扰雷达通带之外，从而被滤除。在使用该方法时，通常将一段共享的频带划分为若干个互不重叠的子带，在多雷达场景下，每个时间单元内，每部雷达都选取一个子带作为自己的工作频带，从而达到消除或减少互相干扰的情况。该方法实现起来较为简单直接，然而其缺点也显而易见。一般来说，可用的频谱资源是有限的，当同一区域内的雷达设备数量较多时，要保证各雷达互不干扰需要划分更多的子带，如此每个子带的带宽就会减小，又会削弱雷达的目标检测性能（例如距离分辨力）。

另一种方法是调整**雷达的发射时间**（也称**时分复用**）^{[23][24]}。根据式(2-4)所展示的 τ_{max} 和 $f_{b\text{max}}$ 的对应关系，可知如果干扰接收信号和参考信号间的相对延迟时间不在 $[0, \tau_{\text{max}}]$ 这个范围内，该干扰与参考信号的频率差亦将大于低通滤波器截止频率，dechirp 后将被低通滤波器滤除。如图 2-4(4)所示，**受干扰雷达的发射信号延迟 t_d** ，这改变了**发射信号和干扰之间的频率差**，从而干扰在 **dechirp** 后被低通滤波器滤除。为了方便表述，我们在此设置一个参考时刻。雷达的发射延迟

时间 t_d 和干扰的到达延迟时间 τ_{intf} 都是相对这个参考时刻给出的。

将上述的中心频率和发射时间调整结合在一起,可以有效缓解频谱资源受限的问题,然而现有的方法^{[23][24]}皆是用合作式的方法来实现避免干扰的,这样需要额外的通信和计算资源来实现频域和时域的资源分配,不仅降低了抗干扰的实时性,还可能引入通信系统和雷达系统间的干扰。

在此,我们提出一种非合作式的时、频域联合避开干扰的策略 (Strategy)。如图 2-6 所示,在每一次发射前,受干扰雷达将基于当前的状态,包括相对参考时刻的发射时间延迟、中心频率以及从接收信号中感知的干扰情况,来决定时域和频域参数的发射。





图 2-4 干扰避免策略示意图, (a)干扰信号出现在受干扰雷达通带内 (b)通过调整发射时间将干扰移出通带 (c)通过调整中心频率将干扰移出通带






图 2-5 有无相干干扰情况下，距离多普勒图以及 CFAR 检测的结果对比，(a)无干扰下的距离多普勒图 (b)无干扰下的 CFAR 检测结果 (c)有干扰下的距离多普勒图 (d)有干扰下的 CFAR 检测结果




图 2-6 时、频域联合干扰避免策略执行流程

2.3 基于深度强化学习的联合抗干扰策略的实现

2.3.1 马尔可夫决策过程

作为解决序贯决策问题的有力方法，马尔可夫决策过程（MDP）为以交互式学习来实现目标的问题提供了一个简洁直观的理论框架。在这个框架中，学习者（Learner）和决策者（Decision Maker）被称为智能体（Agent），智能体以外所有与之交互的事物都被称为环境（Environment）。如图 2-7 所示，二者持续地进行交互，智能体选择动作，环境对这些动作做出响应并向智能体呈现新的状态。同时，环境也会产生一个具体数值，称为收益或奖励，智能体在动作选择时地目标就是最大化这个收益^[55]。




图 2-7 智能体-环境交互示意图

一般地，一个马尔可夫决策过程可以用五元组 $\langle \mathcal{S}, \mathcal{A}, p, r, \gamma \rangle$ 来描述。 $\mathcal{S}$ 表示状态空间（State Space）， $\mathcal{A}$ 表示动作空间（Action Space）， p 表示状态转移概率函数（Transition Probability Function）， r 表示奖励函数（Reward Function）， γ 表示未来回报的折扣率（Discount Rate）。

对于一系列的离散时刻 $t = 0, 1, 2, 3, \dots$ ，在每个时间步 t 上，智能体都通过观测更新环境状态（State）的某些表征， $s_t \in \mathcal{S}$ ，并基于更新的状态选择一个动作（Action）， $a_t \in \mathcal{A}(s)$ （ $\mathcal{A}(s)$ 表示在状态 s 下可用的动作集合，有时所有状态的动作集合都是一样的，可简记为 $\mathcal{A}$ ）。在下一个时间步，作为这个动作的结果，智能体收到一个数值奖励， $r_{t+1} \in \mathbb{R}$ ，同时观测得到新的状态 s_{t+1} 。从而，智能体和环境持续地交互，得到一个序列或一条轨迹（Trajectory）如下：

$$s_0, a_0, r_1, s_1, a_1, r_2, s_2, a_2, r_3, s_3, \dots \quad (2-35)$$

其中任意一组 $(s_t, a_t, r_{t+1}, s_{t+1})$ 都被称为一次转移（Transition）。奖励 r_{t+1} 和状态 s_{t+1} 都可以看作随机变量，他们服从的概率分布只依赖于前继状态 s_t 和动作 a_t ，即对于任意 $s, s' \in \mathcal{S}, a \in \mathcal{A}(s), r \in \mathbb{R}$ ，有

$$\begin{aligned} p(s', r | s, a) &= \Pr\{s_{t+1} = s', r_{t+1} = r | s_t = s, a_t = a\} \\ &= \Pr\{s_{t+1} = s', r_{t+1} = r | s_t = s, a_t = a, s_{t-1}, a_{t-1}, \dots, s_0, a_0\} \end{aligned} \quad (2-36)$$

上式也是状态转移概率函数 p 的定义，它反映了 MDP 的马尔可夫性，同时 p 完全刻画了环境的动态特性。对于 s, a 和 r 数量有限的情况（即有限 MDP），有

$$\sum_{s' \in \mathcal{S}} \sum_r p(s', r | s, a) = 1, s \in \mathcal{S}, a \in \mathcal{A} \quad (2-37)$$

并且我们可以改写 p 为三参数函数：

$$p(s' | s, a) = \Pr\{s_{t+1} = s' | s_t = s, a_t = a\} = \sum_r p(s', r | s, a) \quad (2-38)$$

为方便后续表述，我们在此直接给出奖励函数 r 的“状态-动作-后继状态”的三参

数表示:

$$r(s, a, s') = \mathbb{E}[r_{t+1} | s_t = s, a_t = a, s_{t+1} = s'] = \sum_r r \frac{p(s', r | s, a)}{p(s' | s, a)} \quad (2-39)$$

上述表示在 s 、 a 和 r 的取值不可数时依然成立，对于不可数的维度将求和换成定积分即可。

对于式(2-35)所描述的轨迹，我们给出一个终止时刻 t_∞ ，在这条轨迹上从时刻 t 后所接收的累积回报可简单地表示为奖励的总和

$$G_t = r_{t+1} + r_{t+2} + \cdots + r_{t_\infty} \quad (2-40)$$

对于有自然终止状态的任务，如一盘对弈或一次走迷宫，这个终止时刻显而易见（即决出胜负的时刻或到达迷宫出口的时刻），在这个过程中得到的轨迹称为幕（Episode），这样的任务称为分幕式任务，则其 t_∞ 是有限的。然而，有些任务并不能自然地分为单独的幕，而是持续不断地进行，称为持续式任务。对于持续式任务，其 $t_\infty \rightarrow \infty$ ，则可能面临 G_t 趋于无穷的问题（尽管有时可以人为地规定持续式任务的 t_∞ ，使其有限）。在此，使用 γ 对未来的回报进行折扣，得到

$$G_t = \sum_{k=0}^{t_\infty-t-1} \gamma^k r_{t+k+1} = r_{t+1} + \gamma G_{t+1} \quad (2-41)$$

折扣率 $\gamma \in [0,1]$ 。不妨设 $|r_t|$ 的上界为 r_{sup} ，则

$$|G_t| \leq \sum_{k=0}^{\infty} \gamma^k r_{\text{sup}} = \frac{r_{\text{sup}}}{1-\gamma} \quad (2-42)$$

则对于 $t_\infty \rightarrow \infty$ 的情况，只需取 $\gamma < 1$ 即可保证折扣后的累积回报有界。智能体在与环境交互的过程中，其选取一系列动作的目标就是最大化式(2-41)所给出的累积回报，而 γ 的大小表示未来收益对当前动作的重要性， γ 越大则越重视未来的收益，当 γ 取 0，则智能体选取动作时只考虑最大化这个动作的即时奖励，而完全不考虑未来的收益。

通常，将智能体从状态到选择动作（或每个动作的选择概率）的映射称为策略（Policy），用 π 来表示。对于确定性策略，策略直接给出当前状态下的选择的动作：

$$a_t = \pi(s_t) \quad (2-43)$$

对于随机策略，则给出该状态下动作的概率分布：

$$p(a_t = a | s_t = s) = \pi(a | s) \quad (2-44)$$

从该分布中采样具体的动作。我们把智能体在执行策略 π 时在状态 s 下采取动作 a

的价值记为 $q_\pi(s, a)$, 称为状态动作-价值函数, 它表示依据策略 π , 从状态 s 开始, 执行动作 a 后的所有可能的轨迹的期望回报:

$$\begin{aligned} q_\pi(s, a) &= \mathbb{E}_\pi[G_t | s_t = s, a_t = a] \\ &= \sum_{s' \in \mathcal{S}} p(s' | s, a) \{r(s, a, s') + \gamma \mathbb{E}_\pi[G_{t+1} | s_{t+1} = s']\} \end{aligned} \quad (2-45)$$

为了最大化累积回报, 我们需要找到最优策略, 尽管最优策略可能不止一个, 但它们共享同一个最优状态-动作价值函数 $q_*(s, a)$:

$$q_*(s, a) = \max_{\pi} q_\pi(s, a) \quad (2-46)$$

从而将最大化累积回报转化为求解最优状态-动作价值函数 (最优策略)。

2.3.2 干扰避免的马尔可夫决策过程建模

我们将时、频域联合干扰避免策略的执行过程建模为马尔可夫决策过程, 接下来给出状态、动作、奖励等具体设置。状态 $\mathbf{s} = [\hat{f}_c, t_d, \text{SINR}] \in \mathcal{S}$ 由雷达的频域状态 $\hat{f}_c$ (即中心频率)、时域状态 t_d (即发射时间延迟) 和接收信号的信干噪比 (Signal to Interference and Noise Ratio, SINR) 构成, 我们把其中的雷达参数的部分, 即 $[\hat{f}_c, t_d]$ 称为参数状态, 记为 $\mathbf{s}_{\text{param}}$, 所有参数状态的集合记为 $\mathcal{S}_{\text{param}}$ 。动作定义为 $\mathbf{a}: \mathbf{s}_{\text{param}} \xrightarrow{a} \mathbf{s}'_{\text{param}}, \mathbf{s}_{\text{param}}, \mathbf{s}'_{\text{param}} \in \mathcal{S}_{\text{param}}$ 。在本章中, 雷达的频域状态 $\hat{f}_c$ 和时域状态 t_d 均离散化, 而 SINR 的取值则是连续的。若给定 n 个可用的频域状态和 m 个可用的时域状态, 则参数状态空间 $\mathcal{S}_{\text{param}}$ 的大小为 mn , 动作空间 $\mathcal{A}$ 的大小为 $(mn)^2$ 。但是由于 SINR 的取值是连续的, 状态空间 $\mathcal{S}$ 是不可数的。

在每一个时间步, SINR 和动作代价 (Action Cost, AC) 被用来评估雷达的动作。这两个指标定义如下:

$$\text{SINR} = 10 \log_{10} \frac{|\mathbf{x}_t|^2}{|\mathbf{x}_i + \mathbf{n}|^2} \quad (2-47)$$

$$\text{AC} = \begin{cases} 0, & \hat{f}_c \text{ 和 } t_d \text{ 都没变} \\ 1, & \hat{f}_c \text{ 和 } t_d \text{ 只有其中一个没变} \\ 2, & \hat{f}_c \text{ 和 } t_d \text{ 都改变} \end{cases} \quad (2-48)$$

其中 $\mathbf{x}_t$ 、 $\mathbf{x}_i$ 和 $\mathbf{n}$ 分别表示接收信号在经过 dechirp 和低通滤波之后剩余的目标、干扰和噪声的 beat signal。此处, AC 代表着雷达是否在时域或频域改变了状态。实际中, 动作代价可以根据实现该策略的复杂度或硬件负担来设置。

即时奖励 r 由两部分构成, SINR 奖励 r_S 和动作代价奖励 r_{AC} :

$$r = r_S + r_{\text{AC}} \quad (2-49)$$

$$r_s = \begin{cases} \frac{\alpha_1(\text{SINR} - \text{SINR}_1)}{(\text{SINR} - \text{SINR}_1) + (\text{SINR}_2 - \text{SINR}_1)}, & \text{SINR} \geq \text{SINR}_1 \\ \alpha_2(\text{SINR} - \text{SINR}_1), & \text{SINR} < \text{SINR}_1 \end{cases} \quad (2-50)$$

$$r_{AC} = -\alpha_3 \cdot AC \quad (2-51)$$

其中 SINR_1 是基于正奖励或负奖励的**判断阈值**，实际中可根据目标探测的要求设定。 SINR_2 表示 SINR 取值的一个上界，用于奖励数**值归一化**，它通常与噪声等级（如 SNR）有关。 α_1 、 α_2 和 α_3 是奖励的**权重**，决定了 SINR 和动作代价的优先级。

本文假设接收信号的 SINR 可以被准确估计出来，估计方法不在此次讨论范畴。尽管如此，为了不增加额外的硬件要求，雷达每个时刻只能感知当前通带内的干扰情况（SINR），从而形成了**部分可观测的问题**。此时，单个时刻的状态可能不足以支持雷达做出最有效的决策。为了提供更多的干扰信息，我们将状态 $\mathbf{s}_t$ 扩展为 $\mathbf{S}_t = [\mathbf{s}_{t-k+1}, \mathbf{s}_{t-k+2}, \dots, \mathbf{s}_t]$ ，这包含了该 episode 内最近 k 步的观测。

至此，时、频域联合干扰避免策略的 MDP 中的状态、动作和奖励都已明确，至于状态转移概率和回报折扣率的设定，将在接下来的内容中涉及。

2.3.3 所提方法基于深度强化学习的实现

2.3.3.1 强化学习算法的选择

一般来说，求解式(2-46)所示的**最优 q 函数**有三类方法：**动态规划**、**蒙特卡洛法**和**时序差分法**^[55]。作为基于模型（Model-Based）的方法，动态规划需要完整的状态转移概率分布，来迭代式地**求解方程组**。而蒙特卡洛法和时序差分法都是无模型（Model-Free）的方法，它们不需要明确的状态转移概率，而是直接从采样中学习环境模型。蒙特卡洛法需要完整的采样轨迹来更新价值和策略，这要求每一个 episode 都要有**终止状态来中止**。然而，由于本文场景中的随机初始化和**动态干扰**（将在后面详细介绍），无论是获得完整的状态转移概率函数还是定义终止状态都是很困难的。因此，动态规划和蒙特卡洛法并不适用，本论文均选用时序差分法，且在 MDP 建模时均不再讨论状态转移概率。

在用于求解最优 q 函数的基于时序差分的强化学习算法中，又分为在线策略（On-Policy）和离线策略（Off-Policy）两类方法。在强化学习中，智能体需要不断地与环境交互以采样 transition 用于更新策略。在线策略方法的采样策略和更新的策略保持一致，其优点是策略学习过程比较稳定，但缺点也比较明显，为了满足在线策略的要求，**智能体采样得到的样本只能使用一次**（因为采样后更新后的策略就与采样的策略不同了），样本利用效率较低。然而智能体通常需要大量的样本训练来收敛，所以在线策略方法对采样数量要求很高。而离线策略方法则不要求采样策略和更新策略一致，**可以用旧的样本来更新新的策略**，尽管这样的

做法在稳定性和一致性（当前策略所对应的状态-动作对的分布与样本的分布不一致，这会对策略学习产生负面影响）上不如在线策略，但是样本利用效率更高。

在线策略的强化学习算法有 SARSA^[55]、A2C、A3C^[56]、TRPO^[57]、PPO^[58]等，其中 PPO-Clip 因其对调参要求低、计算简易以及稳定优异的性能备受青睐。通常，实施在线策略的强化学习时需要使用**分布式**强化学习框架，硬件方面分为 CPU 集群和 GPU 集群，其中在 CPU 集群上运行的智能体通常称为 worker，在 GPU 集群上运行的称为 learner。worker 主要负责从 learner 接收新的策略、采样并将样本传回样本池，一般来说 CPU 集群上同时有多个 worker 并行地采样。learner 则负责从样本池中提取样本进行策略更新，并将更新后的策略发送给 worker，样本池中的样本在被使用一次后就被丢弃。本论文的强化学习实验均使用单台服务器完成，服务器的核心硬件配置为 2 块 Intel(R) Xeon(R) Gold 6258R CPU @ 2.70GHz，4 张 NVIDIA GeForce RTX 3090 GPU，24 条 32GB DDR4 2933MHz 内存。考虑到分布式强化学习框架的实现较为复杂且并非本论文工作重点，故本论文**均采用离线策略的强化学习算法**。

离线策略的强化学习算法有 Q-Learning^[59]、DDPG^[60]、TD3^[61]、SAC^[62]等，其中 Q-Learning 作为基于价值函数的方法，非常适合用来求解**离散动作空间**下的最优 q 函数，故本章将采用 Q-Learning 来优化时、频域联合的抗干扰策略。

2.3.3.2 深度 Q-Learning

传统的 Q-Learning 属于表格型求解法（Tabular Solution Method），适用于状态空间和动作空间均较小的问题。Q-Learning 需要维护一个数组或者表格，称为 Q 表（Q Table），用来存放所有状态-动作对的价值。在任一状态下，只需查询 Q 表即可得到每个动作的价值，若执行贪心策略（选择价值最大的动作），则以如下方式选择动作：

$$a_t = \arg \max_{a \in \mathcal{A}} Q(s_t, a) \quad (2-52)$$

Q-Learning 以如下的方式更新价值函数：

$$Q(s_t, a_t) \leftarrow Q(s_t, a_t) + \beta \delta_t \quad (2-53)$$

其中 β 表示学习率（或称更新步长）， δ_t 是用于更新的时序差分误差：

$$\delta_t = r_{t+1} + \gamma \max_{a_{t+1} \in \mathcal{A}} Q(s_{t+1}, a_{t+1}) - Q(s_t, a_t) \quad (2-54)$$

其中的 $r_{t+1} + \max_{a_{t+1} \in \mathcal{A}} Q(s_{t+1}, a_{t+1})$ 称为时序差分目标值，简称为目标值（Target Value）。Q-Learning 的目标可以认为是通过训练更新，使时序差分误差不断减小直至收敛。

尽管 Q-Learning 的收敛性有理论保证^[59]，然而其只能处理离散的搜索空间，

一旦面对高维或连续的搜索空间，将变得不可行。而对于本章的 MDP 模型，由于状态中 SINR 的连续取值以及状态的扩展，状态空间将是高维且非离散的，无法使用传统的表格型方法求解。2015 年，Google DeepMind 的研究人员^[63]提出使用深度神经网络来拟合 Q 表的方法，解决了在高维状态空间中进行有效探索和学习的问题，该方法称为深度 Q-Learning，用来拟合 Q 表的深度神经网络称为深度 Q 网络（Deep Q Network, DQN）。

深度 Q-Learning 选择动作和计算时序差分误差的方式与 Q-Learning 在形式上基本一致（如式(2-52)和式(2-54)所示），而训练时 DQN 更新的目标即为最小化时序差分误差。接下来介绍深度 Q-Learning 在训练时使用的几个技巧：

（1） ϵ 贪心探索（ ϵ -Greedy Exploration）：强化学习存在探索-利用困境（Exploration-Exploitation Dilemma），探索即为选取未尝试过的动作，利用则指根据式(2-52)选取当前价值最大的动作。然而在训练前期，智能体尝试过的动作较少，若从始至终只执行贪心策略，则容易造成“先入为主”的问题，导致智能体因缺乏探索无法对所有状态-动作对形成正确的价值评估，从而很可能陷入次优动作。 ϵ 贪心探索被提出以解决探索-利用的困境，采样时智能体以探索概率 $\epsilon \in [0,1]$ 随机选择动作：

$$a_t = \begin{cases} \arg \max_{a \in \mathcal{A}} Q(s_t, a), & \text{以概率}(1 - \epsilon) \\ \forall a \in \mathcal{A}, & \text{以概率} \frac{\epsilon}{|\mathcal{A}|} \end{cases} \quad (2-55)$$

在训练中，一般需要前期主探索后期主利用，因此 ϵ 的初始值一般设为较大值，随着训练逐渐衰减至一个较小值。

（2）经验回放（Experience Replay）：采样时，将每一个时间步对应的转移 $\mathbf{e}_t = [s_t, a_t, r_{t+1}, s_{t+1}]$ 都存入经验池（Replay Buffer），记为 $\mathcal{D}$ ，在经验池中存储的转移数量达到上限后，新的转移将替换最老的转移。DQN 每一次更新时都从经验池中随机选取一个小批次（Mini-Batch）用来进行反向传播更新。经验回放不仅可以提高样本的利用率，还可以打破连续样本间的相关性，防止其对训练产生负面影响。

（3）双 Q 学习（Double Q-Learning）：在提出 DQN 的文献中，作者就使用了两个 Q 网络，即估计网络 Q_{eval} 和目标网络 Q_{tar} ，其网络参数分别使用 θ 和 θ^- 来表示。具体地，在采样时使用 Q_{eval} 来计算动作价值，而在计算时序差分误差时使用 Q_{tar} 来计算目标值。经验回放直接更新 Q_{eval} ，其反向传播更新的损失函数为

$$L(\theta) = \mathbb{E}_{(s,a,r,s') \sim \mathcal{D}} \left[\left(r + \gamma \max_{a'} Q(s', a'; \theta^-) - Q(s, a; \theta) \right)^2 \right] \quad (2-56)$$

Q_{tar} 则是每过若干时间步同步至 Q_{eval} ,即 $\theta^- \leftarrow \theta$,称为延迟更新(Delayed Update)。这样双网络的做法解决了单个网络同时更新和计算目标值所带来的学习目标的不稳定,显著提升了深度 Q-Learning 的性能。然而,由于在计算目标值时使用了自举(Bootstrap)和 max 操作, Q-Learning 存在价值过估计(Overestimation)的问题,这会导致训练时策略不稳定、收敛速度慢、智能体过度自信等问题,使策略性能下降。Hado van Hasselt 在 2010 年提出双学习的方法来解决过估计的问题^[64],并在 2016 年将其应用于深度 Q-Learning^[65]。其仅仅是在双网络的基础上对目标值的计算进行了些许简单的改动,将目标值的估计和动作的选取分离开,其时序差分目标值为

$$r + \gamma Q(s', \arg \max_{a'} Q(s', a'; \theta); \theta^-) \quad (2-57)$$

即用 Q_{eval} 选择后继动作 a' ,再用 Q_{tar} 计算目标值。双学习显著改善了动作价值过高估计的问题,进一步提升了强化学习算法的性能,此后的强化学习算法^{[56][57][60][61][62]}在涉及目标值的计算时也都使用了这样的双网络、双学习技巧。

本章将采用深度 Q-Learning 来优化时、频域联合的干扰避免策略,并在训练中使用上述技巧。

2.3.3.3 Q 网络设计

DQN 最常用的是深度神经网络(Deep Neural Network, DNN),通常由多层全连接层(Fully Connected Layer, FCL)堆叠而成,如图 2-8 所示。对于单层的全连接层,设其输入向量为 $\mathbf{x} \in \mathbb{R}^d$,全连接层的权重为 $\mathbf{w} \in \mathbb{R}^d$,偏置为 $b \in \mathbb{R}$,则该层的输出向量为

$$\mathbf{y} = \mathbf{w}^T \mathbf{x} + b \quad (2-58)$$




图 2-8 DNN 示意图

显然,上述计算为线性变换。然而,如果只是单纯堆叠线性变换,最终得到的也

只是线性变换，模型的表征能力仍然非常有限。通常，会在全连接层之后使用激活函数（Activation Function），对全连接层的输出进行非线性变换，提升网络的函数拟合能力。常用的激活函数包括 sigmoid、tanh、ReLU、softmax 等，它们的数学表达式如下：

$$\text{sigmoid}(x) = \frac{1}{1 + e^{-x}} \quad (2-59)$$

$$\text{tanh}(x) = \frac{1 - e^{-2x}}{1 + e^{-2x}} \quad (2-60)$$

$$\text{ReLU}(x) = \max(x, 0) \quad (2-61)$$

$$\text{softmax}(x_i) = \frac{e^{x_i}}{\sum_{k=1}^d e^{x_k}} \quad (2-62)$$

一般地，DQN 的输入为状态向量，输出为动作价值向量（包含了每个动作的价值，一个分量对应一个动作），所以其输入维度即为状态向量维度 $\dim(\mathcal{S})$ ，输出维度即为动作空间大小 $|\mathcal{A}|$ 。然而，在本章的 MDP 模型中，为了应对部分可观测问题，我们使用了扩展状态 $\mathbf{S}_t$ ，其可以看作是当前 episode 内最近若干时间步的单步状态的序列。 $\mathbf{S}_t$ 所包含的各个单步状态间存在明确的时序关系，而 DNN 的处理过程很难体现输入向量间的时序关系，故 $\mathbf{S}_t$ 不能直接作为 DNN 的输入进行处理。在此，我们使用可以处理时间序列数据的门控循环单元（Gated Recurrent Unit, GRU）^[66]，它是循环神经网络（Recurrent Neural Network, RNN）的一种。

如图 2-9 所示，GRU 有两个门，即重置门（Reset Gate）和更新门（Update Gate），两个门的输入是由当前时间步的输入和前一时间步的隐状态给出，输出




图 2-9 GRU 结构示意图^[67]

是由使用 sigmoid 激活函数的两个全连接层给出。假设在时间步 t 的输入为 $\mathbf{X}_t \in \mathbb{R}^{n \times d}$ (样本数量 (batch size) 为 n , 向量维度为 d), 上一个时间步的隐状态 (Hidden State) 为 $\mathbf{H}_{t-1} \in \mathbb{R}^{n \times h}$ (隐藏单元个数为 h)。则重置门 $\mathbf{R}_t \in \mathbb{R}^{n \times h}$ 和更新门 $\mathbf{Z}_t \in \mathbb{R}^{n \times h}$ 的计算为:

$$\mathbf{R}_t = \sigma(\mathbf{X}_t \mathbf{W}_{xr} + \mathbf{H}_{t-1} \mathbf{W}_{hr} + \mathbf{b}_r) \quad (2-63)$$

$$\mathbf{Z}_t = \sigma(\mathbf{X}_t \mathbf{W}_{xz} + \mathbf{H}_{t-1} \mathbf{W}_{hz} + \mathbf{b}_z) \quad (2-64)$$

其中 $\mathbf{W}_{xr}, \mathbf{W}_{xz} \in \mathbb{R}^{d \times h}$ 和 $\mathbf{W}_{hr}, \mathbf{W}_{hz} \in \mathbb{R}^{h \times h}$ 是权重参数, $\mathbf{b}_r, \mathbf{b}_z \in \mathbb{R}^{1 \times h}$ 是偏置参数。接着, 重置门 $\mathbf{R}_t$ 用于更新隐状态, 得到候选隐状态 (Candidate Hidden State) $\tilde{\mathbf{H}}_t \in \mathbb{R}^{n \times h}$:

$$\tilde{\mathbf{H}}_t = \tanh(\mathbf{X}_t \mathbf{W}_{xh} + (\mathbf{R}_t \odot \mathbf{H}_{t-1}) \mathbf{W}_{hh} + \mathbf{b}_h) \quad (2-65)$$

其中 $\mathbf{W}_{xh} \in \mathbb{R}^{d \times h}$ 和 $\mathbf{W}_{hh} \in \mathbb{R}^{h \times h}$ 是权重参数, $\mathbf{b}_h \in \mathbb{R}^{1 \times h}$ 是偏置参数, 符号 $\odot$ 表示做 Hadamard 积 (按元素乘积)。最后, 更新门 $\mathbf{Z}_t$ 在 $\mathbf{H}_{t-1}$ 和 $\tilde{\mathbf{H}}_t$ 之间进行按元素的凸组合, 得到最终的新的隐状态:

$$\mathbf{H}_t = \mathbf{Z}_t \odot \mathbf{H}_{t-1} + (1 - \mathbf{Z}_t) \odot \tilde{\mathbf{H}}_t \quad (2-66)$$

这同时也是整个 GRU 的输出。

本章所使用的 DQN 结构如图 2-10 所示, 由 GRU 和 DNN 构成。在每一个时间步, 扩展状态 $\mathbf{S}_t$ 作为整个 DQN 的输入, 被送至一个 GRU 来提取有关干扰的信息, GRU 层的输出作为后续 DNN 的输入, 计算所有动作的 Q 值并作为整个 DQN 的输出。需要注意的是, 上述关于 GRU 的计算中, $\mathbf{X}_t$ 对应的是 $\mathbf{S}_t$ 中的单个时间步状态 $\mathbf{s}_k$ (此处考虑对单个 $\mathbf{S}_t$ 处理, 而非一个 batch, 故 batch size 等于 1), 所以有 $n = 1$ (在处理一个 batch 时, n 等于 batch size), 对于整个 $\mathbf{S}_t$, GRU 则是从最开头的单步状态顺次处理至最后一个, 所以对于每一个 $\mathbf{S}_t$, GRU 最终的输出形状仍然为 $1 \times h$ 。




图 2-10 DQN 结构示意图

实际上, 在此之前 DQN+RNN 的方法已被用于解决部分可观测以及处理具有时序依赖性的环境的问题^[68], 以增强 DQN 在处理序列数据时的学习能力和长期记忆。比较常见的做法是利用 RNN 的隐状态作为实现记忆的载体, 每一时间

步的输入是当前的单步状态（观测），这样做需要保存每一步 RNN 的隐状态，用于经验回放时 **RNN 初始状态的设置**。本章的不同在于直接将多步状态作为输入，不需要额外保存隐状态，但需要注意的是，DQN 每次推理前都要将隐状态置零。

2.4 仿真实验

本节将用仿真实验来验证本章所提出的抗干扰策略的有效性，接下来介绍仿真实验的设置及结果。

2.4.1 实验设置

2.4.1.1 雷达设置

受干扰雷达的参数列在表 2-1 中。干扰的扫频参数与受干扰雷达相同，包括中心频率、调频斜率、扫频时长、带宽和 PRI。在此，我们设置雷达在频域和时域各有 3 个可用状态，即在联合域总共有 9 个可用状态。为了便于 DQN 学习，我们使用 one-hot 编码来表示这些参数状态，各参数状态的编号以及 one-hot 编码以列在表 2-2 中。单步状态中的 **参数状态** 部分也相应地替换为 one-hot 编码，而 **SINR** 的表示不变。

表 2-1 受干扰雷达参数设置

参数	取值
频域状态 $\hat{f}_c$ [GHz]	76.5, 77.0, 77.5
时域状态 $t_d [\times \tau_{max}]$	0, 1, 2
调频斜率 [MHz/us]	10
扫频时长 [us]	50
带宽 [MHz]	500
脉冲重复周期 [us]	60
每帧 chirp 数	128
采样频率 [MHz]	20
最大探测距离 [m]	120
目标回波最大延迟 [us]	0.8
目标回波最大差频 [MHz]	8

表 2-2 雷达参数状态编码

索引	参数状态 ($\hat{f}_c$ [GHz], $t_d [\times \tau_{max}]$)	one-hot 编码
0	(76.25, 0)	[1, 0, 0, 0, 0, 0, 0, 0, 0]
1	(76.25, 1)	[0, 1, 0, 0, 0, 0, 0, 0, 0]
2	(76.25, 2)	[0, 0, 1, 0, 0, 0, 0, 0, 0]
3	(76.50, 0)	[0, 0, 0, 1, 0, 0, 0, 0, 0]
4	(76.50, 1)	[0, 0, 0, 0, 1, 0, 0, 0, 0]
5	(76.50, 2)	[0, 0, 0, 0, 0, 1, 0, 0, 0]
6	(77.25, 0)	[0, 0, 0, 0, 0, 0, 1, 0, 0]

续表 2-2 雷达参数状态编码

索引	参数状态 ($\hat{f}_c$ [GHz], $t_d [\times \tau_{\max}]$)	one-hot 编码
7	(77.25, 1)	[0, 0, 0, 0, 0, 0, 0, 1, 0]
8	(77.25, 2)	[0, 0, 0, 0, 0, 0, 0, 0, 1]

2.4.1.2 场景设置

表 2-3 展示了训练和测试的仿真设置。其中, $\mathcal{U}\{b_1, b_2, \dots, b_l\}$ 表示在集合 $\{b_1, b_2, \dots, b_l\}$ 上服从离散均匀分布, $\mathcal{U}(b_1, b_2)$ 表示在区间 (b_1, b_2) 上服从连续均匀分布, $\mathcal{P}(\lambda)$ 表示期望为 λ 的泊松分布。信号仿真时, 会对雷达接收信号加入加性高斯白噪声, 以模拟雷达系统的噪声, 噪声等级即为表 2.3 中所列的 SNR。由于干扰信号的到达延迟与距离和干扰源的发射时间均有关, 所以为了简便, 干扰的延迟时间 τ_{intf} 直接给出。

表 2-3 仿真设置

参数		取值	
		训练	测试
点目标	数量	$\mathcal{U}\{1, 2, 3\}$	
	幅度	$\mathcal{U}(0.5, 1.5)$	
	距离 [m]	$\mathcal{U}(0.3, 120)$	
	相对受干扰雷达的速度 [m/s]	$\mathcal{U}(-16, 16)$	
	反射引起的相位变化	$\mathcal{U}(-\pi, \pi)$	
干扰	数量	$\mathcal{P}(12)$	6 ~ 18
	幅度	$\mathcal{U}(1, 12)$	
	相对受干扰雷达的速度 [m/s]	$\mathcal{U}(-32, 32)$	
	延迟时间 [us]	$\mathcal{U}(0, 2.4)$	
光速 [m/s]		3×10^8	
SNR [dB]		10	
每个 episode 的时间步数		40	200
动态场景下的时间步间隔 [ms]		125	

在此, 我们定义静态场景和动态场景。在实际中, 汽车雷达干扰避免是一个持续性的任务, 所以在此我们规定了一个 episode 的最大步数。在仿真中, 每个 episode 开始时将完成目标和干扰的随机初始化, 在每个时间步内雷达只发射、接收和处理一帧信号。由表 2-1 给出的雷达参数可知一帧信号的时长少于 10 毫秒, 这个间隔太短, 不足以使移动的目标和干扰源在通带内对信号产生显著的影响。因此在静态场景下忽略每个时间步的时长, 即认为目标和干扰在一个 episode 内均保持不变。在动态场景下, 增大时间步之间的间隔, 从而使目标和干扰源在一个 episode 内的相对运动有显著的影响。例如, 由于相对距离的变化, 干扰既可以移入也可以移出某个通带, 而目标也可能超出最大探测距离, 这将影响雷达的行为。具体地, 目标距离和干扰延迟 τ_{intf} 在每个时间步前将以如下方式更新:

$$d(t_n) = d(t_n) + v_{\text{target}}\Delta t \quad (2-67)$$

$$\tau_{\text{intf}}(t_n) = \tau_{\text{intf}}(t_{n-1}) + \frac{v_{\text{intf}}\Delta t}{c} \quad (2-68)$$

其中 $d(t_n)$ 和 $\tau_{\text{intf}}(t_n)$ 分别代表在时间步 t_n 的目标距离和干扰延迟时间。 v_{target} 和 v_{intf} 分别是目标和干扰源的相对运动速度。为了简便，我们假设目标和干扰的幅度和速度在一个 episode 内保持不变。如果一个目标的距离或干扰的延迟时间超过了表 2-3 中的范围，它将被一个新的随机初始化的目标或干扰所取代，以模拟中途进入视野的目标或干扰。

2.4.1.3 强化学习设置

强化学习的设置列在表 2-4 中。在训练和测试中设有以下雷达智能体：

- 1) Radar-Fixed: 智能体的参数状态 $(\hat{f}_c, t_d)$ 固定为(77 GHz, 0.8 us)。
- 2) Radar-F: 智能体执行跳频，其 t_d 固定为 0.8 us。
- 3) Radar-T: 智能体执行时域策略，其 $\hat{f}_c$ 固定为 77 GHz。
- 4) Radar-Joint-AC- α_3 : 智能体执行带动作代价的联合策略。权重 α_3 决定了动空作代价相对 SINR 的优先级：
 - a) $\alpha_3 = 0$: 完全不考虑动作代价。
 - b) $\alpha_3 = 0.2$: 动作代价优先级低。
 - c) $\alpha_3 = 0.8$: 动作代价优先级高。

表 2-4 强化学习设置

参数项			取值
(α_1, α_2)			(2, 0.1)
$(\text{SINR}_1, \text{SINR}_2)$ [dB]			(0, 11)
γ			0.99
β			0.01 ~ 0.00001
ϵ			1 ~ 0.05
$\mathbf{s}_t$ 的最大容量			20 个时间步
经验池容量			50000
经验回放批大小			4×32
Q_{tar} 更新间隔			200 个时间步
Q 网络结构	层		神经元数目
	GRU		16
	DNN	FCL_1	32
		FCL_2	9
	总参数量		2185

Q 网络由一个 GRU 层和一个 DNN 组成，这个 DNN 有两层 FCL，在第一层 FCL 后使用 ReLU 激活函数。Q 网络的输入为扩展状态 $\mathbf{s}_t$ ，输入的单个向量维度为 10，输出是从当前参数状态切换到每个可用参数状态的 q 值，所以 DQN 的输

出长度，也即第二层 FCL 的神经元数量是 9，对于可用动作不足 9 个的智能体（即 Radar-F 和 Radar-T，在选择动作时屏蔽不可用动作）。DQN 使用 RMSProp^[69] 优化器进行反向传播更新，实现 DQN 所使用的深度学习框架是 TensorFlow 2.6。在训练期间，学习率 β 和探索概率 ϵ 均逐 episode 地指数衰减，直至最小值。在测试期间，智能体将执行贪心策略，而非 ϵ 贪心探索。

2.4.2 实验结果

在每个 episode 中的干扰随机初始化导致了采样数据（环境）具有较大的方差，这使得强化学习训练变得困难且不稳定。为了应对这种不稳定，我们减少了训练中每个 episode 的最大时间步数（如表 2-3 所示，训练时单个 episode 的最大步数仅为测试时的五分之一）。实际上，我们将智能体先放在静态场景下训练至收敛，然后在动态场景下继续训练，两个阶段的训练总共耗费了超过 5 万个 episode（200 万个时间步）才收敛。完成训练后，智能体在不同的干扰数下进行测试，干扰数从 6 取到 18。对每个干扰数，都分别在静态场景和动态场景下测试了 1000 个 episode。表 2-5 列出了测试中，各智能体在静态场景和动态场景下避开干扰的总体表现，图 2-11 展示了个智能体在各干扰数下的测试结果。其中的避开率定义为**通带内没有干扰的时间步占比**，该指标与平均 SINR 共同体现了智能体避开干扰的性能。其中，避开率直接体现了智能体避开相干干扰（避免虚假目标）的水平，而 SINR 则还可以反映在无法完全避开干扰时，避重就轻（即优先避开强度大的干扰）的能力。

表 2-5 测试的统计结果

智能体	平均 SINR [dB]		平均避开率 [%]		平均每个 episode 的 AC 和	
	静态	动态	静态	动态	静态	动态
Fixed	-7.48	-8.52	25.47	22.09		
F	0.92	-1.25	54.16	46.16		
T	1.09	-0.74	54.70	48.21		
Joint-AC-0	4.85	4.18	71.36	68.81	33.86	37.57
Joint-AC-0.2	5.69	3.66	74.01	66.48	19.77	30.56
Joint-AC-0.8	3.41	0.51	64.65	55.18	8.58	14.54

在所有的智能体中，Radar-Fixed 在避开干扰上的表现最差，其无论在 SINR 还是避开率上，与其他智能体都相差甚远。相比之下，Radar-F 和 Radar-T 都表现得好很多，二者在 SINR 上的提升均超过 7 dB，在绝对避开率上的提升则在 24%~29%（相对提升达到 108%~118%）。这证明了单独的频域策略或时域策略在本章的场景下，使用本章所提出的 MDP 建模和强化学习算法优化是有效的。值得注意的是，Radar-F 和 Radar-T 在静态场景下的表现几乎一样。这是因为在

时域和频域的可用状态数量相同，并且干扰初始化时是均匀分布在这两个域的。




图 2-11 不同干扰数量下的测试结果, (a)静态场景下的平均 SINR (b)动态场景下的平均 SINR (c)静态场景下平均避开率 (d)动态场景下的平均避开率 (e)静态场景下平均每个 episode 动作代价总和 (f)动态场景下平均每个 episode 动作代价总和

相比于静态场景，在动态场景下，Radar-F 和 Radar-T 的避开干扰均有明显下降，然而 Radar-T 的性能下降更小，在动态场景下的性能略优于 Radar-F。在动态场景下，最初没有干扰的通带中途可能会加入新的干扰，这使得智能体无法做到“一劳永逸”，因此避开干扰变得更具挑战。同时，干扰的动态特性在时域比在频域更有规律，所以在时域中避开干扰更容易，尤其是在面对更多干扰时，所以在动态场景下 Radar-T 比 Radar-F 更有优势。

Radar-Joint-AC-0 的 SINR 比 Radar-F 或 Radar-T 都更好，联合策略在总体避开率上有着 44% 的相对提升。当干扰数增加时，避开干扰变得越来越困难，从而智能体在 SINR 上的表现变差，并且 Radar-Joint-AC- α_3 采取了更多动作。对比 Radar-Joint-AC-0, Radar-Joint-AC-0.2 和 Radar-Joint-AC-0.8 都实现了 SINR 和 AC 间的折中。由于 α_3 取值较小，Radar-Joint-AC-0.2 在动态场景下仅为 AC 稍微牺牲了一点 SINR。而在静态场景下，Radar-Joint-AC-0.2 不仅在 AC 上展现出较大优势，甚至取得了比 Radar-Joint-AC-0 更高的 SINR。由于静态场景下，在一个 episode 内干扰的分布初始化后就不再改变，当智能体取得高 SINR 后，保持当前参数状态通常是最佳选择。但是 Radar-Joint-AC-0 可能会继续尝试其他参数状态，这因为它缺乏 AC 的约束，这可能导致不稳定的 SINR 表现。低权重的 AC 可以增强联合策略的鲁棒性，而被赋予高权重 AC 的智能体则更倾向于维持低 AC 而非高 SINR。Radar-Joint-AC-0.8 总是维持非常低的 AC，而代价就是 SINR 的显著降低。尽管如此，它依然比 Radar-F 和 Radar-T 更好。

图 2-12 展示了在动态场景下干扰数为 12 时，一个 episode 内这些智能体的状态转移以及在 SINR 和 AC 上的表现。Radar-Fixed、Radar-F、Radar-T、Radar-Joint-AC-0、Radar-Joint-AC-0.2 和 Radar-Joint-AC-0.8 的平均 SINR 分别为 -27.18 dB、-12.15 dB、-17.11 dB、5.05 dB、5.48 dB 和 3.01 dB。Radar-Joint-AC-0、Radar-Joint-AC-0.2 和 Radar-Joint-AC-0.8 的 AC 总和分别为 66、23 和 16。Radar-Fixed 的平均 SINR 显著低于其他的。而由于在联合时、频域上有更大的空间避开干扰，当 Radar-F 和 Radar-T 陷入低 SINR 时，Radar-Joint-AC- α_3 更容易维持高 SINR。当遭遇由动态干扰导致的 SINR 的突然下降，执行联合策略的智能体通常会立即作出反应。然而，当处于低 SINR 时，有着更高的 α_3 的智能体倾向于更不频繁地改变它的参数。所以，对于 Radar-Joint-AC- α_3 ，更高的 α_3 导致了更低的平均 SINR 和 AC 总和。但是，Radar-Joint-AC-0 的平均 SINR 还略低于 Radar-Joint-AC-0.2。如图 4 所示，Radar-Joint-AC-0 在时间步 67 至 104 和 140 至 160 这两段内持续地切换它的工作参数，即使它已经取得高 SINR。这一行为导致 AC 的显著增加以及 SINR 的波动，这可能会危害目标检测。Radar-Joint-AC-0 时常出现这样的情况，而 Radar-Joint-AC-0.2 和 Radar-Joint-AC-0.8 却几乎没有这样的行为。在 AC

的约束下，智能体在取得高 SINR 后会停下而不是探索其他可能。因此，**动作代价机制**不仅能实现 SINR 和 AC 间的折中，还可以使智能体运行更稳定。




图 2-12 动态场景下单 episode 的测试结果

2.5 本章小结

在本章中，我们为 FMCW 汽车雷达提出了一种非合作式的时、频域联合的策略，通过调整中心频率和发射时间，将干扰移出通带来避开相干干扰，从而提高干扰避开率和 SINR。我们将所提出的策略的执行过程建模为马尔可夫决策过程，并使用深度 Q-Learning 来进行策略优化。为了应对部分可观测问题，我们将状态扩展为时间序列，并使用门控循环单元来处理。在静态场景下和动态场景下的仿真实验展示了该方法的有效性。时、频域联合的策略显著提升了避开相干干扰的性能，相较于已有的频域策略，联合策略完全避开干扰的性能提升可以达到 49%，SINR 提升超过 5 dB。另外，我们引入了动作代价机制，该机制不仅可以减少雷达不必要的参数切换，还能增强抗干扰策略的鲁棒性。

第三章 面对相干干扰的脉间相位编码抗干扰策略

本章将先简单介绍相位编码的类型、原理和研究现状。随后，提出一种随机相位编码，并展示其效果。接着，针对这种随机相位编码的不足，提出优化策略。然后，给出相位编码优化策略的 MDP 建模和求解最优策略的强化学习算法设计。最后，将展示验证本章所提出的抗干扰策略的仿真实验的设置和结果。

3.1 应对相干干扰的相位编码

上一章所提出的抗干扰策略的原理是调整参考信号在时频域上的位置，从而将干扰信号移出通带，使其不进入 beat signal 影响后续的目标检测。而本章所要研究的相位编码则允许干扰进入 beat signal，在保持目标回波和参考信号的相关性的同时，破坏干扰信号和参考信号的相关性，使干扰的能量在进行目标检测的操作域（如距离多普勒域）上分散，从而降低干扰的影响。

由于非相干干扰与受干扰雷达参考信号的相关性较弱，故相位编码一般是用来对抗相干干扰的。目前，相位编码可分为两类：脉内（Intra-Pulse）编码和脉间（Inter-Pulse）编码。脉内编码是在一个 chirp 内对参考信号使用编码序列（如特定序列或伪随机码序列）进行相位调制，这意味着在一个 chirp 内，雷达信号会发生相位突变。而脉间编码则是以 chirp 为最小单位，在不同连续发射的 chirp 之间引入相位差异。这两种相位编码都可以将相干干扰的能量在多普勒维上分散，从而避免其在基于距离多普勒图的 CFAR 检测中形成虚假目标。实现脉内相位编码的 FMCW 雷达系统^[19]通常需要更复杂的信号处理器件和算法来实现编码和解码，而脉间相位编码使用目前主流的汽车雷达（如德州仪器的 AWR 系列^[53]）即可实现。本章将专注于脉间相位编码。

假设式(2-11)是没有加入脉间相位编码的信号表示，而我们使用的脉间相位编码序列为 $\boldsymbol{\varphi}_c = [\varphi_c^1, \varphi_c^2, \dots, \varphi_c^L]$ ，则经过相位编码后的参考信号可表示为

$$\mathbf{x}_T^c(t; L) = \sum_{l=1}^L \mathbf{x}_T(t; l) e^{j2\pi\varphi_c^l} \quad (3-1)$$

其接收信号中的目标回波可表示为

$$\mathbf{x}_{\text{echo}}^c(t; L) = \sum_{l=1}^L \mathbf{x}_{\text{echo}}(t; l) e^{j2\pi\varphi_c^l} \quad (3-2)$$

其中 $\mathbf{x}_{\text{echo}}(t; l)$ 为不加相位编码的目标回波的第 l 个 chirp 的信号。则目标回波的 beat signal 为

$$\begin{aligned}
x_{\text{becho}}(t; L) &= x_T^c(t; L) \bar{x}_{\text{echo}}^c(t; L) * h_{lp}(t) \\
&= \sum_{l=1}^L x_T(t; l) e^{j2\pi\varphi_c^l} \cdot \bar{x}_{\text{echo}}(t; l) e^{-j2\pi\varphi_c^l} * h_{lp}(t) \\
&= \sum_{l=1}^L x_T(t; l) \cdot \bar{x}_{\text{echo}}(t; l) * h_{lp}(t)
\end{aligned} \tag{3-3}$$

可见脉间相位编码并不会改变 beat signal 的相位，也就不会影响目标回波和参考信号的相关性。而对于干扰信号，不妨设其使用的相位编码序列为 $\varphi_{\text{cintf}} = [\varphi_{\text{cintf}}^1, \varphi_{\text{cintf}}^2, \dots, \varphi_{\text{cintf}}^L]$ ，其被受干扰雷达接收的信号表示为

$$x_{\text{intf}}^c(t; L) = \sum_{l=1}^L x_{\text{intf}}(t; l) e^{j2\pi\varphi_{\text{cintf}}^l} \tag{3-4}$$

其中 $x_{\text{intf}}(t; l)$ 为不加相位编码的干扰信号。其经过 dechirp 和低通滤波后的 beat signal 可表示为

$$\begin{aligned}
x_{\text{bintf}}(t; L) &= x_T^c(t; L) \bar{x}_{\text{intf}}^c(t; L) * h_{lp}(t) \\
&= \sum_{l=1}^L x_T(t; l) e^{j2\pi\varphi_c^l} \cdot \bar{x}_{\text{intf}}(t; l) e^{-j2\pi\varphi_{\text{cintf}}^l} * h_{lp}(t) \\
&= \sum_{l=1}^L x_T(t; l) \cdot \bar{x}_{\text{intf}}(t; l) e^{j2\pi(\varphi_c^l - \varphi_{\text{cintf}}^l)} * h_{lp}(t)
\end{aligned} \tag{3-5}$$

则相较于双方都不加入相位编码，beat signal 的每个 chirp 都多了一个相位偏移 $(\varphi_c^l - \varphi_{\text{cintf}}^l)$ ，这将直接影响快时间维 FFT 的结果，改变相干干扰在多普勒维的能量分布。只要 φ_{cintf} 和 φ_c 不完全相关，相干干扰的能量就将在多普勒维分散，而通常汽车雷达一个 frame 的 chirp 数为 128 或 256^[53]，因此在非蓄意的情况下， φ_{cintf} 与 φ_c 的相关性通常较低，从而相干干扰的能量在多普勒维难以聚集以形成虚假目标。

3.2 连续值相位编码策略

目前，已有一些脉间相位编码的方法被提出以解决相干干扰的问题^{[21][22]}，这些方法大多使用的是离散的编码序列（多为二进制编码），并且使用随机序列或迭代求解的方法。实际上，每个编码可以在 $(-0.5, 0.5)$ 内连续地取值，离散编码实际上限制了最优编码的求解空间；随机编码也可以进一步优化，而现有的迭代求解^[21]本身是一个 NP-hard 问题，其求解的效率难以保证，从而将严重影响实际使用时的实时性。因此，在本章中我们提出非合作式的连续值脉间相位编码策略，以端到端的方式实现高效的脉间编码抗干扰。

最简单的策略是连续随机值相位编码，即对于 $\boldsymbol{\varphi}_c = [\varphi_c^1, \varphi_c^2, \dots, \varphi_c^L]$ ，有 $\varphi_c^i \sim \mathcal{U}(-0.5, 0.5), 1 \leq i \leq L$ 。由于每个相位取值都是均匀随机的，故相干干扰的能量在多普勒维分散得比较均匀，形成虚假目标的概率非常低，如图 3-1 所示。




图 3-1 有无相干干扰以及有无连续随机值脉间相位编码情况下，距离多普勒图以及 CFAR 检测的结果对比，(a)无干扰无编码下的距离多普勒图 (b) 无干扰无编码下的 CFAR 检测结果 (c)有干扰无编码下的距离多普勒图 (d)有干扰无编码下的 CFAR 检测结果 (e)有干扰有编码下的距离多普勒图 (f)有干扰有编码下的 CFAR 检测结果

然而，由于相干干扰的能量通常比目标回波大很多，即使其能量均匀地分散在多普勒维，每个单元内的能量依旧不小，当干扰和目标在距离维上所处的单元很接近时，会引起目标的漏检，如图 3-2 所示。因此，我们在此提出对连续值脉




图 3-2 在连续随机值脉间相位编码情况下，相干干扰掩盖目标导致漏检的示例，(a)无干扰无编码下的距离多普勒图 (b) 无干扰无编码下的 CFAR 检测结果 (c)有干扰无编码下的距离多普勒图 (d)有干扰无编码下的 CFAR 检测结果 (e)有干扰有编码下的距离多普勒图 (f) 有干扰有编码下的 CFAR 检测结果

间相位编码进行优化, 改变干扰在多普勒维能量的分布, 使其既不会引起虚假目标, 也不会掩盖附近目标。

3.3 基于深度强化学习的脉间相位编码抗干扰策略的实现

根据所要处理的数据样本是否有明确的标签, 机器学习方法可以分为三类: 无监督学习、监督学习和强化学习^[55]。无监督学习用来处理无标签的数据集, 其目标是学习数据内在的结构、模式或关联性。监督学习用来处理有明确标签的数据集, 学习从样本到标签的映射。强化学习则不依赖于预先标记的样本, 而是通过环境给出的即时反馈指导自身行为的改进, 以最大化长期奖励。

实际上, 目前已有研究人员使用监督学习的方法来实现多普勒域上的陷波^[48], 其在原理上与脉间相位编码异曲同工。监督学习需要大量带标签的样本才能实现较好的性能和泛化性, 具体到此处的相位编码问题, 若将干扰的实例定义为样本, 则标签就是最优的相位编码序列。然而, 如前所述, 脉间相位编码是一个 NP-hard 问题, 求解最优编码可能非常耗时, 因此想要收集大量样本, 且针对每一个样本都求解得到最优编码是非常困难的。而如果使用的标签是次优解, 则使用监督学习所训练出来的智能体将受限于数据集质量, 其输出的编码性能将难以超越样本标签。因此, 在解决获取大容量高质量数据集的困难之前, 监督学习的方法难以兼顾编码性能和泛化性。

尽管通过迭代求解获取最优编码比较困难, 但是要获取目标检测的相关指标 (例如虚警、漏检、交叉模糊函数等) 却是比较容易的, 这些数值指标均可以作为反馈, 供智能体改进编码策略。需要说明的是, 迭代求解法^[21]就是以交叉模糊函数作为优化目标, 将求解最优编码建模为优化问题。强化学习也可以看作是一种优化算法, 其优化目标就是最大化累计回报, 即使没有高质量标签, 也可以学习到高水平的策略。著名的 AlphaZero 就是完全不使用棋谱和人类棋手的对局数据, 仅通过自博弈达到超越顶尖职业棋手的水平^[42]。故在此我们用目标检测指标来计算奖励, 使用强化学习来优化智能体编码的抗干扰表现。

3.3.1 脉间相位编码的 MDP 建模

在此, 我们依旧把相位编码优化的执行过程建模为 MDP, 接下来依次介绍状态、动作、奖励函数的设定。动作的设定最为简单, 每个时间步输出的动作就是本次 frame 所要使用的相位编码, 设一个 frame 所含 chirp 数为 L , 则动作为 $\mathbf{a} = [\varphi_c^1, \varphi_c^2, \dots, \varphi_c^L], \varphi_c^i \in (-0.5, 0.5), 1 \leq i \leq L$ 。对于每一个 frame, 都会进行基于距离多普勒图的 CFAR 检测和峰值聚集 (Peak Clustering)^[70], 其结果与真实情况对比得到的虚警和漏检计算, 分别使用 fa 和 md 来表示虚警数和漏检数 (显然二者都是非负整数), 则奖励函数可表示为

$$r = \begin{cases} 1, & \text{fa} + \text{md} = 0 \\ -(\text{fa} + \text{md}), & \text{fa} + \text{md} > 0 \end{cases} \quad (3-6)$$

最后是状态 s_t 的设定，实际中我们无法保证能获得完全无干扰情况下的观测：对于未加入相位编码的观测结果，难以准确判断距离多普勒图中的峰值是真实目标还是干扰引起的虚假目标；对于加入了相位编码的观测结果，若在距离多普勒图上，干扰将真实目标掩盖，则仅凭单个 frame 的距离多普勒图，要获得准确的目标峰值和干扰能量的分布也并非易事。因此，这仍然可以看作是一个部分可观测的问题，我们同样在单步状态中加入多步观测以提供更多信息。接下来详细描述状态和观测的构造。

时间步 t （每个 episode 内， $t \in \mathbb{N}^+$ ）的状态 s_t 包含当前 episode 内在时间步 t 之前的所有单步观测（Observation）矩阵 $O_k, k < t$ 。 O_k 既包含该时间步的相位编码和目标检测结果，还包含对应的距离多普勒图的部分。设第 k 个时间步的距离多普勒图取模值表示为 RDM^k ，其在距离维索引为 i 、多普勒维索引为 j 的分量表示为 $\text{RDM}_{i,j}^k$ 。基于 RDM^k 分别对距离维和多普勒维进行两次一维的 CFAR 检测和峰值聚集，设最终检测出 n 个目标（包括真实目标和虚假目标），峰值聚集得到的矩阵为 PC^k ，其在距离维索引为 i 、多普勒维索引为 j 的分量为 $\text{PC}_{i,j}^k$ ，其取值为 1 或 0，代表该单元有或无目标。设在距离维上，有 m 个距离单元检测出了峰值，这些距离单元的索引为 $\{r_1, r_2, \dots, r_m\}$ ，而这些距离上对应最终检测出的目标数为 $\{n_1, n_2, \dots, n_m\}$ ，则有

$$\begin{cases} r_i \in \mathbb{N}^+, 1 \leq i \leq m \\ n_i \in \mathbb{N}, 1 \leq i \leq m \\ n = \sum_{i=1}^m n_i = \sum_{u,w} \text{PC}_{u,w}^k \end{cases} \quad (3-7)$$

则 O_k 为 $(2m+1) \times (L+3)$ 的矩阵，如表 3-1 所示。 O_k 包括两部分：相位编码和 RDM 检测结果，分别对应第 1 个向量和后 $2m$ 个向量。这 $(2m+1)$ 个向量的第 1 位为该观测的时间步索引。对于第 1 个相位编码相关的向量，其第 2 位固定填充 -1 作为标识，第 3 位为检测出来的目标总数，之后的 L 位为相位编码。后面的 $2m$ 个向量，每 2 个向量为一组，共 m 组。每组的两个向量分别包含了一个距离索引上的目标检测数量和距离多普勒图分量或峰值聚集结果分量。

对于每个 episode，雷达会先做一次无相位编码的发射和一次随机相位编码的发射，以获得初始观测，分别用 O_{-1} 和 O_0 表示，则在时间步 t ，状态 s_t 可表示为 $s_t = [O_{-1}, O_0, O_1, \dots, O_{t-1}]$ 。

到此，状态的构造也已介绍完毕，MDP 建模的主要内容已介绍完毕，折扣率 γ 将在仿真实验设置部分给出。

表 3-1 单个时刻观测矩阵的构造示意


k	-1	n	$\varphi_{\mathbf{c}}^1$	$\varphi_{\mathbf{c}}^2$	$\dots$	$\varphi_{\mathbf{c}}^L$
k	r_1	n_1	$\text{RDM}_{r_1,1}^k$	$\text{RDM}_{r_1,2}^k$	$\dots$	$\text{RDM}_{r_1,L}^k$
k	r_1	n_1	$\text{PC}_{r_1,1}^k$	$\text{PC}_{r_1,2}^k$	$\dots$	$\text{PC}_{r_1,L}^k$
k	r_2	n_2	$\text{RDM}_{r_2,1}^k$	$\text{RDM}_{r_2,2}^k$	$\dots$	$\text{RDM}_{r_2,L}^k$
k	r_2	n_2	$\text{PC}_{r_2,1}^k$	$\text{PC}_{r_2,2}^k$	$\dots$	$\text{PC}_{r_2,L}^k$
k	r_m	n_m	$\text{RDM}_{r_m,1}^k$	$\text{RDM}_{r_m,2}^k$	$\dots$	$\text{RDM}_{r_m,L}^k$
k	r_m	n_m	$\text{PC}_{r_m,1}^k$	$\text{PC}_{r_m,2}^k$	$\dots$	$\text{PC}_{r_m,L}^k$

3.3.2 强化学习算法设计

3.3.2.1 输出连续动作的强化学习算法

对于强化学习实现来说，本章所提出的脉间相位编码抗干扰策略的 MDP 模型与上一章模型的最大区别在于，上一章智能体输出的是离散的动作，而本章智能体需要输出连续动作。深度 Q-Learning 本质是基于价值函数的方法，无法处理连续的动作空间，而要输出连续动作，需要策略函数直接输出动作。包含策略函数的强化学习算法有两类：策略梯度法和演员-评论员（Actor-Critic）算法，在此我们选用目前最为主流的 Actor-Critic 算法。

Actor-Critic 算法有策略网络 (Actor) 和价值网络 (Critic) 两部分, 二者的关系如图 3-3 所示。其中, Actor 直接输出动作与环境交互, 并在 Critic 的指导下用策略梯度优化策略函数, 而 Critic 则通过 Actor 与环境交互收集的数据学习一个价值函数, 用来估计状态-动作的价值, 进而帮助 Actor 进行策略更新^[71]。

图 3-3 Actor-Critic 算法中策略网络和价值网络的关系图^[72]

在此，我们选择软演员-评论员（Soft Actor-Critic, SAC）算法^[62]，它是最先进的离线策略算法之一。SAC 总共有 5 个网络：有一个策略网络 θ ，两个价

值网络 ω_1, ω_2 和它们的目标网络 ω_1^-, ω_2^- ，这里对价值网络也是用了双网络技巧来减小过估计的影响，使训练更稳定。设经验池为 $\mathcal{D}$ ，则任意一个价值网络的损失函数为

$$L(\omega_i) = \mathbb{E}_{(s,a,r,s') \sim \mathcal{D}} \left[\left(Q_{\omega_i}(s, a; \theta) - \left(r + \gamma \min_{j=1,2} Q_{\omega_j^-}(s', a') - \alpha \log \pi_{\theta}(a'|s') \right) \right)^2 \right], i = 1, 2 \quad (3-8)$$

其中 $-\log \pi(a'|s')$ 为策略熵， α 为熵正则项系数。每次更新完价值网络后，目标网络将采取软更新的方式跟进：

$$\omega_i^- \leftarrow \tau \omega_i + (1 - \tau) \omega_i^-, i = 1, 2 \quad (3-9)$$

其中 $\tau \in (0,1)$ 为软更新的步长。

策略网络的损失函数可以表示为

$$L(\theta) = \mathbb{E}_{s \sim \mathcal{D}, a \sim \pi_{\theta}} \left[\alpha \log \pi_{\theta}(a'|s') - \min_{j=1,2} Q_{\omega_j}(s, a) \right] \quad (3-10)$$

对于连续动作空间，SAC 输出高斯随机策略，其策略网络的输出为此高斯分布的均值和标准差，实际动作从该高斯分布中采样得到。然而，直接从高斯分布中采样得到的动作对策略函数是不可导的，在此使用重参数化技巧（Reparameterization Trick），先从一个单位高斯分布 $\mathcal{N}$ 采样，再把采样值乘上标准差后加上均值，这样就可以认为是从策略高斯分布采样，并且该动作对于策略函数是可导的。我们将动作采样表示为 $a = f_{\theta}(\epsilon; s)$ ，其中 ϵ 是一个噪声随机变量。则式(3-9)可重写为

$$L(\theta) = \mathbb{E}_{s \sim \mathcal{D}, \epsilon \sim \mathcal{N}} \left[\alpha \log \pi_{\theta}(f_{\theta}(\epsilon; s)|s) - \min_{j=1,2} Q_{\omega_j}(s, f_{\theta}(\epsilon; s)) \right] \quad (3-11)$$

在上述两个损失函数中，熵正则项的作用就是最大化策略的随机性，增强探索，而其系数 α 则起着平衡探索和利用的重要作用：在最优动作不确定的某个状态下，熵的取值应该大一点；而在某个最优动作比较确定的状态下，熵的取值可以小一点。SAC 的作者提出了自动调整熵正则项的机制^[73]来更新 α ， α 的损失函数为

$$L(\alpha) = \mathbb{E}_{s \sim \mathcal{D}, a \sim \pi} [-\alpha \log \pi(a|s) - \alpha \mathcal{H}_0] \quad (3-12)$$

其中 $-\log \pi(a|s)$ 为策略熵， $\mathcal{H}_0$ 为目标熵，一般设置为动作的维度的相反数，即 $-\dim(\mathcal{A})$ 。注意，上式中 $\log \pi(a|s)$ 和 $\mathcal{H}_0$ 都是不可导的。则当策略熵低于目标熵时，对 $L(\alpha)$ 进行反向传播更新会使 α 增大，从而增大熵正则项的重要性，即增强探索；当策略熵高于目标熵时，对 $L(\alpha)$ 进行反向传播更新会使 α 减小，进而使得

策略训练时更专注于价值提升。

在此需要特别说明，我们在计算采样后对数动作概率上与一般做法不同。实际上，在采样得到动作（不妨设为 u ）通常会对其使用 $\tanh$ 以限制其分布范围，得到压缩后的动作 $a = \tanh(u)$ ，这会改变原本输出的动作的概率密度，因此在计算动作的对数概率时需要修正，设采样和最终输出的分布分别为 μ 和 π ，则有

$$\pi(a|s)da = \mu(u|s)du \quad (3-13)$$

$$\Rightarrow \pi(a|s) = \mu(u|s) \frac{du}{da} = \mu(u|s)(1 - \tanh^2 u)^{-1} \quad (3-14)$$

$$\Rightarrow \log \pi(a|s) = \log \mu(u|s) - \sum_{i=1}^{\dim(\mathcal{A})} \log(1 - \tanh^2 u_i) \quad (3-15)$$

而本章输出的相位实际上是周期性的，所以在压缩时使用正弦函数而非 $\tanh$ ，以体现周期性，同时为了使网络更好训练，还会对输出进行放缩以调整至合适的范围，有 $a = b \sin(u)$ ， b 即为放缩系数（不妨设 $b > 0$ ），则其对数概率计算为

$$\pi(a|s) = \mu(u|s) \frac{du}{da} = \mu(u|s)(b^2 - a^2)^{-\frac{1}{2}} \quad (3-16)$$

$$\log \pi(a|s) = \log \mu(u|s) - \frac{1}{2} \sum_{i=1}^{\dim(\mathcal{A})} \log(b^2 - a_i^2) \quad (3-17)$$

3.3.2.2 策略网络和价值网络设计

本章 MDP 建模的状态构造比上一章更为复杂，除了同样也加入了多步的观测来应对部分可观测问题，其每一步观测还包含多个向量。但更关键的在于，一步状态内的多步观测之间存在时序关系，然而单步观测内的各个向量都对对应同一个时间步，不存在时序上的先后关系，故单步观测并不适合使用 RNN 来处理。另外，在一个 episode 内，随着时间步向前推移，单步状态所包含的向量数将快速增加，且向量本身的维度也较大，而即使是最先进的 RNN，其记忆能力也有限，处理如此复杂的长序列将面临严重的遗忘问题，所以使用 RNN 处理本章 MDP 的状态并不是一个好的选择。

幸运的是，完全基于注意力（Attention）机制的 Transformer 模型^[74]可以较好地处理长序列。本章所使用的 Transformer 的结构如图 3-4 所示，它是基于编码器—解码器架构，由多层 Encoder 和 Decoder 堆叠，最后一层 Decoder 的输出再接 DNN 得到最终的输出。需要说明的是，原始的 Transformer 还会对输入的源和目标进行词嵌入和位置编码，并在 Decoder 中加入掩蔽多头注意力，这些操作

的目的是在自然语言处理中，将词向量从原始的高维稀疏空间变换到低维稠密空间，标识各词向量间在文本中的相对位置，并确保训练过程中输入和输出在时间上的因果性。然而，本章的状态构造已包含时序上的标识，各向量的各个分量均有非常直接的物理意义，已处于低维稠密空间（相对于自然语言处理中的词表），且每一时间步的状态符合时间上的因果性（在智能体输出动作后，才进行信号仿真并更新状态，在此之前智能体无从获知尚未发生的状态转移），故不使用词嵌入、位置编码和掩蔽多头注意力，在此省略。




图 3-4 本章所用 Transformer 的结构示意图

Transformer 的单个注意力头使用了缩放点积注意力（Scaled Dot-Product Attention）。注意力函数的输入一般分为两部分，即查询（Query）和键-值（Key-Value）对，而缩放点积注意力则要求查询和键具有相同的长度。设查询为 $\mathbf{Q} \in \mathbb{R}^{n \times d_q}$ ，键为 $\mathbf{K} \in \mathbb{R}^{m \times d_k}$ ，值为 $\mathbf{V} \in \mathbb{R}^{m \times d_v}$ ，即共有 n 个查询和 m 个键-值对，单个查询、键和值的长度分别为 d_q 、 d_k 和 d_v ，且 $d_q = d_k$ 。则它们的缩放点积注意力函数 f 表示为

$$f(\mathbf{Q}, \mathbf{K}, \mathbf{V}) = \text{softmax}\left(\frac{\mathbf{Q}\mathbf{K}^T}{\sqrt{d}}\right) \mathbf{V} \in \mathbb{R}^{n \times d_v} \quad (3-18)$$

其中 $\mathbf{K}^T$ 表示 $\mathbf{K}$ 的转置。而对于单个查询 $\mathbf{q} \in \mathbb{R}^{d_q}$ 、键 $\mathbf{k} \in \mathbb{R}^{d_k}$ 和值 $\mathbf{v} \in \mathbb{R}^{d_v}$ ，多头

注意力（设共有 h 个头）的每个注意头 $\mathbf{h}_i, i = 1, 2, \dots, h$ 的计算为

$$\mathbf{h}_i = f\left(\mathbf{W}_i^{(q)}\mathbf{q}, \mathbf{W}_i^{(k)}\mathbf{k}, \mathbf{W}_i^{(v)}\mathbf{v}\right) \in \mathbb{R}^{p_v} \quad (3-19)$$

其中， $\mathbf{W}_i^{(q)} \in \mathbb{R}^{p_q \times d_q}$ 、 $\mathbf{W}_i^{(k)} \in \mathbb{R}^{p_k \times d_k}$ 和 $\mathbf{W}_i^{(v)} \in \mathbb{R}^{p_v \times d_v}$ 分别是对查询、键和值计算注意力前进行线性变换的全连接层的参数。多头注意力的输出需要经过另一个线性转换，它对应着 h 个头连结后的结果，其参数是 $\mathbf{W}_0 \in \mathbb{R}^{p_o \times hp_v}$ ，其输出为

$$\mathbf{W}_0 \begin{bmatrix} \mathbf{h}_1 \\ \mathbf{h}_2 \\ \vdots \\ \mathbf{h}_h \end{bmatrix} \in \mathbb{R}^{p_o} \quad (3-20)$$

在多头注意力之后，输出还会经过非线性变换、残差连接和层规范化，最终的输出形状为 $n \times d_v$ 。特别地，在原始的 Transformer 中，在注意力、残差连接和层规范化计算时会使用 Dropout，然而 Dropout 会影响强化学习训练的稳定性，故本文均不使用。

Transformer 的 Encoder 完全使用自注意力（Self-Attention）机制，即其输入同时作为查询、键和值，而 Decoder 则使用交叉注意力（Cross-Attention）机制（掩蔽多头注意力使用的是自注意力机制，但本章不涉及），解码器中的每一层 Decoder 输入的查询为上一层的输出（对于第一层 Decoder，则为输入的目标），而键和值为编码器最后一层 Encoder 的输出。

至此 Transformer 已简单介绍完毕，接下来介绍本章策略网络和价值网络的构造。它们的结构如图 3-5 所示，二者均可分为信息提取模块和决策模块。信息提取模块由多层 Encoder 堆叠而成，其输入即为单步状态，输出状态的信息提取编码，作为决策模块输入的一部分。决策模块则由一个或多个 Decoder 堆叠，后接 DNN 而成，解码器的输入分两部分，一部分是信息提取模块的输出，作为 Decoder 输入的键和值，另一部分为全 1 向量或待评价动作，作为 Decoder 输入的查询。具体地，对于策略网络，解码器输入的查询为一个全 1 向量，其输出再经过一个 DNN，最后接出两个输出头，分别输出高斯随机策略的均值 μ 和标准差 σ ；对于价值网络，解码器输入的查询为待评价动作经过一层全连接层进行线性变换得到的向量（因为动作的维数少于状态的单个向量的维数，故需要经线性变换将长度补齐），最后 DNN 仅输出一个值，即为整个网络输入的状态-动作对的价值估计。




图 3-5 网络结构示意图, (a)策略网络 (b)价值网络

3.4 仿真实验

本节将用仿真实验来验证本章所提出的抗干扰策略的有效性, 接下来介绍仿真实验的设置及结果。

3.4.1 实验设置

3.4.1.1 雷达及仿真场景设置

雷达的参数列在表 3-2 中, 本章的干扰源和受干扰雷达使用同一套扫频参数, 且中心频率和发射时间固定。

表 3-2 雷达参数设置

参数	取值
中心频率 [GHz]	77.0
调频斜率 [MHz/us]	10
扫频时长 [us]	50
带宽 [MHz]	500
脉冲重复周期 [us]	60
每帧 chirp 数	128
采样频率 [MHz]	20
最大探测距离 [m]	120
目标回波最大延迟 [us]	0.8
目标回波最大差频 [MHz]	8

信号仿真参数已列在表 3-3 中。本章中, 训练和测试时的设置相同。使用最简单直接的场景设置, 目标和干扰数均设为 1, 并使干扰和目标在距离多普勒图的距离维上很靠近, 提高仿真时的采样效率, 干扰到达受干扰雷达接收机相对于受干扰雷达参考信号的延迟时间 τ_{intf} 为

$$\tau_{\text{intf}} = \frac{2d_{\text{target}}}{c} \quad (3-21)$$

其中 d_{target} 为目标与受干扰雷达的相对距离。

表 3-3 仿真设置

参数		取值	
		训练	测试
点目标	数量	1	
	幅度	$\mathcal{U}(0.5, 1.5)$	
	距离 [m]	$\mathcal{U}(0.3, 120)$	
	相对受干扰雷达的速度 [m/s]	$\mathcal{U}(-16, 16)$	
	反射引起的相位变化	$\mathcal{U}(-\pi, \pi)$	
干扰	数量	1	
	幅度	$\mathcal{U}(5, 20)$	
	相对受干扰雷达的速度 [m/s]	$\mathcal{U}(-32, 32)$	
光速 [m/s]		3×10^8	
SNR [dB]		10	
每个 episode 的时间步数		20	10

在实际实施时,可以对雷达的每个 frame 都输出一组相位编码,所以本章的相位编码优化也是一个持续性的任务,我们限制了一个 episode 的最大时间步数,并在此假定场景是静态的,即一个 episode 内,目标和干扰在距离维上不移动。

本章的实验设计 CFAR 检测和峰值聚集,CFAR 检测是对距离维和多普勒维分别使用一维 CA-CFAR^[50],再取二者结果的交集,其参数列在表 3-4 中,峰值聚集使用 4-邻接,保留临界区域最大值点。

表 3-4 一维 CA-CFAR 检测的参数

参数		取值
距离维	训练单元数	32
	保护单元数	2
多普勒维	训练单元数	8
	保护单元数	2
虚警率		0.001

3.4.1.2 强化学习设置

强化学习的通用参数设置如表 3.5 所示。由于在雷达设置中,一个 frame 的 chirp 数设为 128,所以智能体动作的维数也为 128,若以表 3.1 所示的观测构造,则状态的维数就是 131。然而,131 是个质数,为了实现多头注意力,我们将在状态的每个向量的第 1 位前再补一位,固定填充 0,从而将状态的维数补长为 132。另外,我们还规定,当经验池收集的样本数达到 1000 后,才开始进行经验回放更新智能体的策略网络和价值网络。训练中使用 α 的对数值可以增强训练的稳定性^[71],其根据式(3-12)进行反向传播更新时,由于只需要更新 α 这一个参数,

故不额外使用优化器。

策略网络的参数设置如表 3-6 所示。特别说明其中的 DNN，FCL_1 是 DNN 的第一层，其输入为解码器的输出，其使用的激活函数为 ReLU，后分别接 FCL_mu 和 FCL_std（即此二者的输入均为 FCL_1）。FCL_mu 直接输出高斯分布的均值，FCL_std 的输出还要经过 softplus 激活函数：

$$\text{softplus}(x) = \log(1 + e^x) \quad (3-22)$$

将输出的取值范围调整为正数，作为高斯分布的标准差（显然，这里假设动作各个分量之间是独立的）。

表 3-5 强化学习通用参数设置

参数项	取值
$\dim(\mathcal{A})$	128
$\dim(\mathcal{S})$	132
目标熵	-128
熵正则项系数 α 初始值	0.01
α 更新的学习率	1×10^{-4}
γ	0.99
经验池容量	2×10^5
经验回放批大小	64
经验回放所需最小经验池大小	1000
目标网络软更新步长	0.01

表 3-6 策略网络的参数设置

参数项			取值
信息提取模块	编码器	Encoder 层数	2
		Encoder 注意力头数	6
决策模块	解码器	Decoder 层数	1
		Decoder 注意力头数	6
	DNN	层	神经元数量
		FCL	264
		FCL_mu	128
		FCL_std	128
总参数量			523900
学习率			1×10^{-4}

价值网络的参数设置列于表 3-7 中。其中，FCL_0 为解码器前的线性变换层，其作用是处理待评价动作，调整其向量长度以作为 Decoder 交叉注意力的输入查询，为了完整保留动作信息，FCL_0 后不使用激活函数进行非线性变换。DNN 的输入为解码器输出，其第一层全连接层 FCL_1 后使用激活函数 ReLU，第二层全连接层 FCL_2 则直接输出一个值，作为整个价值网路输入的状态-动作对的价

值估计。

策略网络和价值网络均使用 Adam^[75] 优化器进行反向传播更新，使用的深度学习平台为 PyTorch 2.0。注意到，二者的学习率并不相同，这是因为价值网络直接接收环境的反馈（即奖励）来学习正确的价值函数，而策略网络则依赖该价值函数来更新策略。从对客观环境形成正确认识的先后顺序来看，只有更准确的价值函数才能帮助策略网络学习更优的策略，因此往往需要价值网络比策略网络更快收敛，故在此价值网络的学习率设置得更高。

表 3-7 价值网络的参数设置

参数项			取值
信息提取模块	编码器	Encoder 层数	2
		Encoder 注意力头数	6
决策模块	解码器	Decoder 层数	1
		Decoder 注意力头数	6
	层		神经元数量
	FCL_0		132
	DNN	FCL_1	8
		FCL_2	1
总参数量			439049
学习率			3×10^{-4}

在强化学习的训练和测试中，除了执行相位编码优化的智能体（称为 Optimized），还设有两个对照组，分别是无相位编码（也可认为是相位编码值均为 0，称为 Zeros）和均匀随机相位编码（称为 Random）。

3.4.2 实验结果

智能体（即 Optimized）训练了 20000 个 episode，共 400000 个时间步，训练过程中各指标变化如图 3-6 所示。需要说明的是，图 3-6 中各指标均是经过平滑后的，对于每一个点，我们取其前后最多各 250 个点，最多共 500 个点（即 500 个 episode）的原始数据进行平均，得到该点的平滑后的数值。累积回报是直接反映智能体的强化学习效果的指标，其计算依据式(2-40)，而虚警数和漏检数都是对每个时间步平均的（并非平滑处理中的平均）。

可以看到，在训练过程中，Optimized 的累积回报总体呈上升趋势，说明其策略总体是在改进的。对于虚警数：Zeros 一直处于 0.9 以上，由于实验中目标和干扰均只有 1 个，所以可以认为在无编码的情况下，相干干扰极大概率导致虚警；Random 的虚警数则几乎一直为 0，这也证明了随机相位编码对抗相干干扰，消除虚警有非常好的效果；Optimized 的虚警数前期与 Random 一致，中后期出现了明显的波动。对于漏检数：Zeros 一直在 0.04 附近波动（均值为 0.0393），




图 3-6 训练结果, (a)平滑后的单个 episode 的累积回报 (b)平滑后的单步平均虚警数 (c)平滑后的单步平均漏检数

这实际上是当干扰在多普勒维和目标比较接近时,掩盖目标导致的漏检,更进一

步，多普勒维共 256 个单元，由此可以推测出，在多普勒维，当干扰中心距目标中心 5 个单元以内时 ($5/128 \approx 0.039$)，就会掩盖目标导致漏检；Random 的漏检数大多处于 0.3~0.35 之间；Optimized 的漏检数早期与 Random 非常接近，随着训练的进行，漏检数总体呈明显下降趋势，当然，期间也出现了波动。

除了训练结束时的 Actor 和 Critic 的网络模型，我们还在训练中每 1500 个 episode 保存一次模型的参数。对于保存下来的每一组模型，我们都对其进行了 5000 个 episode 的测试。实际上，在测试时，只需要 Actor 进行推理输出动作，不需要 Critic。在所有保存的模型中，训练中的第 7500 个 episode 和第 16500 个 episode 后保存的模型（分别称为 Optimized-7500 和 Optimized-16500）在测试中表现最好，二者的测试结果如图 3-7 所示。




图 3-7 测试结果，对所有 episode 平均，(a)单个 episode 内每个时间步的平均虚警数 (b)单个 episode 内每个时间步的平均漏检数

对于虚警数，Zeros、Random、Optimized-7500 和 Optimized-16500 在单个 episode 内都比较稳定，分别为 0.95、 2×10^{-5} 、 2×10^{-5} 和 0。其中，Zeros 和 Random 保持了训练时的表现，Optimized-7500 与 Random 持平，而 Optimized-16500 则比 Random 更低，完全消除了虚警。

对于漏检数，Zeros、Random、Optimized-7500 和 Optimized-16500 在单个 episode 内每个时间步的平均漏检数分别为 0.0387、0.3126、0.1857 和 0.1846。其中 Zeros、Random 和 Optimized-7500 每个时间步的漏检数都比较稳定，而 Optimized-16500 第一个时间步的平均漏检数为 0.2066，而后迅速下降，在第三个时间步取得 0.1806，后一直稳定。

相较于 Random，Optimized-7500 和 Optimized-16500 在虚警的表现上均持平甚至更好，同时还将漏检数降低了至少 40%，这样的结果足以证明本章所提出的

基于深度强化学习的脉间相位编码策略对抗相干干扰的有效性。此外, Optimized-7500 和 Optimized-16500 还有少许区别。Optimized-7500 能够在第一个时间步就取得比较稳定且良好的结果, 其时效性非常优秀, 这得益于 Transformer 强大的信息提取和函数拟合能力, 同时这也证明了我们的静态场景假设是合理的。Optimized-16500 虽然要到第三个时间步才能得到最低的漏检数, 但相较于 Random, 其第一步的结果也低 34%, 且从第三个时间步开始的漏检数比 Optimized-7500 更低, 更重要的是, 它完全消除了虚警。

3.5 本章小结


在本章中, 我们为 FMCW 汽车雷达提出了一种非合作式的连续值脉间相位编码的策略来对抗相干干扰, 通过相位编码来调整干扰的能量分布, 从而同时避免相干干扰引起的虚警和漏检。我们将所提出的策略的执行过程建模为 MDP, 并使用输出连续动作的 SAC 算法来进行策略优化。本章 MDP 的状态构造更加复杂, 因此我们使用了 Transformer 来处理。在仿真实验中, 本章所提出的脉间相位编码抗干扰策略表现出了良好的性能。相较于无编码的情况, 该策略几乎完全消除了相干干扰可能引起的虚警; 而相较于随机值相位编码, 该策略能将相干干扰导致的漏检数量减少 40%。同时, 本章所提出的相位编码策略具有较好的时效性, 当面对干扰时, 在 3 个 frame 内即可取得稳定的抗干扰效果。更重要的是, 本章所提出的方法不需要额外的干扰感知和识别的步骤, 构造状态的观测信息完全取自常规的雷达信号处理的中间步骤的结果, 故该策略基于现有的主流的汽车雷达硬件即可实施。

第四章 面对非相干干扰的多域联合抗干扰策略

本章将先简单介绍汽车雷达的非相干干扰。然后，提出一种基于避开想干扰策略改进的多域联合抗干扰策略。接着，给出多域联合抗干扰策略的 MDP 建模和优化策略的强化学习算法设计。最后，将展示验证本章所提出的抗干扰策略的仿真实验的设置和结果。

4.1 非相干干扰场景

前两章已分别给出了避免相干干扰进入雷达通带和消除雷达通带内相干干扰影响的策略，两种策略结合可以形成比较完备的对抗相干干扰的方法。然而，在实际中，为了满足不同探测场景的需求，汽车雷达有长程、中程和短程雷达之分，它们的带宽、调频斜率、扫频时长各不相同，以实现不同的探测距离和距离分辨力^[53]。当同一区域内处于工作状态的汽车雷达数量较为密集时，不同功能的雷达之间不可避免地会形成非相干干扰。与相干干扰不同的是，非相干干扰在 **dechirp** 处理后能量是分散在频谱上的，如图 4-1 所示，其影响主要体现在提高噪声门限，掩盖真实目标。






图 4-1 有无非相干干扰的情况下，距离多普勒图以及 CFAR 检测的结果对比，(a)无干扰的距离多普勒图 (b)无干扰的 CFAR 检测结果 (c)有干扰的距离多普勒图 (d)有干扰的 CFAR 检测结果 (e)无干扰情况下，雷达接收信号在距离多普勒域的能量分布 (f)有干扰情况下，雷达接收信号在距离多普勒域的能量分布

4.2 面对非相干干扰的多域联合抗干扰策略

从理论上，前两章所提出的方法对非相干干扰并不会有很好的效果。首先，非相干干扰与受干扰雷达参考信号的相关性很弱，其能量在距离多普勒域本身就是分散的，因此脉间相位编码难以奏效。其次，非相干干扰处于受干扰雷达通带内的干扰样式虽与目标回波不一致，但仍然存在周期性，其在时域上的规律相较于相干干扰更加复杂，如图 4-2 所示，因此直接使用第二章的时域策略也难以取得效果。




图 4-2 有非相干干扰的情况下，雷达接收信号中的连续 8 个 chirp 的 STFT 结果

本章在第二章所提出的时、频域联合策略的基础上，加入调频斜率的调整，形成多域联合的抗干扰策略来应对非相干干扰。尽管已有研究人员提出改变调频斜率来避开干扰^[45]，但是该方法仅与频域策略结合，其原理是通过调整调频斜率

改变雷达的带宽，再配合中心频率的调整减少干扰进入通带的比例。而本章的原理则是通过调整调频斜率，将非相干干扰转化为相干干扰，再结合时、频域联合策略避开干扰。同时，为了处理非相干干扰在时域上更复杂的变化规律，本章将三个扫频参数的调整设置为连续取值，以实现更精细的控制。

4.3 基于深度强化学习的多域联合抗干扰策略的实现

我们完全借鉴第二章所给出的抗干扰策略执行过程及其 MDP 建模，在此给出状态、动作和奖励的设置。雷达的参数状态为 $[\hat{f}_c, t_d, \hat{K}]$ 包含雷达的中心频率 $\hat{f}_c$ 、发射时间 t_d 和调频斜率 $\hat{K}$ ，动作直接参照第二章的方法定义，在此不再重复。奖励由两部分组成，包括由 SINR 计算的奖励 r_s 和由重叠度（干扰进入通带的信号长度占 beat signal 总长度的比例，用 overlap 表示）计算的奖励 r_o ：

$$r = r_s + r_o \quad (4-1)$$

$$r_s = \begin{cases} \beta_1 \text{SINR}, & \text{SINR} \leq \text{SINR}_1 \\ \frac{\beta_2 \text{SINR}}{\text{SINR} + \text{SINR}_2}, & \text{SINR} > \text{SINR}_1 \end{cases} \quad (4-2)$$

$$r_o = \beta_3 \text{overlap} \quad (4-3)$$

其中 SINR_1 是 SINR 奖励正负的判断阈值，实际中可根据目标探测的要求设定。 SINR_2 表示 SINR 取值的一个上界，用于奖励数值归一化，它通常与噪声等级（如 SNR）有关。 β_1 、 β_2 和 β_3 都是奖励权重系数，因各指标的量纲和取值不同（SINR 的取值通常在 $-20 \sim 10$ ，而 overlap 通常在 0.03 以下），所以用它们计算奖励时需要调整数值。由于非相干干扰的效果主要是抬高噪声门限，这与目标检测性能直接相关^[3]，故在此我们即以 SINR 和重叠度来衡量策略的抗干扰性能。

状态 $\mathbf{s} = [\mathbf{O}_{\text{intf}}, \mathbf{O}_r]$ 由干扰信息矩阵 $\mathbf{O}_{\text{intf}}$ 和雷达发射观测矩阵 $\mathbf{O}_r$ 组成。在此我们假设雷达通过额外的模块和计算获取了当前整个可用频带内所有干扰的参数（当然，干扰参数的估计不在本文的讨论范畴，尽管这是一个很强的条件）。假设共有 n 个干扰源，则 $\mathbf{O}_{\text{intf}}$ 的构造如表 4-1 所示。其第 i 个向量表示第 i 个干扰源的参数，包括了干扰的相对强度 A_{intf_i} 、中心频率 f_{intf_i} 、相对延迟时间 $t_{d\text{intf}_i}$ 、调频斜率 K_{intf_i} 、带宽 B_{intf_i} 、单次扫频时长 T_{swintf_i} 和 chirp 重复周期 T_{cintf_i} ，而干扰向量的

表 4-1 干扰信息矩阵的构造

-1	A_{intf_1}	f_{intf_1}	$t_{d\text{intf}_1}$	K_{intf_1}	B_{intf_1}	T_{swintf_1}	T_{cintf_1}
-1	A_{intf_2}	f_{intf_2}	$t_{d\text{intf}_2}$	K_{intf_2}	B_{intf_2}	T_{swintf_2}	T_{cintf_2}
$\vdots$							
-1	A_{intf_n}	f_{intf_n}	$t_{d\text{intf}_n}$	K_{intf_n}	B_{intf_n}	T_{swintf_n}	T_{cintf_n}

第 1 位固定填充-1 作为标识。

对于一个 episode 内的第 k 个时间步，其雷达发射观测矩阵包含了初始发射观测（可认为是第 0 个时间步的发射观测）和前 $(k-1)$ 个时间步的发射观测，如表 4-2 所示。每个向量表示一个时间步的观测，其第 1 位为时间步序号，第 2 位固定填充 1，之后各位依次为雷达的中心频率、发射时间、调频斜率、带宽、单次扫频时长和 PRI。虽然在此 T_{sw} 和 T_c 不做调整，其取值是固定的，但我们还是留出了接口。需要注意的是，当雷达的调频斜率调整时，其带宽和低通滤波器截止频率也要做相应调整，参考式(2-2)和式(2-4)。

表 4-2 雷达发射观测矩阵的构造

0	1	$\hat{f}_{c0}$	t_{d0}	$\hat{K}_0$	B_0	T_{sw0}	T_{c0}
1	1	$\hat{f}_{c1}$	t_{d1}	$\hat{K}_1$	B_1	T_{sw1}	T_{c1}
$\vdots$							
$k-1$	1	$\hat{f}_{c(k-1)}$	$t_{d(k-1)}$	$\hat{K}_{(k-1)}$	$B_{(k-1)}$	$T_{sw(k-1)}$	$T_{c(k-1)}$

这样，该时间步的状态矩阵的形状为 $(n+k) \times 8$ 。其中， $\mathbf{O}_{\text{intf}}$ 中的各个向量在时序上是平行的，而 $\mathbf{O}_r$ 的各个向量在时序上有明显的先后关系。因此，本章仍然沿用第三章的做法，使用 SAC 算法，并使用 Transformer 来构造策略网络和价值网络，它们同样使用图 3-5 所示的结构。

本章的强化学习算法设计大部分都与第三章的完全一致，相同的内容在此不再赘述，唯一需要说明的是 SAC 算法中 Actor 动作采样后的对数概率计算。为了使网络更好训练，在此亦对输出进行放缩和偏置以调整至合适的范围，有 $\mathbf{a} = b_1 \tanh(u) + b_2$ ， b_1 和 b_2 分别为放缩系数和偏置，尽管如此，其对数概率计算可直接使用式(3-85)。

4.4 仿真实验

本节将用仿真实验来验证本章所提出的抗干扰策略的有效性，接下来介绍仿真实验的设置及结果。

4.4.1 实验设置

4.4.1.1 雷达及仿真场景设置

受干扰雷达的参数列在表 4-3 中，受干扰雷达可以在区间内任意取值。干扰源雷达的参数列在表 4-4 中，仿真参数设置如表 4-5 所示，在此我们也假定场景为静态的，在每个 episode 开始前，都对目标和干扰进行随机初始化，随机初始化的参数所服从的分布也已列在表 4-4 和表 4-5 中。

表 4-3 受干扰雷达参数设置

参数	取值
中心频率 $\hat{f}_c$ [GHz]	[76, 77]
发射时间 t_d [us]	[0, 60]
调频斜率 $\hat{K}$ [MHz/us]	[8, 12]
扫频时长 [us]	50
带宽 [MHz]	400 ~ 600
脉冲重复周期 [us]	60
每帧 chirp 数	128
采样频率 [MHz]	20
最大探测距离 [m]	120
目标回波最大延迟 [us]	0.8
目标回波最大差频 [MHz]	6.4 ~ 9.6

表 4-4 干扰源雷达参数设置

参数	取值
中心频率 [GHz]	$\mathcal{U}(76, 77)$
调频斜率 [MHz/us]	$\mathcal{U}(5, 15)$
扫频时长 [us]	$\mathcal{U}(40, 60)$
带宽 [MHz]	200 ~ 900
脉冲重复周期 [$\times$ 扫频时长]	$\mathcal{U}(1.2, 2.0)$
每帧 chirp 数	128
采样频率 [MHz]	20

表 4-5 仿真设置

参数		取值	
		训练	测试
点目标	数量	$\mathcal{U}\{1, 2, 3\}$	
	幅度	$\mathcal{U}(0.5, 1.5)$	
	距离 [m]	$\mathcal{U}(0.3, 120)$	
	相对受干扰雷达的速度 [m/s]	$\mathcal{U}(-16, 16)$	
	反射引起的相位变化	$\mathcal{U}(-\pi, \pi)$	
干扰	数量	$\mathcal{P}(8)$	4 ~ 12
	幅度	$\mathcal{U}(20, 100)$	
	相对受干扰雷达的速度 [m/s]	$\mathcal{U}(-32, 32)$	
	延迟时间 [us]	$\mathcal{U}(0, 60)$	
光速 [m/s]		3×10^8	
SNR [dB]		10	
每个 episode 的时间步数		20	

4.4.1.2 强化学习设置

在训练和测试中设有以下雷达智能体：

- 1) Radar-Fixed: 智能体的参数状态($\hat{f}_c, t_d, \hat{K}$)固定为(76.5 GHz, 0, 10 MHz/us)。

- 2) Radar-F: 智能体在 Radar-Fixed 的基础上只调整中心频率。
- 3) Radar-T: 智能体在 Radar-Fixed 的基础上只调整发射时间。
- 4) Radar-FT: 智能体在 Radar-Fixed 的基础上只调整中心频率和发射时间。
- 5) Radar-FS: 智能体在 Radar-Fixed 的基础上只调整中心频率和调频斜率。
- 6) Radar-TS: 智能体在 Radar-Fixed 的基础上只调整发射时间和调频斜率。
- 7) Radar-FTS: 智能体执行本章所提出的多域联合策略, 整中心频率、发射时间和调频斜率均可调整。

值得一提的是, 因为单独调整调频斜率只能改变带宽, 要尽可能多地避开干扰只能将调频斜率调至最低值, 通过减小带宽实现, 这种做法会严重降低雷达目标探测的性能, 意义不大, 因此这里没有设置只调整调频斜率的对照组。

强化学习的通用参数设置如表 4-6 所示。需要说明的是, 除了 Radar-FTS, 其他智能体地动作维数均小于 3。由于使用 SAC 算法涉及动作熵的计算, 所以此处的做法是调整策略网络最终输出的维数, 而不是简单地屏蔽不可用的动作维度, 同时目标熵也相应调整, 取值为 $-\dim(\mathcal{A})$ 。

表 4-6 强化学习通用参数设置

参数项	取值
$\dim(\mathcal{A})$	3
$\dim(\mathcal{S})$	8
目标熵	-3
熵正则项系数 α 初始值	0.01
α 更新的学习率	1×10^{-4}
γ	0.99
$(\beta_1, \beta_2, \beta_3)$	(0.1, 2, -10)
$(\text{SINR}_1, \text{SINR}_2)$ [dB]	(0, 10)
经验池容量	2×10^5
经验回放批大小	64
经验回放所需最小经验池大小	1000
目标网络软更新步长	0.01

策略网络和价值网络的参数设置分别列于表 4-7 和表 4-8 中, 此处的设计构造与第三章几乎完全一致, 仅在输入输出维数、神经元数量、注意力头数以及相

表 4-7 策略网络的参数设置

参数项			取值
信息提取模块	编码器	Encoder 层数	2
		Encoder 注意力头数	4
决策模块	解码器	Decoder 层数	1
		Decoder 注意力头数	4

续表 4-7 策略网络的参数设置

参数项			取值
决策模块	DNN	层	神经元数量
		FCL	16
		FCL_mu	3
		FCL_std	3
总参数量			1950
学习率			1×10^{-4}

应的总参数量上存在数值的差别,故在此不再对策略网络和价值网络进行详细的描述,相关细节参考第三章。

表 4-8 价值网络的参数设置

参数项			取值
信息提取模块	编码器	Encoder 层数	2
		Encoder 注意力头数	4
决策模块	解码器	Decoder 层数	1
		Decoder 注意力头数	4
	层		神经元数量
	FCL_0		8
	DNN	FCL_1	16
		FCL_2	1
总参数量			1897
学习率			3×10^{-4}

4.4.2 实验结果

所有智能体一起训练了 20000 个 episode, 共 400000 个时间步, 训练过程中各指标变化如图 4-3 所示, 各指标的平滑方法与第三章相同。在本次训练中, 所有智能体基本都在 5000 个 episode 内达到收敛的结果, 仅 Radar-FS 和 Radar-FTS 存在一定程度的波动。从训练结果来看, Radar-T 与 Radar-Fixed 的三项性能曲线几乎全程完全重合, Radar-T 完全没有改善; Radar-TS 比 Radar-T 更好一些; Radar-F 和 Radar-FT 全程都非常接近, 它们都明显好于 Radar-TS; Radar-FS 在前期比 Radar-F 和 Radar-FT 更好, 而从 7500 个 episode 以后稍恶化并有上下波动, 其性能曲线也与 Radar-F 和 Radar-FT 比较接近; Radar-FTS 相较于其他智能体, 用了更长的时间达到相对稳定的状态, 其中后期存在一定波动, 这是由于只有它能调整三个参数, 搜索空间最大, 但其性能也是所有智能体中最好的, 且明显优于 Radar-FS。

由于最后所有智能体都收敛了, 所以我们直接取训练完成后保存的模型参数作为测试用的智能体模型参数。在测试中, 干扰数的取值为 4 到 12, 在每个干

扰数下，我们都进行了 1000 个 episode 的测试，每个 episode 的最大时间步数与训练时保持一致，为 20 步。对所有干扰数的统计结果如表 4-9 所示，每个干扰数下的测试结果如图 4-4 所示。




图 4-3 训练结果, (a)平滑后的单个 episode 的累积回报 (b)平滑后的单步平均 SINR (c)平滑后的单步平均重叠度

测试结果与训练结果一致,在所有智能体中,Radar-FTS 的抗干扰性能最好,相比其他智能体,它在平均 SINR 上的领先在 2 ~ 8 dB,而在平均重叠度上的降低其他智能体,它在平均 SINR 上的领先在 2 ~ 8 dB,而在平均重叠度上的降低在 18.75%~66.54%,这证明本章所提出的多域联合抗干扰策略是有效的。同时注意到,所有不调整调频斜率的策略在加入时域策略后,其抗干扰性能并没有提升,具体的有 Radar-Fixed 与 Radar-T、Radar-F 与 Radar-FT,这证明无调频斜率配合的时域策略对非相干干扰完全无效。而在执行调频斜率调整的基础上加入时域策略,即从 Radar-FS 到 Radar-FTS,抗干扰性能有明显的提升,这验证了发射时间和调频斜率联合调整对抗相干干扰的原理,即先通过调整调频斜率将非相干干扰转化为相干干扰,在调整发射时间来避开。综上,仿真实验完全验证了本章所提出的多域联合抗干扰策略的原理和有效性。

表 4-9 测试的统计结果

智能体	平均 SINR [dB]	重叠度
Radar-Fixed	-18.79	0.0272
Radar-F	-13.41	0.0137
Radar-T	-18.79	0.0272
Radar-FT	-13.59	0.0140
Radar-FS	-12.64	0.0112
Radar-TS	-17.78	0.0219
Radar-FTS	-10.39	0.0091




图 4-4 各干扰数下的测试结果, (a)平均 SINR (b)平均重叠度

4.5 本章小结

在本章中，我们为 FMCW 汽车雷达提出了一种非合作式的多域联合抗干扰策略，通过调整中心频率、发射时间和调频斜率来减少非相干干扰进入通带的比例，从而提高 SINR（相应地，降低漏检率）。我们将所提出的策略的执行过程建模为 MDP，并使用输出连续动作的 SAC 算法来进行策略优化。本章 MDP 的状态构造同样很复杂，因此我们亦使用了 Transformer 来处理。仿真实验验证了本章所提出的多域联合抗干扰策略的有效性，相较于时、频域策略或频域结合调频斜率的策略，多域联合策略在 SINR 上的提升超过 2 dB，干扰进入雷达通带的比例降低了超过 18%。同时，通过对比实验，我们分析了各个域的单独策略相互组合的效果，验证了发射时间和调频斜率联合调整的原理的有效性，这部分结论亦可为其他场景下抗干扰方法设计提供参考。

第五章 总结与展望

5.1 总结

汽车雷达间的相互干扰会严重影响雷达的探测能力,进而降低车辆行驶的安全性。本文针对该问题研究分析了雷达及干扰的信号模型,建立了多样的干扰场景及仿真方法,根据干扰原理提出了三种非合作式的抗干扰策略,它们分别是:针对相干干扰的时、频域参数联合调整的抗干扰策略;针对相干干扰的连续值脉间相位编码抗干扰策略;针对非相干干扰的多域参数联合调整的抗干扰策略。通过大量仿真实验,我们验证了这些方法的有效性。本文具体工作内容如下:

(1) 针对相干干扰的时、频域参数联合调整的抗干扰策略

建立了雷达及干扰的信号模型和运动场景下的仿真方法;提出了在时域和频域非合作式的调整参数以避免相干干扰的策略;将所提出的时、频域联合抗干扰策略的执行过程建模为马尔可夫决策过程,并设计了深度强化学习算法来求解最优策略;通过仿真实验,验证了时、频域联合策略在面对相干干扰时优秀的抗干扰性能,相较于单一域的参数调整,时、频域联合策略能显著提升干扰避开率和信干噪比,获得更好的抗干扰表现;引入动作代价约束机制,进一步提升了抗干扰策略的鲁棒性和可实施性。

(2) 针对相干干扰的连续值脉间相位编码抗干扰策略

分析了相位编码对抗相干干扰的原理,建立了脉间相位编码抗干扰的模型;提出了非合作式的随机连续值脉间相位编码及其优化的策略;将所提出的脉间相位编码抗干扰策略的执行过程建模为马尔可夫决策过程,设计了深度强化学习算法来处理复杂的状态空间并输出高维连续取值动作,优化相位编码序列;通过仿真实验,验证了连续值脉间相位编码策略在面对相干干扰时良好的抗干扰性能和实时性,可在较短时间内完全消除虚警并大幅降低漏检率;设计的抗干扰方法不需要额外的干扰感知硬件和计算开销,可完全基于现有汽车雷达硬件系统实施,具有良好的落地前景。

(3) 针对非相干干扰的多域参数联合调整的抗干扰策略

分析了非相干干扰的特点,基于对抗相干干扰的方法进行改进,提出非合作式地调整雷达的中心频率、发射时间和调频斜率的多域联合策略来避开干扰;将所提出的多域联合抗干扰策略建模为马尔可夫决策过程,并设计了深度强化学习算法来优化抗干扰策略;通过仿真实验,验证了多域联合策略在面对非相干干扰时良好的抗干扰性能,相较于时、频域联合策略,多域联合策略能进一步降低干扰进入通带的比列并提升信干噪比,同时还分析了各单一域策略及其组合的原理

及有效性，对抗干扰方法设计具有参考价值。

5.2 未来工作展望

目前已有的通过调整雷达参数来消除互相干扰的方法多时合作式的，本文提出并验证了三种非合作式的抗干扰策略，覆盖了相干干扰和非相干干扰场景，形成了更加完备的抗干扰方法。然而，本文工作亦存在不足之处，有待改进：

(1) 调整雷达的中心频率、发射时间或调频斜率的方法需要较多的干扰信息支持决策，而对相干干扰能量和对非相干干扰扫频参数的精准估计方法仍然有待研究。

(2) 尽管所提出的三种抗干扰策略均有良好的抗干扰性能，但尚未将三种策略结合在一起，得到能同时应对相干干扰和非相干干扰的抗干扰策略，相信这样的工作能进一步推动雷达抗干扰的研究，统一抗干扰方法。

(3) 本文提出的是非合作式的抗干扰方法，仿真场景为单智能体场景，仅考虑受干扰雷达执行抗干扰策略，并未考虑其他车辆的雷达（即干扰源）也执行抗干扰策略。未来可以建立多智能体场景，进行集中式训练分布式执行（Centralized Training Decentralized Execution, CTDE），实现所有车辆的雷达在仅依靠自身车辆的观测而不需要互相通信的情况下，同时执行抗干扰策略，这样更符合抗干扰方法已普及的情况。

(4) 本文所提出的方法均仅经过仿真实验验证，而现实世界中的电磁环境、道路状况远比仿真场景复杂，抗干扰方法的鲁棒性和泛化性有待验证。同时，抗干扰方法在实际汽车雷达系统上的部署尚未被充分研究和实现，这将是所有抗干扰方法最终落地都需要解决的一大难题！

参考文献

- [1] 李维杨.试论汽车电动智能化发展趋势[J].现代工业经济和信息化,2022,12(11):81-83.
- [2] 李凯,王智宇,奚瑞轩等.L4 级自动驾驶汽车发展综述[J].专用汽车,2023(02):4-7.
- [3] Aydogdu C, Keskin M F, Carvajal G K, et al. Radar interference mitigation for automated driving: Exploring proactive strategies[J]. IEEE Signal Processing Magazine, 2020, 37(4): 72-84.
- [4] 中华人民共和国工业和信息化部. 汽车雷达无线电管理暂行规定[Z]. 2020 年 12 月 6 日, 工信部令第 181 号.
- [5] Alland S, Stark W, Ali M, et al. Interference in automotive radar systems: Characteristics, mitigation techniques, and current and future research[J]. IEEE Signal Processing Magazine, 2019, 36(5): 45-59.
- [6] Kim G, Mun J, Lee J. A peer-to-peer interference analysis for automotive chirp sequence radars[J]. IEEE Transactions on Vehicular Technology, 2018, 67(9): 8110-8117.
- [7] Rameez M, Dahl M, Pettersson M I. Autoregressive model-based signal reconstruction for automotive radar interference mitigation[J]. IEEE Sensors Journal, 2020, 21(5): 6575-6586.
- [8] Jin F, Cao S. Automotive radar interference mitigation using adaptive noise canceller[J]. IEEE Transactions on Vehicular Technology, 2019, 68(4): 3747-3754.
- [9] Lee S, Lee J Y, Kim S C. Mutual interference suppression using wavelet denoising in automotive FMCW radar systems[J]. IEEE Transactions on Intelligent Transportation Systems, 2019, 22(2): 887-897.
- [10] Wang J. CFAR-based interference mitigation for FMCW automotive radar systems[J]. IEEE Transactions on Intelligent Transportation Systems, 2021, 23(8): 12229-12238.
- [11] Mun J, Ha S, Lee J. Automotive radar signal interference mitigation using RNN with self attention[C]. ICASSP 2020-2020 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP). IEEE, 2020: 3802-3806.
- [12] Rock J, Toth M, Messner E, et al. Complex signal denoising and interference mitigation for automotive radar using convolutional neural networks[C]. 2019 22th International Conference on Information Fusion (FUSION). IEEE, 2019: 1-8.
- [13] Li R, Wang J, He Y, et al. Deep Learning for Interference Mitigation in Time-Frequency Maps of FMCW Radars[C]. 2021 CIE International Conference on Radar (Radar). IEEE, 2021: 1883-1886.
- [14] Wang J, Li R, He Y, et al. Prior-guided deep interference mitigation for FMCW radars[J]. IEEE

- Transactions on Geoscience and Remote Sensing, 2022, 60: 1-16.
- [15] Wang J, Li R, Zhang X, et al. Interference mitigation for automotive FMCW radar based on contrastive learning with dilated convolution[J]. IEEE Transactions on Intelligent Transportation Systems, 2024, 25(1): 545-558.
- [16] 李润龙. 基于复数网络和先验信息的汽车雷达干扰抑制技术[D]. 北京邮电大学, 2023.
- [17] Luo T N, Wu C H E, Chen Y J E. A 77-GHz CMOS automotive radar transceiver with anti-interference function[J]. IEEE Transactions on Circuits and Systems I: Regular Papers, 2013, 60(12): 3247-3255.
- [18] Kitsukawa Y, Mitsumoto M, Mizutani H, et al. An interference suppression method by transmission chirp waveform with random repetition interval in fast-chirp FMCW radar[C]. 2019 16th European Radar Conference (EuRAD). IEEE, 2019: 165-168.
- [19] Uysal F. Phase-coded FMCW automotive radar: System design and interference mitigation[J]. IEEE Transactions on Vehicular Technology, 2019, 69(1): 270-281.
- [20] Uysal F, Orru S. Phase-coded FMCW automotive radar: Application and challenges[C]. 2020 IEEE International Radar Conference (RADAR). IEEE, 2020: 478-482.
- [21] Tang B, Huang W, Li J. Slow-time coding for mutual interference mitigation[C]. 2018 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP). IEEE, 2018: 6508-6512.
- [22] Jin S, Roy S. FMCW radar network: Multiple access and interference mitigation[J]. IEEE Journal of Selected Topics in Signal Processing, 2021, 15(4): 968-979.
- [23] Khoury J, Ramanathan R, McCloskey D, et al. RadarMAC: Mitigating radar interference in self-driving cars[C]. 2016 13th Annual IEEE International Conference on Sensing, Communication, and Networking (SECON). IEEE, 2016: 1-9.
- [24] Aydogdu C, Keskin M F, Garcia N, et al. RadChat: Spectrum sharing for automotive radar interference mitigation[J]. IEEE Transactions on Intelligent Transportation Systems, 2019, 22(1): 416-429.
- [25] Bose A, Tang B, Soltanalian M, et al. Mutual interference mitigation for multiple connected automotive radar systems[J]. IEEE Transactions on Vehicular Technology, 2021, 70(10): 11062-11066.
- [26] Haykin S. Cognitive radar: a way of the future[J]. IEEE signal processing magazine, 2006, 23(1): 30-40.
- [27] Haigh K, Andrusenko J. Cognitive electronic warfare: an artificial intelligence approach[M]. Artech House, 2021.
- [28] Zhou F, Zhou D, Yu G. Target tracking in interference environments reinforcement learning

- and design for cognitive radar soft processing[C]. 2008 Congress on Image and Signal Processing. IEEE, 2008, 4: 73-77.
- [29] Greco M S, Gini F, Stinco P, et al. Cognitive radars: On the road to reality: Progress thus far and possibilities for the future[J]. IEEE Signal Processing Magazine, 2018, 35(4): 112-125.
- [30] Griffiths H, Cohen L, Watts S, et al. Radar spectrum engineering and management: Technical and regulatory issues[J]. Proceedings of the IEEE, 2014, 103(1): 85-102.
- [31] Hakobyan G, Fink M, Soyolyn A, et al. Sweep-based spectrum sensing method for interference-aware cognitive automotive radar[C]. 2020 IEEE Radar Conference (RadarConf20). IEEE, 2020: 1-6.
- [32] Mishra K V, Zhitnikov A, Eldar Y C. Spectrum sharing solution for automotive radar[C]. 2017 IEEE 85th Vehicular Technology Conference (VTC Spring). IEEE, 2017: 1-5.
- [33] Slavik Z, Mishra K V. Cognitive interference mitigation in automotive radars[C]. 2019 IEEE Radar Conference (RadarConf). IEEE, 2019: 1-6.
- [34] Hakobyan G, Armanious K, Yang B. Interference-aware cognitive radar: A remedy to the automotive interference problem[J]. IEEE Transactions on Aerospace and Electronic Systems, 2019, 56(3): 2326-2339.
- [35] Tabrikian J, Isaacs O, Bilik I. Cognitive antenna selection for DOA estimation in automotive radar[C]. 2016 IEEE Radar Conference (RadarConf). IEEE, 2016: 1-5.
- [36] Tabrikian J, Isaacs O, Bilik I. Cognitive antenna selection for automotive radar using bobrovsky-zakai bound[J]. IEEE Journal of Selected Topics in Signal Processing, 2021, 15(4): 892-903.
- [37] Selvi E, Buehrer R M, Martone A, et al. On the use of Markov decision processes in cognitive radar: An application to target tracking[C]. 2018 IEEE Radar Conference (RadarConf18). IEEE, 2018: 0537-0542.
- [38] Selvi E, Buehrer R M, Martone A, et al. Reinforcement learning for adaptable bandwidth tracking radars[J]. IEEE Transactions on Aerospace and Electronic Systems, 2020, 56(5): 3904-3921.
- [39] Wu Q, Wang H, Li X, et al. Reinforcement learning-based anti-jamming in networked UAV radar systems[J]. Applied Sciences, 2019, 9(23): 5173.
- [40] Yi W, Yuan Y. Reinforcement learning-based joint adaptive frequency hopping and pulse-width allocation for radar anti-jamming[C]. 2020 IEEE Radar Conference (RadarConf20). IEEE, 2020: 1-6.
- [41] Silver D, Huang A, Maddison C J, et al. Mastering the game of Go with deep neural networks and tree search[J]. Nature, 2016, 529(7587): 484-489.

- [42] Silver D, Schrittwieser J, Simonyan K, et al. Mastering the game of go without human knowledge[J]. *Nature*, 2017, 550(7676): 354-359.
- [43] Vinyals O, Babuschkin I, Czarnecki W M, et al. Grandmaster level in StarCraft II using multi-agent reinforcement learning[J]. *Nature*, 2019, 575(7782): 350-354.
- [44] Liu P, Liu Y, Huang T, et al. Decentralized automotive radar spectrum allocation to avoid mutual interference using reinforcement learning[J]. *IEEE Transactions on Aerospace and Electronic Systems*, 2020, 57(1): 190-205.
- [45] 刘飞鹏. 基于强化学习的车载 FMCW 雷达抗干扰方法研究[D]. 吉林大学, 2023.
- [46] Coutino M, Uysal F. Reinforcement Learning for Radar Waveform Optimization[C]. 2023 IEEE Radar Conference (RadarConf23). IEEE, 2023: 1-6.
- [47] Smith G E, Gurbuz S Z, Brüggewirth S, et al. Neural networks & machine learning in cognitive radar[C]. 2020 IEEE Radar Conference (RadarConf20). IEEE, 2020: 1-6.
- [48] Smith G E, Reininger T J. Reinforcement learning for waveform design[C]. 2021 IEEE Radar Conference (RadarConf21). IEEE, 2021: 1-6.
- [49] Reininger T J, Smith G E. Deep Deterministic Policy Gradient Artificial Intelligence for Radar Applications[C]. 2022 IEEE Radar Conference (RadarConf22). IEEE, 2022: 1-6.
- [50] Richards M A. Fundamentals of Radar Signal Processing(2nd ed)[M]. McGraw-Hill Education, 2014.
- [51] 王溢. 面向网联自动驾驶的多雷达干扰抑制技术研究[D]. 北京邮电大学, 2023.
- [52] Einstein A. On the electrodynamics of moving bodies[J]. *Annalen der physik*, 1905, 17(10): 891-921.
- [53] Dham V. Programming chirp parameters in TI radar devices[R]. Application Report SWRA553, Texas Instruments, 2017, 1457.
- [54] Texas Instruments. AWR18xx/16xx/14xx/68xx technical reference manual [R]. Dallas, Texas Instruments Incorporated, 2020.
- [55] Sutton R S, Barto A G. Reinforcement learning: An introduction[M]. MIT press, 2018.
- [56] Mnih V, Badia A P, Mirza M, et al. Asynchronous methods for deep reinforcement learning[C]. International Conference on Machine Learning. PMLR, 2016: 1928-1937.
- [57] Schulman J, Levine S, Abbeel P, et al. Trust region policy optimization[C]. International Conference on Machine Learning. PMLR, 2015: 1889-1897.
- [58] Schulman J, Wolski F, Dhariwal P, et al. Proximal policy optimization algorithms[DB]. arXiv preprint arXiv:1707.06347, 2017.
- [59] Watkins C J C H, Dayan P. Q-Learning[J]. *Machine Learning*, 1992, 8: 279-292.
- [60] Lillicrap T, Hunt J, Pritzel A, et al. Continuous control with deep reinforcement learning[C].

- International Conference on Learning Representation, 2016.
- [61] Fujimoto S, Hoof H, Meger D. Addressing function approximation error in actor-critic methods[C]. International Conference on Machine Learning. PMLR, 2018: 1587-1596.
- [62] Haarnoja T, Zhou A, Abbeel P, et al. Soft actor-critic: Off-policy maximum entropy deep reinforcement learning with a stochastic actor[C]. International Conference on Machine Learning. PMLR, 2018: 1861-1870.
- [63] Mnih V, Kavukcuoglu K, Silver D, et al. Human-level control through deep reinforcement learning[J]. Nature, 2015, 518(7540): 529-533.
- [64] Hasselt H. Double Q-learning[J]. Advances in Neural Information Processing Systems, 2010, 23.
- [65] Van Hasselt H, Guez A, Silver D. Deep reinforcement learning with double q-learning[C]. Proceedings of the AAAI Conference on Artificial Intelligence. 2016, 30(1).
- [66] Cho K, van Merriënboer B, Gulcehre C, et al. Learning phrase representations using RNN encoder-decoder for statistical machine translation[C]. Conference on Empirical Methods in Natural Language Processing (EMNLP 2014). 2014.
- [67] Zhang A, Lipton Z C, Li M, et al. Dive into deep learning[M]. Cambridge University Press, 2023.
- [68] Hausknecht M, Stone P. Deep recurrent q-learning for partially observable MDPs[C]. 2015 AAAI Fall Symposium Series. 2015.
- [69] Tieleman T, Hinton G. Lecture 6.5-rmsprop: divide the gradient by a running average of its recent magnitude[Z]. COURSE: Neural networks for machine learning, 4(2), 26–31.
- [70] Lee C E. Computing the apparent centroid of radar targets[C]. Proceedings of the 1996 IEEE National Radar Conference. IEEE, 1996: 166-171.
- [71] 张伟楠,沈键,俞勇. 动手学强化学习[M]. 人民邮电出版社, 2022.
- [72] 王树森,黎戡君,张志华. 深度强化学习[M]. 人民邮电出版社, 2022.
- [73] Haarnoja T, Zhou A, Hartikainen K, et al. Soft actor-critic algorithms and applications[DB]. arXiv preprint arXiv:1812.05905, 2018.
- [74] Vaswani A, Shazeer N, Parmar N, et al. Attention is all you need[J]. Advances in Neural Information Processing Systems, 2017, 30.
- [75] Kingma D P, Ba J. Adam: A method for stochastic optimization[C]. International Conference on Learning Representation, 2015.

致 谢

攻读学位期间取得的“创新成果”目录

已发表论文：

- [1] 本文作者, 其他作者, 导师. Reinforcement learning based time-domain mutual interference avoidance for automotive radar[C]. IET International Radar Conference 2023 (IET IRC 2023). (本文作者一作, EI 收录)