

一种基于分层强化学习的 FMCW 雷达抗干扰方法

技术领域

本发明涉及雷达抗干扰技术领域，特别涉及调频连续波雷达在相干干扰环境下的自适应抗干扰方法，具体为一种基于分层强化学习的 FMCW 雷达时频域联合抗干扰策略优化方法。

背景技术

随着智能驾驶技术的快速发展，调频连续波雷达凭借其高距离分辨率和速度分辨率、无距离盲区、低发射功率等优势，已成为高级驾驶辅助系统和自动驾驶系统中不可或缺的核心传感器。FMCW 雷达通过发射线性调频连续波信号并接收目标回波进行差拍处理，实现目标距离和速度的精确测量。

然而，随着道路上搭载 FMCW 雷达的车辆数量急剧增加，雷达之间的相互干扰问题日益严峻。特别是当多个雷达的调频斜率、脉冲重复周期等参数完全相同时，会产生相干干扰。相干干扰经 Dechirp 混频后，干扰能量集中在一个窄带内，与真实目标回波的信号形态高度一致，传统的信号处理方法无法有效区分干扰与目标，会在距离-多普勒谱上产生虚假目标，严重影响目标检测的可靠性和行车安全。

现有 FMCW 雷达抗干扰方法主要分为三类：信号处理层面的干扰检测与抑制方法、波形设计层面的参数随机化方法、以及认知层面的自适应策略方法。信号处理方法如干扰检测后置零、信号重构等通常在接收端被动处理，对相干干扰的抑制效果有限；波形参数随机化方法可通过随机抖动调频斜率或发射时

机来降低干扰概率，但无法根据实时干扰环境做出针对性调整；认知抗干扰方法利用强化学习等智能算法进行参数自适应选择，具有较好的灵活性和适应能力。

但现有基于深度强化学习的认知抗干扰方法仍存在以下结构性不足：

第一，时间尺度矛盾。FMCW 雷达每 $50\mu\text{s}$ 发射一个 chirp，动作选择须在此周期内完成，这是微秒级的战术决策。而干扰源的分布模式（如频域集中多个干扰源或是时域密集干扰）在数十至数百个 chirp 的跨度上才呈现出稳定的统计特征，这是相对于逐 chirp 决策的较长时间尺度判断。单一 DRL 智能体以逐 chirp 的相同粒度处理两类决策，无法同时满足两个尺度的要求：若积累统计信息以判断场景，则丧失逐 chirp 的响应速度；若逐 chirp 做所有决策，则场景级信息淹没在瞬时噪声中。

第二，标量反馈的信息不足。DRL 智能体仅以信干噪比标量作为环境反馈。信干噪比反映当前频点和时延配置下的聚合信号质量，但无法揭示干扰源在频域和时域上的分布结构——即无法回答“当前信干噪比低是因为频域被占满还是时延不匹配”。智能体只能通过切换动作后观测新的信干噪比来间接推断干扰分布，这个过程表现为动作序列的频繁振荡和大量无效试错。

第三，探索-利用矛盾在非平稳环境中的加剧。相干干扰环境具有非平稳性：干扰车辆的相对运动、新干扰源的加入、已有干扰的频率跳变，都使环境分布持续变化。单一 DRL 智能体的 ϵ -greedy 策略面临两难： ϵ 太小则无法适应环境变化， ϵ 太大则稳态信干噪比持续振荡。根本原因在于单层结构把“判断是否需要切换策略”和“选择具体动作”绑定在同一 Q 网络上，而这两类决策需要不同的信息基础和决策频率。

因此，亟需一种能够实现战术决策与战略判断时间尺度分离、弥补标量反馈信息不足、且层间协作具备容错能力的 FMCW 雷达抗干扰方法。

发明内容

本发明提出一种基于分层强化学习的 FMCW 雷达抗干扰方法，构建元策略控制器与深度强化学习执行器协同的两层决策架构：元策略控制器基于滑动窗口内的十二维场景语义特征识别干扰模式，并输出频域优先、时域优先或联合探索的元策略指令及置信度；深度强化学习执行器以逐 chirp 粒度选择载波频点和发射时延；层间采用 Q 值偏置软引导及策略持久化机制，实现不同时间尺度上的协同决策。

本发明的基于分层强化学习的 FMCW 雷达抗干扰方法如附图 1 所示，主要包括步骤 200—步骤 270；其中步骤 200—步骤 260 用于动作空间构建、模型训练及控制机制设计，步骤 270 用于在线执行。

步骤 200，构建 FMCW 雷达联合抗干扰动作空间。定义三个可选载波频点 $\{fc_0, fc_1, fc_2\}$ 分别对应中心频率 76.25GHz、76.75GHz、77.25GHz，定义三个可选发射时延 $\{td_0, td_1, td_2\}$ 分别对应时延值 0、 τ_{max} 、 $2\tau_{max}$ ，其中 $\tau_{max} = 2 \times d_{max} / c$ 为最大探测距离 d_{max} 对应的往返时延，c 为光速。由此形成 9 维离散联合动作空间 $A = \{(fc_index, td_index) | fc_index \in \{0,1,2\}, td_index \in \{0,1,2\}\}$ 。发射信号时延调整的物理原理为：改变发射时延 t_d 会改变参考信号与干扰信号的相对时延差，使干扰信号的差拍频率 $f_{beat}^{intf} = K * \tau_{intf}$ 发生变化，当该频率超出低通滤波器通带范围即最大拍频 $f_{bmax} = K * \tau_{max}$ 时，干扰信号被滤除，从而避免干扰进入后续信号处理流程。

FMCW 雷达发射信号模型为：

$$x_T(t) = e^{j2\pi[f_c t + \frac{1}{2}K(t - \frac{T_{sw}}{2})^2]} \quad (1)$$

其中， f_c 为中心频率， K 为调频斜率， T_{sw} 为扫频时长。

接收到的干扰信号经 Dechirp 混频后的差拍信号为：

$$s_{beat}^{intf}(t) = A_{intf} * e^{j2\pi K \pi_{intf} t} \quad (2)$$

其中， A_{intf} 为干扰幅度， π_{intf} 为干扰信号与参考信号的相对时延。

差拍频率 $f_{beat}^{intf} = K \times \pi_{intf}$ ，若 $|f_{beat}^{intf}| > f_{bmax}$ 则干扰被低通滤波器滤除。

所述联合动作空间使得 FMCW 雷达可同时在频域和时域两个维度进行干扰规避，频域策略通过调整载波频率改变干扰与雷达工作频段的频率关系，时域策略通过调整发射时延改变参考信号与干扰的时间关系，两者均利用低通滤波器的通带限制实现干扰物理隔离。

步骤 210，设计基于深度强化学习的抗干扰策略执行层网络架构。本发明采用 Double DQN 与门控循环单元相结合的深度网络结构，网络输入为三通道：

第一通道——上一时刻动作的独热编码，维度等于动作空间大小 9；

第二通道——当前时刻的 SINR 标量值，维度为 1；

第三通道——门控循环单元上一步隐状态，维度为 32。

第一通道和第二通道经拼接后通过两个全连接层 Dense(16, ReLU) + Dense(16, ReLU) 编码为 16 维中间特征表示，通过 Lambda 层扩展时间维度后送入 GRU 层。GRU 层配置 32 个隐单元，采用 Stateful 模式，保留跨 chirp 步的隐状态，使网络具备对干扰环境变化趋势的时序记忆能力。GRU 层后接 Dense(64, ReLU) 全连接层进行高维特征映射，最终通过 Dense(9, Linear) 全连接层输出各动作的 Q 值估计。

训练机制采用 Double DQN 解耦架构。维护 Online 网络和 Target 网络两套参数——Online 网络负责选择动作，Target 网络负责评估该动作的 Q 值，解耦选择与评估以减少 Q 值过估计。Target 网络参数通过软更新方式更新：

$$\theta_{target} \leftarrow \tau \cdot \theta_{online} + (1-\tau) \cdot \theta_{target} \quad (3)$$

其中软更新系数 $\tau = 0.005$ 。

损失函数采用 Huber 损失 ($\delta = 1.0$)：当预测误差绝对值 $|\text{error}| \leq 1$ 时使用均方误差保证平滑梯度；当 $|\text{error}| > 1$ 时使用平均绝对误差抑制异常值的影响。优化器采用 RMSprop，学习率从 1×10^{-3} 指数衰减至 1×10^{-5} 。训练中对梯度范数进行裁剪，梯度范数上限设为 1.0，防止损失函数爆炸，并采用混合精度 FP16 训练以降低显存占用。

步骤 220，设计自适应分段激励的奖励函数。为使深度强化学习执行层以最少切换步数达到并维持高 SINR 状态，本发明设计包含信号质量奖励和动作切换代价的两部分复合奖励函数：

$$\text{总奖励 } R = r_s + r_{AC} \quad (4)$$

其中信号质量奖励 r_s 采用分段设计：

当 $\text{sinr} \geq \text{SINR1}$ 时，采用饱和递增函数：

$$r_s = \alpha 1 * (\text{sinr} - \text{SINR1}) / [(\text{sinr} - \text{SINR1}) + (\text{SINR2} - \text{SINR1})] \quad (5)$$

其中 $\text{SINR1} = 0\text{dB}$ 为参考基准点， $\text{SINR2} = 11\text{dB}$ 为饱和参考点， $\alpha 1 = 1.0$ 。

当 SINR 从 0dB 逐步提升至 11dB 时， r_s 从 0 快速增长趋近至 $\alpha 1$ ；当 sinr 超过 11dB 后奖励增长极为缓慢，引导智能体达到阈值后不再过度追求更高 SINR。

当 $\text{sinr} < \text{SINR1}$ 时，采用线性惩罚函数：

$$r_s = \alpha 2 \times (\text{sinr} - \text{SINR1}) \quad (6)$$

说 明 书

其中 $\alpha_2 = 0.1$ 为较小的惩罚系数，既对低 SINR 状态施加负向激励驱动智能体逃离干扰区域，又避免梯度过大导致训练不稳定。

动作切换代价 r_{AC} 用于抑制策略频繁抖动：

$$r_{AC} = -\alpha_3 * AC \quad (7)$$

其中 $AC = \text{频域切换次数} + \text{时域切换次数}$ ， $\alpha_3 = 0.05$ 。该惩罚项促使智能体优先使用较少切换达成目标 SINR，避免在两个以上等效动作间频繁振荡。

步骤 230，构建包含抗干扰策略状态空间和时序拓展状态的马尔可夫决策过程模型。将 FMCW 雷达抗干扰问题建模为部分可观测马尔可夫决策过程。

定义基础状态为：

$$s_t = [a(t-1), r(t-1), \text{SINR}(t)] \in \mathbb{R}^3 \quad (8)$$

其中 $a(t-1)$ 为上一 chirp 周期的动作索引， $r(t-1)$ 为上一 chirp 周期获得的即时奖励， $\text{SINR}(t)$ 为当前 chirp 周期测量的信干噪比。

为捕获干扰环境的时间动态，将最近 k 步基础状态级联形成时序拓展状态：

$$S_t = [s_{t-k+1}, s_{t-k+2}, \dots, s_t] \in \mathbb{R}^{k \times 3} \quad (9)$$

其中 $k = 20$ 。时序拓展状态通过 GRU 网络进行序列建模，使智能体能够从 SINR 的变化趋势中推断当前干扰模式，而非仅对瞬时 SINR 值进行反应式决策。

动作空间为步骤 200 定义的 9 维离散联合动作空间，动作索引 a 与 (f_c_index, t_d_index) 的映射关系为 $f_c_index = \lfloor a/3 \rfloor$ ， $t_d_index = a \bmod 3$ 。

步骤 240，设计分层决策元策略控制器，在长度为 W 的滑动窗口内提取 12 维场景语义特征。这 12 维特征包括四大类：

第一类，信号质量统计特征（4 维）：

窗口均值 $\mu = \frac{1}{W} \sum_{i=t-W+1}^t \text{SINR}_i$ ，反映平均信号质量水平；

标准差 $\sigma = \sqrt{\frac{1}{W} \sum_{i=t-W+1}^t (\text{SINR}_i - \mu)^2}$, 反映干扰波动程度;

线性趋势斜率 $\Delta = \frac{\sum_i (i - \bar{i})(\text{SINR}_i - \mu)}{\sum_i (i - \bar{i})^2}$, 其中 $\bar{i}$ 为窗口内索引均值, μ 为窗口内 SINR 均值, $\Delta > 0$ 表示信号质量在改善, $\Delta < 0$ 表示信号质量在恶化;

窗口最小值 $\text{SINR}_{\min} = \min_{i \in [t-W+1, t]} \text{SINR}_i$, 刻画最坏情况。

第二类, 执行层动作行为特征 (3 维):

动作熵 $H_{\text{action}} = -\sum_{a=0}^8 p(a) \log p(a)$, 其中 $p(a)$ 为动作 a 在窗口内出现的频率。
熵值高说明 DRL 执行层在频繁切换动作、找不到稳定策略, 是场景困难的信号;

频域动作切换率 $r_{\text{freq_switch}} = (\text{频域切换次数}) / (W-1)$;

时域动作切换率 $r_{\text{time_switch}} = (\text{时域切换次数}) / (W-1)$ 。

第三类, 避干扰效能特征 (2 维):

避开率 $r_{\text{avoid}} = \frac{\text{SINR} > 0 \text{ 的步数}}{W}$;

SINR 增益 $\text{SINR}_{\text{gain}} = \mu_{\text{后半窗}} - \mu_{\text{前半窗}}$, 反映当前策略是否在改善信号质量。

第四类, 维度敏感性特征 (3 维):

$f_{c\text{gap}}$ 表示各频点 EMA-SINR 的极值之差, 反映切换到不同频点的潜在收益;

$t_{d\text{gap}}$ 表示各时延 EMA-SINR 的极值之差, 反映调整时延的潜在收益;

$f_{c-t_d\text{ratio}} = \log \frac{f_{c\text{gap}}}{t_{d\text{gap}}}$, 正值表示频域优化空间更大, 负值表示时域优化空间更大。

训练阶段 $W = 50$, 测试阶段 $W = 12$, 保证基于充分的统计信息做出稳定决策。

步骤 250, 训练随机森林元策略分类器并设计纯软引导机制。元策略控制器的核心是监督学习分类器, 将 12 维场景语义特征映射至三种元策略标签之一及对应置信度。

说明书

随机森林分类器配置：树的数量 $n_estimators = 200$ ，最大深度 $max_depth = 12$ ，叶节点最小样本数 $min_samples_leaf = 5$ ，类别权重 $class_weight$ 采用 $balanced_subsample$ 以应对各类别样本不均衡问题。

三种元策略定义为：

频域优先策略——固定当前发射时延 t_d 不变，仅开放 3 个频点选择（动作掩码限定 f_c 可切换、 t_d 固定），适用于 $f_c - t_{d_ratio} > 0$ 、即频域维度存在更大优化空间的场景；

时域优先策略——固定当前载波频点 f_c 不变，仅开放 3 个时延选择（动作掩码限定 t_d 可切换、 f_c 固定），适用于 $f_c - t_{d_ratio} < 0$ 、即时域维度存在更大优化空间的场景；

联合探索策略——开放全部 9 维动作空间，适用于两维度单策略收益均不足、需时频联合优化的高动态密集干扰场景。

训练数据自动生成流程为：对各种干扰数量（6/9/12/15/18 个干扰源）各采集 800 个随机场景样本，共计 4000 条训练样本。每个场景首先重置雷达环境并预热 60 步——前 54 步系统性扫描全部 9 个 (f_c, t_d) 组合各 6 轮以充分探索动作空间，后 6 步由 DRL 随机探索完成预热。然后从 3×3 的 SINR oracle 表中计算各策略的期望 SINR：以联合策略的相对优势作为标签生成准则——当 $joint_best - max(freq_best, time_best) > 0.3dB$ 时标注为联合探索策略；当差值 $\leq 0.3dB$ 时标注为期望 SINR 较高的单维度策略。训练集与测试集按 8:2 比例分层划分，采用 5 折交叉验证评估泛化性能。

不同于传统硬掩码方案（将被限制动作的 Q 值直接置为 -1×10^9 ），本发明采用纯软引导机制：

$$bonus = base_bonus \times p^2 \quad (10)$$

其中 $base_bonus = 12.0$, p 为分类器输出的置信度。对策略标签允许的动作施加 Q 值偏置 $bonus$, 被限制动作保持原始 Q 值不变。该设计保证元策略在最坏情况下——即分类器误判率约 15%-20% 时, 系统行为等价于纯 DRL 方案, 不会因误判而强制选择次优动作。置信度 p 起到了自适应调节作用: 当分类器对当前场景判断置信度高时给出较大引导力度, 置信度低时减小引导力度, 在环境突变时自动渐进适应。

步骤 260, 构建指数移动平均在线估计机制和策略持久化机制。为实时估计各频点和各时延下的信号质量, 对每个 (f_c_index, t_d_index) 组合维护指数移动平均 SINR 估计值:

$$SINR_EMA_{(t)}^{(f_c, t_d)} = \alpha * SINR_{(t)}^{(f_c, t_d)} + (1 - \alpha) * SINR_EMA_{(t-1)}^{(f_c, t_d)} \quad (11)$$

其中 $\alpha = 0.30$ 为平滑系数。该 EMA 机制使维度敏感性估计在约 3-4 步 (约 150-200 μ s) 内响应干扰分布变化。

各频点 $SINR_EMA$ 取该频点下三个时延 EMA 值的最大值:

$$SINR_EMA_{f_c}(f_c) = \max_{t_d} SINR_EMA^{(f_c, t_d)};$$

各时延 $SINR_EMA$ 取该时延下三个频点 EMA 值的最大值:

$$SINR_EMA_{t_d}(t_d) = \max_{f_c} SINR_EMA^{(f_c, t_d)}.$$

基于上述 EMA 值计算步骤 240 中的维度敏感性特征 f_{c_gap} 与 t_{d_gap} 。

为消除训练阶段与测试阶段的特征分布鸿沟, 在训练阶段使用 SINR oracle 表的无噪声 3×3 穷举值替代 EMA 估计来计算 f_{c_gap} 、 t_{d_gap} 和 $f_{c-t_d_ratio}$ 特征, 消除训练标签噪声; 在测试阶段的 warmup 结束时, 利用 oracle SINR 表直接种子化 EMA 状态, 使测试初始时刻 EMA 值即具备准确估计能力。

此外，设计策略持久化机制以抑制元策略抖动。设定最小策略保持步数 $\min_strategy_steps = 5$ 。元策略控制器在每个决策周期输出新策略标签时：若新标签与当前生效策略相同，则直接更新并重置计数器；若新标签不同但当前策略已保持 $\geq \min_strategy_steps$ 步，则允许切换并重置计数器；若新标签不同且当前策略保持不足 $\min_strategy_steps$ 步，则忽略新策略继续执行当前策略。该机制使 DRL 执行层在受限子空间内有充足时间优化策略，策略切换频率降低约 40%。

训练阶段决策周期 $K_training = 8$ 步，测试阶段 $K_test = 3$ 步，配合 $\min_strategy_steps = 5$ ，在每个 30 步的 episode 内进行约 6 次有效策略决策。

步骤 270，在线部署阶段，按照元策略控制器的策略指令与 DRL 执行层的动作输出，在线调整 FMCW 雷达在每个 chirp 周期的载波频率和发射时延。具体执行流程如下：

- (1) 发射步骤：以当前载波频点 f_c 和发射时延 t_d 参数发射 FMCW chirp 信号；
- (2) 接收与处理步骤：接收包含目标回波、干扰信号和噪声的混合信号，经 Dechirp 混频和低通滤波提取差拍信号，根据公式(2)的物理机制，若干扰差拍频率超出 f_{bmax} 则被滤除；
- (3) SINR 计算步骤：根据 FMCW 物理模型计算当前 (f_c, t_d) 参数配置下的信干噪比；
- (4) 状态更新步骤：按公式(8)构建基础状态，按公式(9)级联最近 k 步基础状态形成扩展时序状态 S_t ；
- (5) 动作选择步骤——DRL 执行层基于扩展时序状态 S_t 通过 Double DQN+GRU 网络输出各动作的原始 Q 值，叠加元策略控制器通过 DAM 接口下

发的 Q 值偏置 bonus, 以 ϵ -greedy 策略 (测试阶段 $\epsilon = 0.05$) 选择下一 chirp 的载波频点和发射时延;

(6) 元策略更新步骤——每 K 步触发一次元策略控制器决策, 按步骤 240 提取 12 维特征, 按步骤 250 通过随机森林分类器输出策略标签及置信度, 按公式(10)计算各动作 Q 值偏置, 经步骤 260 策略持久化后更新生效。

所述逐 chirp 闭环中的发射、接收、信干噪比计算、状态更新和执行层动作选择按 chirp 周期运行; 元策略控制器的特征提取与随机森林推理按 K 步决策周期触发, 与逐 chirp 执行层解耦。仿真环境中, 12 维特征提取和随机森林单次推理的总耗时约 99.6ms, 该数值反映当前仿真实现的计算开销, 不表示其已满足 50 μ s chirp 周期下的工程实时部署要求。

有益效果

本发明提出的基于分层强化学习的 FMCW 雷达抗干扰方法, 建立了"战略场景感知—战术动作执行"的两层协同抗干扰框架, 具有以下有益效果:

第一, 通过时间尺度分离解决了单一 DRL 智能体的探索-利用矛盾。上层元策略控制器以 K 步 (3-8 步) 为决策周期, 积累充分的统计信息后进行战略级场景判断; 下层 DRL 执行层以逐 chirp (50 μ s) 粒度在被限定的动作子空间内进行战术级动作选择。两层各司其职, 将"判断当前属于什么场景"与"在当前场景下选什么动作"两类不同粒度的决策解耦。实验结果表明, 相比纯 DRL 方案, 加入元策略层后在系统级信干噪比上提升 5.1dB (-1.32 vs -6.42dB), 在动态跳频场景下跳频前信干噪比领先 2.5dB (+2.0 vs -0.5dB)、跳频后恢复步数减少 37.5% (5 vs 8 步)。

第二，通过十二维场景语义特征弥补了标量信干噪比反馈的信息不足。其中维度敏感性特征 ($f_{c_{gap}}$ 、 $t_{d_{gap}}$ 、 $f_{c-t_{d_{ratio}}}$) 通过 EMA ($\alpha=0.30$) 在线估计各频点和各时延的信干噪比期望值，直接回答了"当前是频域还是时域存在更大优化空间"这一 DRL 无法从单一信干噪比标量中获取的结构性判断依据。随机森林的特征重要性分析揭示 $f_{c-t_{d_{ratio}}}$ 在策略判别中权重最高，验证了维度敏感性估计的核心作用。

第三，动作空间动态裁剪提升了探索效率。元策略根据场景类型将动作空间从 9 维动态收窄至 3 维（频域优先或时域优先）或保持全开放（联合探索），使得在多数场景下探索负担降低约 67%。实验结果表明 Meta-RF 在各干扰档位下的收敛斜率均优于纯 DRL，且恢复轨迹平滑无锯齿，说明受限动作空间有效减少了无效试错。

第四，纯软引导机制保证了分层系统的鲁棒容错性。以 Q 值偏置替代硬掩码，当分类器置信度低时引导力度自动减弱，保证最坏情况下系统行为等价于纯 DRL 方案；策略持久化机制抑制了元策略层输出抖动，使执行层在受限子空间内有充足时间收敛。该设计使得分层系统在分类器误判率约 15%-20% 时仍不退化。

第五，GRU 时序建模使 DRL 执行层具备干扰环境动态感知能力。32 维 GRU 隐状态（Stateful 模式）跨 chirp 步持续传递，捕获干扰的时间演变趋势，使执行层能从信干噪比序列中推断干扰模式而非仅对瞬时值做反应式决策。消融实验表明 GRU 组件独立贡献约 2.3dB 的信干噪比提升。

附图说明

为了清晰明确地解释本发明的技术步骤，下面将对本发明说明中使用的所

说明书

有附图做简单描述。需要说明的是，下面描述的附图仅仅是本发明实施的一些例子，本领域其他普通技术人员依旧可以根据这些附图在其他不同场景下获得其他的附图。

附图 1 是本发明的实施流程图；

附图 2 是本发明分层决策系统架构图；

附图 3 是 DRL 执行层 Double DQN+GRU 网络结构图；

附图 4 是元策略控制器特征提取与分类流程图；

附图 5 是不同策略方案 SINR 收敛曲线对比图；

附图 6 是动态跳频场景恢复速度对比图。

具体实施方式

下面结合本申请中的附图，对本发明的步骤、过程进行完整清晰的描述。显而易见，本申请中所描述的实例仅仅是本发明的一个实例应用场景，其他基于本发明内容的、没有做出实质性改变的结果都属于本发明的保护范畴。

附图 2 是本发明的一个实例场景，展示了本发明包含的基本元素及后续会使用到的一些参数。在该实例场景中，道路上搭载 FMCW 雷达的受扰车辆作为主车，其周围存在多辆同样搭载 FMCW 雷达的车辆作为潜在干扰源。干扰雷达与受扰雷达的调频斜率和脉冲重复周期完全相同，产生相干干扰。受扰雷达可在三个中心频率（76.25GHz、76.75GHz、77.25GHz）和三个发射时延（0、0.8 μ s、1.6 μ s）之间切换，形成 9 种 (f_c, t_d) 联合配置。本发明的机制实现由车载雷达控制单元在检测到干扰后自动触发执行。

按照附图 2 的实例场景，相关参数为：

说 明 书

参数	符号	取值	定义
中心频率	f_c	76.25/76.75/77.25 GHz	可调频域状态
调频斜率	K	10 MHz/ μ s	线性调频速率
扫频时长	T_{sw}	50 μ s	单个 chirp 持续时间
脉冲重复周期	PRI	60 μ s	chirp 重复间隔
每帧 chirp 数	L	128	用于多普勒处理
采样频率	f_s	20 MHz	ADC 采样率
最大探测距离	d_{max}	120 m	决定通带宽度
最大时延	τ_{max}	0.8 μ s	$\tau_{max} = 2 \times d_{max} / c$
最大拍频	f_{bmax}	8 MHz	$f_{bmax} = K * \tau_{max}$
每 chirp 采样点数	N	1000	$N = f_s \times T_{sw}$
发射功率	P_t	10 dBm	发射信号功率
噪声系数	NF	12 dB	接收机噪声系数
天线增益	G	10 dBi	收发天线增益
SNR	-	10 dB	目标回波信噪比
干扰数量	n_{inf}	6~18 个	随机干扰源数量

在一个具体实施例中，以下按照步骤 200—步骤 270 的统一编号，对本发明各步骤的具体实现与验证过程进行说明：

步骤 200 的具体实施：构建 FMCW 雷达联合抗干扰动作空间并进行马尔可夫决策过程建模。

在三维笛卡尔坐标系中，受扰雷达位于原点，目标车辆和干扰车辆分布在道路场景中。实例场景中动态生成 1-3 个真实目标，目标距离在 0.3m 至 120m 范围内均匀随机分布，目标速度在 -16m/s 至 +16m/s 范围内均匀随机分布。干扰

源数量服从泊松分布（均值 λ 在训练时为随机值，测试时固定为6/9/12/15/18/21/24等档位），干扰源距离、速度、幅度分别在设定范围内随机初始化。每 episode 为 30 个 chirp 周期（总时长 $30 \times 60\mu s = 1.8ms$ ）。

定义状态空间如公式(8)和(9)，动作空间为 $A = \{(f_c_index, t_d_index) | f_c_index \in \{0,1,2\}, t_d_index \in \{0,1,2\}\}$ ，动作索引 $a \in \{0,...,8\}$ 。奖励函数如公式(4)-(7)。

FMCW 雷达干扰避免的物理原理为：

设当前配置下的 f_c 和 t_d ，发射信号如公式(1)。干扰源同样发射 FMCW 信号，其与受扰雷达参考信号的相对时延为 τ_{intf} 。经 Dechirp 混频后，若干扰的差拍频率 $f_{beat}^{intf} = K * \tau_{intf} \leq f_{bmax} = 8MHz$ ，干扰能量落在低通滤波器通带内，对目标检测产生干扰；若 $f_{beat}^{intf} > f_{bmax}$ ，干扰能量被滤除。切换 f_c 和 t_d 均可改变 τ_{intf} 的等效值，从而将干扰"推出"通带。

步骤 210 的具体实施：训练深度强化学习执行层网络。

按步骤 210 所述的 Double DQN+GRU 网络结构构建 Online 网络和 Target 网络，随机初始化 Online 网络参数 θ_{online} ，将 θ_{target} 初始化为 θ_{online} 的副本。

训练采用经验回放机制。在每个 chirp 周期，执行层以 ϵ -greedy 策略选择动作 a_t ，执行后观测 $SINR_{t+1}$ 和奖励 r_t ，将转移元组 (S_t, S_{t+1}, a_t, r_t) 存入容量为 50000 的经验回放缓冲区。每步从缓冲区随机采样 256 条转移元组进行单步梯度更新。

Target 网络每步按公式(3)进行软更新。Huber 损失函数为：

$$L = \frac{1}{B} \sum_i \text{Huber}(Q_{online}(S_i, a_i) - y_i) \quad (12)$$

其中目标值 $y_i = r_i + \gamma * \max_a Q_{target}(S_{i+1}, a_i)$ ， $\gamma = 0.95$ 为折扣因子。

探索率 ε 从 1.0 指数衰减至 0.05, 衰减跨度为 12000 episodes。学习率从 1×10^{-3} 指数衰减至 1×10^{-5} 。总训练 15000 episodes, 前 80% 为训练模式, 后 20% 为测试模式使用固定 $\varepsilon = 0.05$ 。

训练完成后保存 DRL 执行层网络权重, 作为后续元策略控制器训练和在线部署的基础模型。

步骤 240 至步骤 250 的具体实施: 生成元策略分类器训练数据。

对各种干扰数量 (6/9/12/15/18 个) 各采集 800 个随机场景, 共计 4000 条训练样本。

每个场景的数据采集流程为:

- (1) 重置雷达环境, 随机初始化目标、干扰源参数;
- (2) 预热阶段 60 步: 前 54 步系统性扫描全部 9 个 (f_c, t_d) 组合各 6 轮, 后 6 步由 DRL 随机策略完成;
- (3) 从 SINR oracle 表获取 3×3 穷举无噪声 SINR 值;
- (4) 计算各元策略的期望 SINR——频域优先策略取每个频点下最优时延的 SINR 平均值, 时域优先策略取每个时延下最优频点的 SINR 平均值, 联合探索策略取全部 9 个组合的 SINR 最大值;
- (5) 标签生成: 若 $joint_{best} - \max(freq_{best}, time_{best}) > 0.3\text{dB} \rightarrow$ 联合探索; 否则 $\rightarrow$ SINR 较高的单维度策略;
- (6) 按步骤 240 提取 12 维特征, 其中 $f_{c_{gap}}$ 、 $t_{d_{gap}}$ 、 $f_c - t_{d_{ratio}}$ 使用 oracle 值替代 EMA 估计, 消除标签噪声。

将 4000 条样本按 8:2 分层划分为训练集 (3200 条) 和测试集 (800 条), 进行 5 折交叉验证。随机森林分类器配置如步骤 250 所述。

经训练，随机森林分类器在测试集上的分类准确率约为 80%-85%，其中联合探索策略的召回率最高（约 88%），频域优先和时域优先策略的召回率略低（约 78%），这主要受两类单维度策略边界模糊的影响。

步骤 250 的进一步说明：提取特征重要性并进行可解释性分析。

利用随机森林的 *feature_importances* 属性输出 12 个特征的重要性排名。实例场景中的分析结果表明：

$f_{c-t_d\text{ratio}}$ 权重最高（约 0.32），表明元控制器首要判断频域和时域哪个潜在收益更大，据此决定资源投向；

$f_{c\text{gap}}$ 与 $t_{d\text{gap}}$ 权重次之（分别约 0.22 和 0.22），说明决策更关注"调整维度能带来多大极限提升"，而非当前平均信号水平；

r_{avoid} 与 H_{action} 权重中等（分别约 0.07 和 0.05），说明干扰避免程度和执行层迷茫程度是场景判断的辅助依据；

SINR 统计特征（ μ 、 $SINR_{min}$ 、 Δ 等）和动作切换率特征（ r_{freq_switch} 、 r_{time_switch} ）重要性普遍较低（多数低于 0.04），证明元控制器已从战术细节中抽离，专注于结构性机会评估。

整体呈现"机会驱动"的战略思维——决策链条围绕"哪个维度存在更好的干扰空穴"展开，而非被动响应信号恶化，是一种主动寻优的高层认知行为。

步骤 270 的具体实施：部署在线推理系统并验证性能。

将训练好的 DRL 执行层网络和随机森林元策略分类器部署至车载雷达控制单元。

在线推理阶段，每个 chirp 周期执行步骤 270 所述的闭环流程（发射→接收→SINR 计算→状态更新→动作选择），其中动作选择需叠加元策略 Q 值偏置。

每 $K_{test} = 3$ 步触发一次元策略决策，基于最近 $W_{test} = 12$ 步的 SINR 序列提取 12 维特征，随机森林单次推理输出策略标签和置信度 p ，按公式(10)计算 Q 值偏置并经策略持久化后更新生效。

为验证本发明方法的有效性，设计以下四组对比实验：

Exp-A（系统级 SINR 对比）：200 个随机干扰场景下，对比 Baseline（固定 $fc=1, td=1$ ）、纯 DRL 方案（第三章训练的 Joint DQN+GRU agent, $\epsilon=0.05$ ）、和本发明 Meta-RF 方案的平均 SINR、标准差及避开率。结果表明，Meta-RF 方案平均 SINR 为 $-1.32 \pm 10.54\text{dB}$ ，避开率 90.0%；纯 DRL 方案为 $-6.42 \pm 10.03\text{dB}$ ，避开率 85.5%；Baseline 为 $-12.26 \pm 7.65\text{dB}$ ，避开率 75.9%。Meta-RF 相比纯 DRL 平均 SINR 提升约 5.1dB，避开率提升 4.5 个百分点。在 $n_{inf}=18$ 条件下的收敛速度分析中，Meta-RF 的早期 SINR (-9.41dB) 显著优于纯 DRL (-12.08dB)，T80 收敛步数更快（3.4 vs 5.7 步）。

Exp-B（干扰数量扩展性）：在 $n_{inf} \in \{6, 9, 12, 15, 18, 21, 24\}$ 七档干扰数量下评估泛化性能。Meta-RF 在所有档位下 SINR 均保持最优，在分布外测试($n_{inf}=21, 24$) 仍保持 2.4~3.8dB 的领先。值得注意的是 Meta-RF 在 $n_{inf}=24$ 时 SINR 优于 $n_{inf}=21$ 时，说明元策略控制器能在高干扰中发现结构性的避干扰机会。

Exp-C（收敛速度对比）：在 $n_{inf} \in \{6, 12, 18, 21\}$ 四档干扰数量下，Meta-RF 的早期收敛斜率均明显优于纯 DRL——0 至 5 步内的 SINR 上升速度更快，且上升轨迹更平滑。纯 DRL 在四档中的上升轨迹均存在明显的锯齿状震荡（探索引起的动作试错），而 Meta-RF 上升轨迹更平滑，说明元策略对动作空间的有效约束减少了无效探索。

Exp-D（动态跳频恢复）：50 次独立试验， $n_{inf}=9$ ，所有干扰源在第 15 步

说明书

随机跳频（全部 f_c_index 重新分配），是验证元策略层在非稳态环境中增量价值的核心实验。

方案	跳频前SINR	跳频后低点	恢复步数
Pure DRL	-0.5 dB	-5.5 dB	~8步
Meta-RF	+2.0 dB	-4.0 dB	~5步

跳频前 Meta-RF 稳态 SINR (+2.0dB) 领先纯 DRL (-0.5dB) 2.5dB——元策略使执行层在跳频前已锁定更优时频配置。跳频后 Meta-RF 跌幅更小 (-4.0 vs -5.5dB)、恢复更快 (5 vs 8 步, 快约 37.5%)。原因在于: 跳频后 DRL 的 Q-network 基于旧干扰分布的 Q 值估计完全失效, 需在 9 维空间重新试错探索; 而 Meta-RF 的 EMA 机制 ($\alpha=0.30$) 在 3-4 步内更新维度敏感性估计, RF 分类器在下一个决策周期 ($K=3$) 即输出适应新模式策略标签, 将动作搜索空间从 9 维收窄至 3 维, 大幅减少无效试错。

附图说明与结果分析

附图 3 是 DRL 执行层 Double DQN+GRU 网络结构详图。网络包含三通道输入（动作编码、SINR 标量、GRU 隐状态），经编码层（两个 Dense(16)层）、GRU 层（32 单元 Stateful 模式）和价值估计层（Dense(64)+Dense(9)）输出各动作 Q 值。GRU 的 Stateful 模式使隐状态跨 chirp 步持续传递，捕获干扰环境的时间演变趋势。消融实验表明 GRU 是提升性能的关键组件，移除 GRU 导致 SINR 下降约 2.3dB。

附图 4 是元策略控制器特征提取与分类流程图。在长度为 W 的滑动窗口内，从原始 SINR 序列和动作记录中提取 12 维场景语义特征，经随机森林分类器（200 棵树，最大深度 12）输出策略标签 ($freq_only/time_only/joint$) 及置信度 p，通过纯软引

导公式 $bonus = base_bonus \times p^2$ 转化为各动作的 Q 值偏置。

附图 5 是不同策略方案的 SINR 收敛曲线对比图。四个方案的 15000 episodes 训练过程 (50-episode 滑动平均) 表明: 频域优先策略收敛最快 (约 2000 episodes 达到稳态) 但最终 SINR 约 8.2dB, 标准差约 3.2dB; 时域优先策略收敛速度居中 (约 3000 episodes), 最终 SINR 约 7.8dB, 标准差约 4.6dB; 联合探索策略收敛最慢但最终性能最优, 前 3000 episodes SINR 较低, 约 4000 episodes 后超越两单维度策略, 最终 SINR 约 9.5dB, 标准差仅约 0.57dB, 体现了联合探索在各类干扰模式下的性能稳定性。Baseline 固定策略平均 SINR 仅约 2.6dB, 标准差高达约 9.9dB, 完全依赖运气。

附图 6 是动态跳频场景下 Meta-RF 与纯 DRL 方案的 SINR 时序对比图。X 轴为 chirp 步数 (0~30 步), Y 轴为平均 SINR (50 次独立试验平均), 跳频事件发生在第 15 步 (竖直虚线)。跳频前 Meta-RF 稳态 SINR (+2.0dB) 领先纯 DRL (-0.5dB) 2.5dB; 跳频后 Meta-RF 跌幅更小 (-4.0 vs -5.5dB)、恢复更快 (5 vs 8 步)。Meta-RF 的恢复轨迹平滑单调, 纯 DRL 的恢复轨迹呈锯齿状震荡, 说明元策略通过收窄动作搜索空间减少了无效试错。

以上所述仅为本发明的较佳实施例而已, 并不用以限制本发明, 凡在本发明的精神和原则之内所作的任何修改、等同替换和改进等, 均应包含在本发明的保护范围之内。