

权 利 要 求 书

1、一种基于分层强化学习的 FMCW 雷达抗干扰方法，其特征在于，包括以下步骤：

(1) 构建 FMCW 雷达联合抗干扰动作空间，定义可选载波频点集合和可选发射时延集合，形成离散联合动作空间；

(2) 设计基于深度强化学习的抗干扰策略执行层，构建包含门控循环单元时序建模模块的深度 Q 网络，以逐 chirp 粒度进行自适应动作选择；

(3) 设计分层决策元策略控制器，在滑动窗口内提取多维场景语义特征，训练监督学习分类器将当前干扰场景映射至元策略标签；

(4) 构建动态动作掩码软引导接口，将元策略标签以 Q 值偏置方式作用于执行层，在不屏蔽动作的前提下引导探索方向；

(5) 采用指数移动平均机制对各频点和各时延下的信号质量进行在线估计，计算维度敏感性特征；

(6) 部署策略持久化机制，约束元策略的最小保持步数，抑制元策略层输出抖动；

(7) 按照元策略控制器的策略指令与深度强化学习执行层的动作输出，在线调整 FMCW 雷达在各 chirp 周期的载波频率和发射时延，实现相干干扰环境下的自适应抗干扰。

2、根据权利要求 1 所述的 FMCW 雷达联合抗干扰动作空间，其特征在于，定义三个可选载波频点 $\{fc_0, fc_1, fc_2\}$ 分别对应中心频率 76.25GHz、76.75GHz、77.25GHz，定义三个可选发射时延 $\{td_0, td_1, td_2\}$ 分别对应时延值 0、 τ_{max} 、 $2\tau_{max}$ ，其中 $\tau_{max} = 2 \times d_{max} / c$ 为最大探测距离对应的往返时延，c 为光速，形成 9 维离散

权 利 要 求 书

联合动作空间 $A = \{(f_c_index, t_d_index) | f_c_index \in \{0,1,2\}, t_d_index \in \{0,1,2\}\}$, 动作索引 $a \in \{0,1,...,8\}$ 与联合动作的映射关系满足 $f_c_index = \lfloor a/3 \rfloor$, $t_d_index = a \bmod 3$, 发射信号时延调整通过改变参考信号与干扰信号的相对时延差, 使干扰信号的差拍频率超出低通滤波器通带范围, 从而实现干扰滤除。

3、根据权利要求 1 所述的基于深度强化学习的抗干扰策略执行层, 其特征在于, 采用 Double DQN 与门控循环单元相结合的深度网络架构, 网络输入为三通道结构: 第一通道为上一时刻动作的独热编码, 维度为动作空间大小 9; 第二通道为当前时刻的 SINR 标量值, 维度为 1; 第三通道为门控循环单元上一步隐状态, 维度为 32; 第一通道和第二通道经拼接后通过两个全连接层编码为 16 维中间表示, 再通过 Lambda 层扩展时间维度后送入门控循环单元层; 门控循环单元层采用 Stateful 模式, 保留跨 chirp 步的隐状态以捕获干扰环境的时间动态; 门控循环单元层后接全连接层输出各动作的 Q 值估计; 训练采用 Double DQN 解耦机制, Online 网络负责动作选择, Target 网络负责 Q 值评估, Target 网络参数通过软更新方式更新: $\theta_{target} \leftarrow \tau \cdot \theta_{online} + (1-\tau) \cdot \theta_{target}$, 其中 τ 为软更新系数; 采用 Huber 损失函数训练, 以兼顾平滑梯度和异常值抑制; 优化器采用 RMSprop 并对学习率进行衰减。

4、根据权利要求 1 所述的分层决策元策略控制器, 其特征在于, 在长度为 W 的滑动窗口内提取 12 维场景语义特征, 包括:

信号质量统计特征 4 维: 窗口均值 μ 、标准差 σ 、线性趋势斜率 Δ 、窗口最小值 $SINRmin$, 其中 $\mu = \frac{1}{W} \sum_{i=t-W+1}^t SINR_i$; $\sigma = \sqrt{\frac{1}{W} \sum_{i=t-W+1}^t (SINR_i - \mu)^2}$; $\Delta = \frac{\sum_i (i - \bar{i})(SINR_i - \mu)}{\sum_i (i - \bar{i})^2}$ 。其中 $\bar{i}$ 和 μ 分别为窗口内索引均值与 SINR 均值

$$SINRmin = \min_{i \in [t-W+1, t]} SINR_i;$$

权 利 要 求 书

执行层动作行为特征 3 维：动作熵 $H_{action} = -\sum_{a=0}^8 p(a)\log p(a)$ ，其中 $p(a)$ 为动作 a 在窗口内的出现频率；频域动作切换率 r_{freq_switch} ；时域动作切换率 r_{time_switch} ；

避干扰效能特征 2 维：避开率 $r_{avoid} = \frac{SINR>0 \text{ 的步数}}{W}$ ；SINR 增益 $SINR_{gain} = \mu_{\text{后半窗}} - \mu_{\text{前半窗}}$ ；

维度敏感性特征 3 维： f_{c_gap} 表示各频点指数移动平均 SINR 的极值之差，反映频率维度的潜在收益； t_{d_gap} 表示各时延指数移动平均 SINR 的极值之差，反映时延维度的潜在收益； $f_{c_t_{d_ratio}} = \log \frac{f_{c_gap}}{t_{d_gap}}$ 表示频域与时域相对敏感性比值的对数。

5、根据权利要求 4 所述的分层决策元策略控制器，其特征在于，所述监督学习分类器采用随机森林分类器，所述分类器输出三类元策略标签及对应置信度 p ：

频域优先策略：固定当前发射时延，仅开放 3 个频点选择，适用于 $f_{c_t_{d_ratio}} > 0$ 、频域干扰分布不均而时域较干净的场景；

时域优先策略：固定当前载波频点，仅开放 3 个时延选择，适用于 $f_{c_t_{d_ratio}} < 0$ 、时域干扰分布不均而频域较干净的场景；

联合探索策略：开放全部 9 维动作空间，适用于两维度单策略收益均不足、需时频联合优化的高动态密集干扰场景；

训练数据自动生成方式为：对各种干扰数量分别采集随机场景样本，每个场景预热后从 oracle SINR 表计算各策略期望 SINR，以联合策略相对优势准则生成标签，当 $joint_best - \max(freq_best, time_best) > \text{预设阈值}$ 时标注为联合探索策略，否则标注为期望 SINR 更高的单维度策略。

权 利 要 求 书

6、根据权利要求 1 所述的动态动作掩码软引导接口，其特征在于，元策略控制器输出的策略标签及置信度 p 不强制屏蔽执行层动作，而是对允许动作施加 Q 值偏置 $bonus = base_bonus \times p^2$ ，其中 $base_bonus$ 为基准偏置值，被限制动作保持原始 Q 值不变，使未被优先引导的动作仍保留被选择的可能，从而降低元策略误判对执行层的影响。

7、根据权利要求 4 所述的指数移动平均机制，其特征在于，对每个 (f_c_index, t_d_index) 组合维护一个指数移动平均 SINR 估计值，更新公式为：

$$SINR_EMA_{(t)}^{(f_c, t_d)} = \alpha * SINR_{(t)}^{(f_c, t_d)} + (1 - \alpha) * SINR_EMA_{(t-1)}^{(f_c, t_d)} \quad \text{其中 } \alpha$$

为平滑系数，各频点 EMA-SINR 值取该频点下三个时延 EMA 值的最大值：

$$SINR_EMA_{f_c}(f_c) = \max_{t_d} SINR_EMA_{(f_c, t_d)}; \quad \text{各时延 EMA-SINR 值取该时延下三}$$

个频点 EMA 值的最大值 $SINR_EMA_{t_d}(t_d) = \max_{f_c} SINR_EMA_{(f_c, t_d)}$ ；基于上述 EMA 值计算维度敏感性特征：

$$f_{c_gap} = \max_{f_c} SINR_EMA_{f_c}(f_c) - \min_{f_c} SINR_EMA_{f_c}(f_c)$$

$$t_{d_gap} = \max_{t_d} SINR_EMA_{t_d}(t_d) - \min_{t_d} SINR_EMA_{t_d}(t_d)$$

该 EMA 机制使维度敏感性估计随干扰分布变化而更新，为元策略控制器提供在线场景感知信息。

8、根据权利要求 5 所述的策略持久化机制，其特征在于，设定最小策略保持步数 $min_strategy_steps$ 为预设正整数，元策略控制器在每个决策周期输出的新策略标签需与当前生效策略比较：若新策略标签与当前策略相同，则直接更新并重置计数器；若新策略标签与当前策略不同但当前策略已保持大于等于 $min_strategy_steps$ 步，则允许策略切换并重置计数器；若新策略标签与当前策

权 利 要 求 书

略不同且当前策略保持不足 $min_strategy_steps$ 步，则忽略新策略继续执行当前策略，计数器继续累加；该机制使深度强化学习执行层在受限子空间内有充足时间优化策略，减少因元策略频繁切换导致的探索效率损失。

9、根据权利要求 3 所述的分层强化学习抗干扰方法，其特征在于，深度强化学习执行层的奖励函数采用分段激励设计：当 $sinr \geq SINR1$ 时，采用饱和递增函数： $r_s = \alpha_1 * (sinr - SINR1) / [(sinr - SINR1) + (SINR2 - SINR1)]$ ，使奖励随 $sinr$ 提升从 0 快速趋近至 α_1 ， $sinr$ 超过 $SINR2$ 后奖励增长放缓；当 $sinr < SINR1$ 时，采用线性惩罚函数： $r_s = \alpha_2 \times (sinr - SINR1)$ ，以较小斜率驱动智能体逃离低 SINR 状态；同时引入动作切换代价 $r_{AC} = -\alpha_3 * ac$ ，其中 $AC = \text{频域切换次数} + \text{时域切换次数}$ ， $\alpha_1 = 1.0$ ， $\alpha_2 = 0.1$ ， $\alpha_3 = 0.05$ ， $SINR1 = 0\text{dB}$ ， $SINR2 = 11\text{dB}$ ；总奖励 $R = r_s + r_{AC}$ ，引导智能体以最少切换步数达到目标 $sinr$ ，避免策略抖动。

10、根据权利要求 1 所述的 FMCW 雷达抗干扰方法，其特征在于，FMCW 雷达在每个 chirp 周期内执行以下闭环流程：发射步骤——以当前载波频点 f_c 和发射时延 t_d 参数发射 FMCW chirp 信号，发射信号形式为 $x_T(t) = e^{j2\pi[f_c t + \frac{1}{2}K(t - \frac{T_{sw}}{2})^2]}$ ，其中 K 为调频斜率， T_{sw} 为扫频时长；接收与处理步骤——接收包含目标回波、干扰信号和噪声的混合信号，经 Dechirp 混频和低通滤波提取差拍信号，若干扰信号与参考信号的频率差超过最大拍频 $f_{bmax} = K * \tau_{max}$ ，则被低通滤波器滤除；SINR 计算步骤：根据 FMCW 物理模型计算当前 (f_c, t_d) 参数配置下的信干噪比；状态更新步骤：将当前 SINR 与上一动作编码扩展为状态向量 $s_t = [a(t-1), r(t-1), SINR(t)]$ ，并级联最近 k 步状态形成扩展时序状态 $S_t = [s_{t-k+1}, s_{t-k+2}, \dots, s_t] \in \mathbb{R}^{k \times 3}$ ，其中 k 为预设正整数；动作选择步骤——深度强化学习执行层基于扩展时序状态 S_t 通过 Double DQN+GRU 网络输出各动作 Q 值，结合元策略控制器下

权 利 要 求 书

发的 Q 值偏置，以 ε -greedy 策略选择下一 chirp 的载波频点和发射时延参数。