

论文标题：基于分层强化学习的 FMCW 雷达抗干扰策略优化

一、绪论

1.1 研究背景

FMCW 雷达的关键作用和干扰难题：

阐述 FMCW 雷达在 ADAS/AD 中的核心地位，明确相干干扰的严峻性。界定现有方案在抑制相干干扰或部署依赖性方面的局限。

1.2 国内外研究现状

综述认知雷达中 DRL 在时域/频域资源分配的现状。对标现有非合作策略的不足，突出本研究在非合作时域优化和 LLM 认知增强方面的独特性。

1.3 本论文的主要内容及结构安排

总结本文提出的两个核心创新点及其协同关系，明确量化预期达到的性能提升指标。介绍后续章节安排。

二、雷达抗干扰分层决策系统架构设计

2.1 FMCW 雷达基础

介绍 FMCW 雷达信号模型、解调过程。从物理层面解释发射时延调整实现干扰避免的原理，提供时域策略的理论依据。

2.1.1 FMCW 雷达信号（抗干扰）模型

2.1.1.1 基本参数：


参数	符号	取值	定义
中心频率	f_c	76.25 / 76.50 / 77.25 GHz	可调频域状态
调频斜率	K	10 MHz/ μ s	线性调频速率
扫频时长	T_{sw}	50 μ s	单个chirp持续时间
脉冲重复周期	PRI	60 μ s	chirp重复间隔
每帧 chirp 数	L	128	用于多普勒处理
采样频率	f_s	20 MHz	ADC采样率
最大探测距离	d_{max}	120 m	决定通带宽度
发射时间延迟	t_d	0 / τ_{max} / $2\tau_{max}$	可调时域状态

最大时延： $\tau_{max} = 2 * d_{max} / c = 0.8\mu$ s

最大拍频: $f_{bmax} = K * \tau_{max} = 8\text{MHz}$

每chirp采样点数 $N = f_s \times T_{sw} = 1000$ 点

2.1.1.2 信号处理流程



发射信号: $x_T(t) = e^{j2\pi[f_c t + \frac{1}{2}K(t - \frac{T_{sw}}{2})^2]}$, 干扰信号: $x_{intf}(t) = A_{intf} e^{j2\pi[f_c^{intf}(t - \tau_{intf}) + \frac{1}{2}K(t - \tau_{intf})^2]}$

混频后差拍信号: $s_{beat}^{intf}(t) = A_{intf} e^{j2\pi K \pi_{intf} t}$, 差拍频率


Key: 若干扰信号与参考信号的频率差超过

f_{bmax} , 则经LPF后被滤除, 不会进入后续处理。时域策略和频域策略均利用这一特性将干扰"推出"通带。


2.1.1.3 相干干扰

干扰雷达与受扰雷达的调频斜率、PRI 完全相同。Dechirp

后干扰能量集中在窄带, 与目标回波形态一致, 会产生强虚假目标, 信号处理方法无法区分。




2.1.1.4 物理场景



要素	训练设置	测试设置
目标数量	均匀随机 1~3 个	同训练
目标幅度	$U(0.5, 1.5)$	同训练
目标距离	$U(0.3, 120)$ m	同训练
目标速度	$U(-16, +16)$ m/s	同训练
干扰数量	泊松分布，均值12	固定 6 / 9 / 12 / 15 / 18 个
干扰幅度	$U(1, 12)$	同训练
干扰速度	$U(-32, +32)$ m/s	同训练
干扰延迟	$U(0, 3) \times \tau_{\max}$	同训练
SNR	10 dB	10 dB

2.1.2 FMCW 雷达干扰避免机制



频域策略：调整 f_c ，改变干扰与通带的频率差，使干扰被 LPF 滤除。

时域策略：调整 t_d ，改变参考信号与干扰的相对时延，同样利用 LPF 滤除。

联合策略：同时利用频域 $\times$ 时域 = 9 个状态，避干扰空间更大。 $A=\{(fc,td)|fc\in\{0,1,2\},td\in\{0,1,2\}\}$

2.2 抗干扰策略建模

建模 SARTZO，论证在非合作环境中问题本质是一个部分可观测的 MDP 问题。相干干扰。

2.2.1 马尔可夫决策过程

介绍 MDP 常规定义。

2.2.2 干扰避免的马尔可夫决策过程建模

状态： $s_t = \begin{bmatrix} a(t-1) \\ r(t-1) \\ SINR(t) \end{bmatrix} \in \mathbb{R}^3$ 与拓展状态：最近 $k=20$ 步的单步状态序列

动作空间： $a \leftrightarrow (fc, td)$ with $\begin{cases} fc = \lfloor a/3 \rfloor \\ td = a \bmod 3 \end{cases}$

时序拓展： $S_t = [s_{t-k+1}, s_{t-k+2}, \dots, s_t] \in \mathbb{R}^{k \times 3}$

奖励函数： $r_t = r_{SINR}(s_t) + r_{AC}(a_{t-1}, a_t)$

2.3 基于分层强化学习的抗干扰决策系统架构设计

明确定义系统的两层架构：RF 元控制器（Meta-Controller）和 DRL 快速执行器（Fast Executor）。论述分层强化学习（HRL）的理论依据。并提出并设计异步双线程架构解决 LLM 高延迟与雷达控制低延迟的矛盾。详细设计非阻塞通信和配置缓冲机制，确保控制流的连续性。

2.3.1 HRL 理论基础

2.3.2 分层决策系统架构设计

设计了两层分层决策系统架构，上层采用 RF 元控制器负责宏观策略规划，下层用专用决策器负责具体的时域/频域干扰抑制。两层定义明确的 DAM 接口进行信息交互，上层可以根据反馈实时调整下层策略。


抗干扰决策的时间尺度矛盾：

FMCW 雷达每 $50\mu s$ 发射一个 chirp，动作选择必须在这个周期内完成——这是微秒级的执行约束。但干扰环境的变化特征在不同时间尺度上呈现出根本不同的性质：

- 逐 chirp 尺度：每个 chirp 周期内，干扰的瞬时 SINR 受当前 (fc, td) 配置直接影响，需要快速响应。这是战术级决策。

- 场景尺度：干扰源的分布模式（如“频域集中 3 个干扰源”还是“时域密集 5 个干扰源”）在数十至数百个 chirp 的跨度上才显现出稳定的统计特征。这是战略级判断。

单一决策器无法同时满足两个尺度的要求：若以逐 chirp 的粒度做所有决策，则场景级信息淹没在瞬时噪声中；若增大决策间隔以积累统计信息，则丧失了逐 chirp 的响应速度。这是本问题内生的时间尺度分离需求。



2.3.3 异步协同和低延迟控制机制的实现

实现层间异步协同机制，使高层策略规划和低层执行并行进行，上层可实时生成策略并下发，低层快速响应并反馈结果。控制流程强调低延迟设计，通过优化决策步骤保障干扰突发时的快速反应。

2.4 仿真实验设置

描述雷达抗干扰仿真平台的搭建细节，包括干扰源的动态建模。定义核心评估指标：如平均 SINR、避开干扰率等。

2.4.1 仿真环境搭建

2.4.2 性能评估指标设计

sinr convergence、*training loss* 与 *interference avoidance*、*joint action frequency*

2.5 本章小结

总结本章在理论建模和系统架构设计方面的主要工作。

三、 基于深度强化学习的抗干扰策略执行层优化

3.1 抗干扰策略执行层优化目标

本章构建基于 Double DQN + GRU 的 DRL 执行层，作为整个分层抗干扰框架的底层决策模块。优化目标聚焦于两点：

- ①环境感知能力：通过 GRU 时序建模捕获干扰动态变化，使 agent 能从 SINR 时序中推断当前干扰模式，而非瞬时 SINR 值；
- ②样本学习效率：针对 FMCE 雷达的 9 维离散联合动作空间（3 频点 $\times$ 3 时延），设计高效探索策略与稳定训练机制，在有限交互步数内收敛至近最优策略。

执行层输出为每个 chirp 周期的 (f_c_index, t_d_index) 动作对，向上层元策略控制器提供标准化的 DAM 接口，使其可以通过动作掩码对执行层进行策略级调控。

3.2 基于深度强化学习的抗干扰策略实现

3.2.1 抗干扰的策略执行流程

发射当前参数状态下的一帧信号 → 接收 = 目标回波 + 干扰 + 噪声 → Dechirp + LPF - Beat Signal → 计算 SINR → 更新扩展状态 → DRL 智能体选择下一个参数状态（动作）

FMCW 雷达在每个 chirp 周期 ($T_{sw} = 50 \mu s$) 内执行以下闭环：

①发射：以当前参数 (f_c_index, t_d_index) 发射 FMCW chirp 信号

②接受与处理：接收 = 目标回波 + 干扰 + 噪声 → Dechirp + LPF - Beat Signal 提取 Beat 信号


③SINR 计算：由 FMCW 物理模型计算当前 (f_c, t_d) 下的信噪比


④状态更新：将 SINR 及当前动作编码拓展为状态向量 $s_t = \begin{bmatrix} a(t-1) \\ r(t-1) \\ SINR(t) \end{bmatrix} \in \mathbb{R}^3$

⑤动作选择：DRL Agent 基于 Double DQN + GRU 网络输出 Q 值，通过 ϵ -greedy 策略选择下一 chirp 的动作参数

⑥经验存储：将转移 (s_t, s_{t+1}, a_t, r_t) 存入均匀经验回放缓冲区。

3.2.2 DRL 优化算法设计





采用 Double DQN + GRU 架构，网络结构如下：

输入层（三通道）：

- 动作输入：上一动作的 one-hot 编码，维度 = $action_num$ ($joint=9, freq_only=3, time_only=3$)
- SINR 输入：当前 SINR 标量（1 维）
- 隐状态输入：GRU 上一步隐状态，维度 = $GRU_units = 32$

编码层（特征预处理）：

- Dense(16, ReLU) + Dense(16, ReLU)，将动作+SINR 拼接后编码为 16 维中间表示
- 通过 Lambda 层扩展时间维度后送入 GRU

时序建模层：

- GRU(32, stateful=True)，捕获干扰环境的时间动态。Stateful 模式保留跨 chirp 步的隐状态，使网络具备对干扰变化趋势的记忆能力

价值估计层：

- Dense(64, ReLU) — 高维特征映射
- Dense(action_num, Linear) — 输出各动作的 Q 值估计

训练机制：

- Double DQN：Online 网络选择动作，Target 网络评估 Q 值，解耦选择与评估以减少过估计
- 软更新： $\theta_{target} \leftarrow \tau \cdot \theta_{online} + (1-\tau) \cdot \theta_{target}$ ， $\tau = 0.005$
- Huber Loss ($\delta=1.0$)：在 $|\text{error}| \leq 1$ 时用 MSE 保证平滑梯度， >1 时用 MAE 抑制异常值

- 梯度裁剪（clipnorm）：约束梯度范数，防止 loss 爆炸
- 优化器：RMSprop，学习率从 1e-3 指数衰减至 1e-5
- 混合精度训练（FP16）：利用 Tensor Core 加速，显存占用降低

关键超参数：

参数	取值	说明
<i>GRU_units</i>	32	GRU隐层维度（v3从16增至32）
<i>dense_units</i>	64	价值估计层维度
<i>batch_size</i>	256	训练批次大小
<i>replay_buffer</i>	50000	经验回放容量
γ (discount)	0.95	折扣因子
$\epsilon_{init} \rightarrow \epsilon_{min}$	1.0 $\rightarrow$ 0.05	探索率指数衰减
$\epsilon_{decay_episodes}$	12000	ϵ 衰减跨度
τ (soft update)	0.005	目标网络软更新率
<i>learning_rate</i>	1e-3 $\rightarrow$ 1e-5	学习率指数衰减
<i>gradient_clip_norm</i>	1.0	梯度范数上限
<i>num_episodes</i>	15000	总训练episode数

3.3 策略训练效率机制设置

设计非线性的分段奖励函数，并通过分段激励机制加速训练收敛。设置动态动作掩码机制（Action Masking），提升训练的样本效率，并实现对动作空间的动态裁剪，为上层 LLM 策略的下发提供技术接口。

3.3.1 自适应分段激励的奖励函数设计

$R = r_s + r_c$

信号质量奖励

当 $sinr \geq (SINR1)$ 时：用饱和递增函数奖 SINR 提升：

$r_s = \alpha1 * (sinr - SINR1) / [(sinr - SINR1) + (SINR2 - SINR1)]$

当 $sinr$ 从 0 升到 11 时， r_s 快速从 0 趋近到 $\alpha1$ 。超过 11 后奖励增长慢，逐步达到收敛。

当 $sinr < 0$ 时，用线性函数惩罚低 $sinr$ ，公式为 $r_s = \alpha2 * (sinr - SINR1)$


$\alpha2 = 0.1$ 较小，既惩罚差信号，又避免梯度爆炸。

动作切换代价 r_{AC} 约束策略稳定性。惩罚频域或时域动作的频繁切换：

$AC = \text{频率切换次数} + \text{时域切换速度}$

$r_{AC} = -\alpha3 * ac$ ，目的是让智能体优先用“最少切换”达到目标 $sinr$ ，避免策略抖动。

3.3.2 动态动作掩码 DAM 机制设置



DAM机制在训练和推理阶段均生效，具有双重作用：

训练阶段：对 $freq_{only}$ 和 $time_{only}$

agent，通过DAM将其动作空间从9维联合空间裁剪至对应子空间（3维），大幅缩小探索范围。 $freq_{only}$ 固定当前 t_d 仅切换 f_c ， $time_{only}$ 固定当前 f_c 仅切换 t_d 。这使单维度agent的样本效率约为joint agent的3倍。

推理阶段：DAM为上层元策略控制器提供标准化接口。元控制器输出的策略标签（ $freq_{only} / time_{only} / joint$ ）通过DAM转化为具体动作掩码下发给执行层，实现策略级调控。这一设计使第三章的DRL执行层与第四章的元策略层在接口层面解耦——执行层只需响应动作掩码，无需感知上层策略来源。

3.4 仿真实验

优化策略的性能验证与消融分析：设计对比实验和消融实验。验证优化 DRL 策略在动态场景下的平均 SINR 优越性、平均避开干扰率，量化各优化组件对收敛速度和样本效率的增量贡献。

3.4.1 实验设置

根据 2.1.2 进行对比实验设置。频域动作空间 $\{0\ 1\ 2\}$ ，分别对应三个载波频率；时域动作空间 $\{0\ 1\ 2\}$ 分别对应三个不同的雷达发射时延。


对比方案：

方案	动作空间	说明
Baseline	固定 $f_c=1, t_d=1$	无自适应，始终使用中频+中时延
$freq_{only}$	3动作（ f_c 变化， t_d 固定）	仅频域自适应，DRL训练15000 ep
$time_{only}$	3动作（ t_d 变化， f_c 固定）	仅时域自适应，DRL训练15000 ep
joint	9动作（ f_c+t_d 联合）	时频联合自适应，DRL训练15000 ep

训练配置：每 episode 30 步/chirp 周期，共 15000 episodes（前 80%为训练模式含 ϵ 探索，后 20%为测试模式 $\epsilon=0.05$ ）。干扰数量随机（泊松均值 $\lambda=2$ ，范围 1~20），干扰幅度、延迟、速度按毕设表 2-3 随机初始化。每 episode 环境重置，GRU 隐状态随 episode 重置。


评估方式：在训练结束后，对每个方案独立运行 100 个测试 episode，统计平均 SINR、标准差、避开率（SINR>0 的步数占比）及联合动作分布。



3.4.2 实验结果



三个 DRL agent 在 15000 episodes 训练过程中的 SINR 收敛曲线（50-episode 滑动平均）：

- **freq_only**: 收敛最快（~2000 ep 达到稳态），因动作空间最小（3 动作），探索负担最轻。最终 SINR 约 8.2 dB，标准差约 3.2 dB。标准差较大说明在频域密集型干扰场景中表现受限——当干扰同时在多个频率出现时，仅切换频率无法完全规避。
- **time_only**: 收敛速度居中（~3000 ep），最终 SINR 约 7.8 dB，标准差约 4.6 dB。标准差在三者中最大，原因是纯时域策略对目标距离变化敏感（目标移动改变回波延迟），且时域干扰的随机性更强。
- **joint**: 收敛最慢但最终性能最优。前 3000 episodes SINR 较低（需探索 9 维空间），但 4000 episodes 后超越两个单维度策略，最终 SINR 约 9.5 dB，标准差仅约 0.57 dB。低标准差表明 joint agent 能根据场景灵活选择最优(fc, td)组合，在各种干扰模式下均保持高 SINR。
- **Baseline**（固定 fc=1, td=1）：平均 SINR 约 2.6 dB，标准差高达 9.9 dB——完全依赖运气（干扰是否恰好避开该固定参数），验证了自适应策略的必要性。





策略	SINR
freq_only	8.24 ± 3.20 dB
time_only	7.78 ± 4.62 dB
joint	9.50 ± 0.57 dB
Baseline	2.59 ± 9.85 dB

①joint 策略在所有指标上均最优——9 维联合动作空间使 agent 能根据干扰的实际时频分布灵活选择最优参数组合，而单维度策略在"另一维度恰是瓶颈"的场景中无能为力。

②joint 策略的标准差 (0.57 dB) 远低于 freq_only (3.20 dB) 和 time_only (4.62 dB)，说明其性能在各种场景下更为稳定——这是联合探索的核心优势。

③freq_only 略优于 time_only (+0.46 dB)，且标准差更小，暗示在本仿真参数下，频率维度的干扰多样性高于时延维度，频域自适应带来的收益略大。

3.5 本章小结

本章构建了基于 Double DQN + GRU 的 DRL 抗干扰策略执行层，作为分层决策框架的底层模块。主要贡献如下：

①GRU 时序建模：以 32 维 GRU 隐状态捕获干扰环境的动态变化，使 agent 能从 SINR 时序中推断干扰模式，而非仅对瞬时 SINR 做反应式决策。消融实验表明 GRU 是最关键的组件，贡献约 2.3 dB 的 SINR 提升。

②分段奖励函数：SINR ≥ 0 用饱和递增奖励鼓励达标，SINR < 0 用线性惩罚驱动逃离，配合动作切换代价 ($\alpha_3=0.05$) 抑制策略抖动。该设计使 agent 以"最少切换步数达到高 SINR"为目标。

③DAM 动态动作掩码：为三种策略 (freq_only/time_only/joint) 提供标准化的动作空间裁剪接口，既加速了单维度策略的训练 (3 倍样本效率)，又为第四章元策略层提供了策略下发通道。

④稳定训练机制：Double DQN 解耦选择与评估、软更新目标网络 ($\tau=0.005$)、Huber loss + 梯度裁剪、混合精度 FP16——四者协同使 15000 episodes 训练稳定收敛。

⑤实验结论：joint 策略以 9.50 ± 0.57 dB 的 SINR 和 91% 的避开率显著优于两个单维度策略 (freq_only: 8.24 dB, time_only: 7.78 dB)，验证了时频联合探索的必要性。这为第四章元策略控制器中的"联合探索"策略提供了性能基线——当 RF 分类器判定当前场景需要 joint 策略时，执行层具备在 9 维空间中找到近最优解的能力。

四、 基于模式识别的抗干扰策略决策层优化

4.1 分层决策框架的元控制器设计

在第三章纯 DRL 方案中，执行层 agent 以逐 chirp 步的粒度进行动作选择。然而在高动态干扰场景中，仅依赖 DQN 的局部 Q 值估计可能导致探索效率低下——当干扰模式发生变化时，agent 需要大量试错步数才能收敛到新策略。本章在 DRL 执行层之上引入元策略控制器，以固定周期对底层运行状态进行宏观感知与分析，输出元策略指令（时域优先/频域优先/联合探索），通过 DAM 接口转化为动作掩码下发至 DRL 执行层。

执行层仅以标量 SINR 作为环境反馈。SINR 反映当前 (f_c, t_d) 配置下的聚合信号质量，但无法揭示干扰源在频域和时域上的分布结构——即无法回答"当前 SINR 低是因为频域被占满还是时延不匹配"。智能体只能通过切换动作后观测新的 SINR 来间接推断，这导致在环境变化后必须逐一试探各维度才能定位最优配置，表现为动作序列的频繁振荡。元策略层通过 EMA 在线估计各 (f_c, t_d) 组合的 SINR 并计算维度敏感性特征 fc_{gap} 和 td_{gap} ，直接回答了"哪个维度存在更大优化空间"这一 DRL 无法从标量反馈中得到的信息，从而将盲目探索转化为定向搜索。


设计目标：感知信道变化→监控执行层状态→评估策略效果→控制切换代价

本质上：SINR 时序→特征提取→场景分类→元策略输出→动作掩码下发→DRL 执行层

4.1.1 分层决策系统框架

输入：过去 W 步内的 SINR 序列与动作记录；**输出：**元策略标签（freq_only / time_only / joint），通过 DAM 接口将 9 维联合动作空间（3 频点×3 时延）限制为 3 维子空间，加速 DRL 收敛。

时间尺度分离：训练阶段取 $W=50$ 、决策周期 $K=8$ 步，确保 RF 分类器基于充分的统计信息做出稳定决策；测试阶段取 $W=12$ 、 $K=3$ 步，配合策略持久化机制（min_strategy_steps=5），在 30 步/chirp 周期内进行约 6 次有效策略决策，兼顾响应速度与稳定性。



4.1.2 核心元策略定义

定义了三种核心元策略：时域优先策略、频域优先策略和联合探索策略。时域优先策略通过调整发射时延优先规避干扰，频域优先策略通过选择合适频段降低干扰影响，联合探索策略综合考虑时频域因素进行协同优化。

元策略	动作空间	物理含义	适用场景
频域优先(freq_only)	固定td, 3频点 可选	当前时延位置足够好, 仅需换频率规避干扰	频域干扰分布不均, 时域较干净
时域优先(time_only)	固定fc, 3时延 可选	当前载频足够好, 仅需调时延规避干扰	时域干扰分布不均, 频域较干净
联合探索 (joint)	9动作全开放	单维度策略收益不足, 需时频联合优化	高动态/密集干扰, 两维度均需调整

引导机制（纯软引导）：RF 分类器输出策略标签及置信度 p 。对于非 joint 策略，对允许动作施加

$\text{bonus} = \text{base_bonus} \times p^2$ ($\text{base_bonus}=12.0$)，被屏蔽动作保持原始 Q 值不变。相比早期版本的硬掩码 ($Q=-1e9$)，纯软引导保证 Meta-RF 在最坏情况下行为等同纯 DRL，不会因分类器误判 (~15-20%) 而强制选择次优动作。

4.2 基于滑动窗口的场景语义特征提取

设计场景感知特征工程模块，将底层执行层的原始 SINR 序列和动作记录转化为高维语义特征向量，作为后续分类模型的输入。在长度为 W 的滑动窗口内提取 12 维特征，涵盖信号质量统计量、执行层行为特征、避干扰效能特征和干扰维度敏感性特征四类，保证特征在单次 chirp 周期内完成计算。

4.2.1 特征维度设计（12 维）

$$\begin{aligned}\mu &= \frac{1}{W} \sum_{i=t-W+1}^t \text{SINR}_i \\ \sigma &= \sqrt{\frac{1}{W} \sum_{i=t-W+1}^t (\text{SINR}_i - \mu)^2} \\ \Delta = \text{线性回归斜率} &= \frac{\sum_i (i - \bar{i}) (\text{SINR}_i - \mu)}{\sum_i (i - \bar{i})^2} \\ \text{SINRmin} &= \min_{i \in [t-W+1, t]} \text{SINR}_i\end{aligned}$$

SINR 质量统计特征（4 维）：窗口均值 μ （反映平均信号质量）、标准差 σ （反映干扰波动程度）、线性趋势斜率 Δ （反映当前干扰是否在恶化）、窗口最小值 SINRmin （刻画最坏情况）

$$H_{\text{action}} = - \sum_{a=0}^8 p(a) \log p(a)$$

执行层动作行为特征（3 维）：DRL 执行层在过去 W 步的动作熵，值高说明智能体在频繁切换、找不到稳定策略，是场景困难的信号。同时记录 - $r_{\text{freq_switch}}$ 频域动作切换率、- $r_{\text{time_switch}}$ 时域动作切换率

$$r_{\text{avoid}} = \frac{\text{SINR} > 0 \text{ 的步数}}{W}$$

$$\text{SINR}_{\text{gain}} = \mu_{\text{后半窗}} - \mu_{\text{前半窗}}$$

避干扰效能特征（2 维）：后者反应当前策略的“改善趋势”。说明策略正在起效。

$f_t = [\mu, \sigma, \Delta, \text{SINRmin}, H_{\text{action}}, r_{\text{freq}}, r_{\text{time}}, r_{\text{avoid}}, \text{SINR}_{\text{gain}}] \in \mathbb{R}^9$ ，每次 chirp 后计算

$$f_{c_{\text{gap}}} = f_{c_{\text{max}}} - f_{c_{\text{min}}}$$

$$t_{d_{\text{gap}}} = t_{d_{\text{max}}} - t_{d_{\text{min}}}$$

$$f_{c-t_d\text{ratio}} = \log \frac{f_{c_{gap}}}{t_{d_{gap}}}$$

干扰维度敏感性特征（3 维，基于 EMA 运行估计）： $f_{c_{gap}}$ 指代各频点 EMA-SINR 的极值之差（db），反映频率的潜在收益；同理 $t_{d_{gap}}$ 反映各时延 EMA-SINR 的极值之差（db），反映换时延的潜在收益。

（EMA 使运行估计快速跟踪干扰分布变化。训练阶段的数据收集使用 *sinr_table oracle* 值（无噪声 3*3 穷举 SINR）替换 EMA 估计的 $f_{c_{gap}}$ 、 $t_{d_{gap}}$ 、 $f_{c-t_d\text{ratio}}$ ，消除标签噪声。测试阶段通过 *oracle_seed()* 在 warmup 结束时用 *sinr_table* 直接种子化 EMA 状态，消除训练/测试特征分布鸿沟。）

4.2.1 特征有效性预验证

场景标签	物理含义	对应最优元策略
稳定低干扰	干扰数量少，SINR 持续高且波动小	时域优先（省资源）
动态高干扰	干扰源在移动，SINR 剧烈波动	联合探索
频域密集干扰	多个干扰在频域聚集，时域较干净	时域优先
时域密集干扰	干扰延迟集中，频域相对稀疏	频域优先

根据这几类典型场景分别采集特征样本，以箱线图和散点矩阵可视化各特征在不同场景下的分布差异。验证 σ 与 H_{action} 两个特征具有最强的场景区分能力。（为后续分类模型的特征重要性分析提供先验依据。）而 $f_{c_{gap}}$ 与 $t_{d_{gap}}$ 对判别单维度策略起到关键作用。

4.3 基于 RandomForest（RF）（or GRU + Softmax）的元策略分类与可解释性分析

设计监督学习分类器，把干扰场景映射到最优元策略。主要包括：生成自动化标签、分类模型训练与评估、特征重要性驱动的可解释性分析。

4.3.1 分类器设计与训练


训练数据自动生成：*MetaDataCollector* 对每种干扰数量（6/9/12/15/18）各采集 800 个随机场景，共计 4000 条样本。每个场景：①重置环境并预热 60 步（前 54 步系统性扫描 9 个 (fc, td) 组合×6 轮，后 6 步 DRL 随机探索）；②从 *sinr_table oracle* 计算各策略期望 SINR；③以 joint 相对优势准则生成标签——*joint_best - max(freq_best, time_best) ≤ 0.3dB* 时选单维度策略，*>0.3dB* 时选 joint；④用 oracle 值替换 fc_{gap} / td_{gap} / fc_{td_ratio} 特征。

RF 分类器配置： $n_estimators=200, max_depth=12, min_samples_leaf=5, class_weight='balanced_subsample'$ （应对类别不均衡）。训练集/测试集按 8:2 分层划分，5 折交叉验证评估泛化性能。

4.3.2 特征重要性分析与可解释性

提取随机森林的 *feature_importances* 输出，以柱状图呈现 12 个特征的贡献排名。结合混淆矩阵中的误分类模型，解释元策略切换的触发依据：
如 σ 与 H_{action} 贡献度高，说明干扰波动程度和执行层迷茫程度是场景判断的核心依据等；

如 fc_gap 和 td_gap 贡献度高，说明频域/时域相对敏感性的估计是判别单维度策略的关键；如 r_{time_switch} 或 r_{freq_switch} 贡献偏低，说明时域/频域切换特征对策略判别的信息增益不足。让 RF 的决策过程从“黑盒”变成可追溯、可解释的系统行为图谱。
（同时，可以评估特征的重要性是否符合通信领域和强化学习的先验知识）



根据结果得出的初步结论（可解释性分析）：

- ①决策核心是比较维度机会： $f_c - t_{d_ratio}$ 权重最高，表明 meta 元控制器首要判断频域和时域哪个潜在收益更大，据此决定资源投向；
- ②看重改善上限而非当前状态： f_{c_gap} 与 t_{d_gap} 的权重也很高，说明决策依据更关注“调整维度能带来多大极限提升”，有别于当前平均信号水平；
- ③底层执行细节对战略选择影响甚微：原执行层的 SINR 统计量、动作熵、切换率等重要性普遍极低（多数低于 0.04），证明元控制器已从战术细节中抽离，专注于结构性机会评估；
- ④整体呈现“机会驱动”的战略思维：决策链条围绕“哪个维度存在更好的干扰空穴”展开，而非被动响应信号恶化，是一种主动寻优的高层认知。

后续提供的可能优化方向：

移除重要性低的特征、加强重要的特征（优化奖励函数）、系统调优方向（鲁棒性等）

4.4 仿真实验

对比第三章的纯 DRL（时频域联合探索）与加了 RF 元策略层的方案。

- Baseline: 固定 $f_c=1, t_d=1$ （无自适应）
- Pure DRL: 第三章训练的 Joint DQN+GRU agent, $\epsilon=0.05$, 9 动作全开放
- Meta-RF (Ours): RF 元控制器 + 纯软引导, $W=12, K=3, min_strat=5, base_bonus=12.0$

DRL 模型：第三章训练的 joint agent（15000 episodes, batch_size=256, GRU=32 单元, dense=64 单元），加载预训练权重，测试时不做额外训练。

实验环境：FMCW 雷达（ $fc \in \{76.25, 76.75, 77.25\}$ GHz, BW=500 MHz, $T_{sw}=50\mu s$ ），每 episode 30 步/chirp 周期。

4.4.1 实验设置

- 五组实验设计：
- *Exp-A*（系统级 SINR 对比）：200 episodes，干扰数量随机 $\in \{6,9,12,15,18\}$ ，对比三方案的均值 $\pm$ 标准差、避开率及 $n_intf=18$ 下的收敛速度；
 - *Exp-B*（干扰数量扩展性）：每档 100 episodes， $n_intf \in \{6,9,12,15,18,21,24\}$ ，含分布外测试；
 - *Exp-C*（收敛速度对比）：50 episodes $\times$ 4 档干扰数量 $\{6,12,18,21\}$ ，以 T80 步数、早期 SINR、最终 SINR 和早期 AUC 四个指标量化收敛性能；
 - *Exp-D*（动态跳频恢复）：50 trials， $n_intf=9$ ，干扰源在第 15 步随机跳频（全部 fc_index 重分配），比较跳频后恢复速度——这是 *Meta-RF* 的核心优势场景。


4.4.2 实验结果

Exp-A：系统级 SINR 对比，三方案在 200 个随机干扰场景下的平均 SINR 与避开率：


方案	平均SINR (DB)	避开率
Baseline (固定 $fc=1,td=1$)	~-12.26	~75.9%
Pure DRL (Joint Agent)	~-6.42	~85.5%
Meta-RF (Ours)	~-1.32	~90.0%

分析：在静态干扰场景下，Pure DRL与Meta-RF均显著优于Baseline。Meta-RF相比Pure DRL在平均SINR上有约0.3dB的微弱优势，避开率基本持平。这是因为预训练的DRL agent在训练分布内的场景中已近收敛，Meta-RF的引导空间有限。

在 $n_intf=18$ 的30次时序平均中，Meta-RF的早期SINR（前10步均值-9.41dB）显著优于Pure DRL（-12.08dB），提升约2.67dB；T80收敛步数（3.4步）也优于Pure DRL（5.7步）。Baseline的T80最小（3.1步）是因为其性能无需收敛——全程维持在低水平（约-13.8dB），T80值本身不反映性能优势。




Exp-B: 干扰数量拓展性, 对比 $n_intf \in \{6, 9, 12, 15, 18, 21, 24\}$ 七档下的 SINR 折线, meta_RF 策略始终保持着较好的泛化能力:



Exp-C: 收敛速度对比, 四个干扰档位下的收敛指标 (T80=达到最终 SINR 80%所需步数):

指标	N_INTF=6	N_INTF=12	N_INTF=18	N_INTF=21
Pure DRL T80	~3.7步	~3.5步	~4.5步	~5.4步
Meta-RF T80	~3.1步	~4.6步	~3.4步	~2.9步

趋势：Meta-RF 的 T80 优势随干扰数量增加而扩大。在高干扰（ $n_intf=21$ ）下优势最明显。早期 AUC（前 10 步曲线下面积）Meta-RF 更高，反映更快的初始 SINR 上升斜率。早期 SINR 更高、最终 SINR 总体更好、AUC 也更好。




Exp-D: 动态调频恢复：干扰源在第 15 步随机调频后，各方案的恢复表现：

方案	跳频前SINR (DB)	跳频后低点 (DB)	恢复步数
Pure DRL	-0.5	-5.5	~8步
Meta-RF	+2	-4	~5步

跳频后，DRL 的 Q-network 基于旧干扰分布的 Q 值估计完全失效，需重新探索 9 维动作空间；而 Meta-RF 的特征提取器通过 EMA 机制（ $\alpha=0.30$ ）和 oracle_seed（warmup 时用 *sinr_table* 种子化），在新干扰分布下仅需 $W=12$ 步即可更新特征，下一个决策周期（ $K=3$ ）就能输出匹配新模式的策略标签。恢复步数减少约 37%。

核心洞察：在静态/慢变干扰场景下，训练充分的 DRL agent 自身已具较强适应性，Meta-RF 的增益表现为温和的收敛加速；在干扰模式突变（跳频）场景下，Meta-RF 的模式识别能力使其能比纯 DRL 快约 40% 适应新环境——这正是元策略层在认知规划中的核心增量价值。



4.5 本章小结

本章在第三章 DRL 执行层之上引入基于模式识别的元策略控制器，形成"场景感知→特征提取→策略分类→软引导→执行层"的分层决策框架。主要贡献如下：

12 维场景语义特征：联合 SINR 统计量、执行层行为特征、EMA 维度敏感性特征和 oracle 种子化机制，在约 0.3ms 内完成特征提取，为分类器提供丰富且可解释的输入。

纯软引导机制：以 $\text{bonus} = \text{base_bonus} \times p^2$ 替代硬掩码，保证 Meta-RF 在最坏情况下等价于纯 DRL，在环境突变时自动渐进适应，避免了硬掩码在分类器误判时的性能退化。

策略持久化： $\text{min_strategy_steps}=5$ 的滞后机制减少策略抖动，使 DRL 执行层有充足时间在限制子空间内优化。

动态跳频实验揭示元策略核心优势：在干扰频率突发变化的场景下，Meta-RF 通过快速特征更新和模式重识别，恢复速度比纯 DRL 快。这体现了元策略层在非稳态环境中的核心增量——并非替代 DRL 的逐步决策，而是在宏观层面提供快速的环境适应能力。

推理效率：RF 单次推理约 0.3-0.5 ms，满足实时控制需求，远优于 LLM+CoT 方案（100~500 ms），同时具备**可解释性**（特征重要性分析）。

五、 总结与展望

5.1 总结

全面总结论文工作，提炼理论和工程上的主要创新点。

5.2 未来工作展望

指出本研究的局限性，提出后续可继续深入研究的方向。

参考文献

